

Desarrollo de una herramienta predictiva de la PLC y el CHF para la CNA-UII

Ing. Juan Ignacio Teich

2 de octubre de 2026



1. Introducción general
2. Contexto y motivación
3. Predictor de PLC
4. Espacio latente de perfiles de potencia
5. Predictor de CHF
 - 5.1 Modelos finales
6. Conclusiones y trabajo futuro


DESARROLLO DE UNA HERRAMIENTA PREDICTIVA DE LA PLC Y EL CHF
PARA LA CNA-UII

Introducción general

Primero un poco de Ingeniería Nuclear...

Central Nuclear Atucha II (CNA-UII)


- Lima, Pcia. de Buenos Aires, Argentina.
- PHWR de 2 160 MWt y 745 MWe.
- Combustible: uranio natural.
- Refrigerante y moderador: agua pesada (D_2O).
- 451 canales refrigerantes.



Primero un poco de Ingeniería Nuclear...

Criterios de limitación de la potencia térmica.

- Fracción de vapor o vacío (α) a la salida de los canales refrigerantes.
- Distancia al Apartamiento de la Ebullición Nucleada (DNBR, del inglés *Departure from Nucleate Boiling Ratio*).



Primero un poco de Ingeniería Nuclear...

¿Cuándo es necesario recalcular las potencias límite de canal (PLC)?

- Cambios de estrategia de recambio de combustible, cambios de condiciones de operación, operación con canales refrigerantes vacíos previo a parada programada, etc.
- Algunos casos pueden implicar más de 1 millón de cálculos individuales.

¿Cómo se calculan las PLC?

- Código de subcanales COBRA-3CP, especialmente calibrado para la predicción de las condiciones termohidráulicas de los canales refrigerantes de la CNA-UII.

¿Cómo se calcula la distancia al DNB o DNBR?

- Correlaciones de CHF en un tubo.
- Correcciones para la geometría de la CNA-UII a partir de ensayos experimentales.

DESARROLLO DE UNA HERRAMIENTA PREDICTIVA DE LA PLC Y EL CHF
PARA LA CNA-UII

Contexto y motivación

IA + TH

Inteligencia Artificial

+

Termohidráulica

¿Cómo puede la Inteligencia Artificial ayudar a la Termohidráulica Nuclear?

- Velocidad de predicción.
- Nuevas metodologías y mejores predicciones en campos de aplicación complejos.

Objetivos

Objetivos estratégicos:

- Disminuir el tiempo y costo computacional del cálculo de PLC, manteniendo precisión.
- Mejorar la precisión de la predicción de CHF para el bundle de la CNA-UII.

Objetivos específicos:

1. Desarrollar una herramienta predictiva de PLC por fracción de vapor y DNBR, entrenada con simulaciones de código de subcanales.
2. Implementar reducción de dimensionalidad por medio de autoencoders para comprender las características relevantes de los perfiles de potencia de los elementos combustibles.
3. Desarrollar una metodología basada en Inteligencia Artificial para mejorar la precisión de la predicción de CHF para el bundle de la CNA-UII.

DESARROLLO DE UNA HERRAMIENTA PREDICTIVA DE LA PLC Y EL CHF
PARA LA CNA-UII

Predictor de PLC

¿Cómo se pueden aprovechar la IA para obtener mayor velocidad en el cálculo de PLC?

Cálculo de la fracción de vapor y el DNBR, a partir de condiciones termohidráulicas de entrada y perfiles de potencia de los elementos combustibles.

- Pocas variables de entrada.
- Muchos datos disponibles para entrenamiento.


Una red neuronal profunda (DNN) puede aprender la relación entre las condiciones de entrada y los resultados de salida.

Un lazo de cálculo iterativo permite utilizar la DNN para obtener las PLC según las condiciones.

Predictor de PLC - Entrenamiento de la DNN

Conjunto de entrenamiento:

- Potencia entre 5 % y 30 % sobre nominal.
- Temperatura entre 268 y 288 °C (± 10 °C nominal).
- Presión entre 105 y 125 bar (± 10 bar nominal).



Predictor de PLC - Entrenamiento de la DNN

- Optimizador: Adam.
- Optimización de hiperparámetros con Optuna.
- Función de pérdida: MRE para DNBR y $100 \cdot \text{MAE}$ para α .


Hiperparámetros optimizados:

Hiperparámetro	Valor
Cantidad de capas ocultas	3
Cantidad de neuronas por capa	478
Learning rate	$1,38 \cdot 10^{-4}$
Batch	64
Función de activación	ReLU

Predictor de PLC - Resultados de predicción


Predicción de DNBR: subpredicción con media de 0,006. Conservativo.

Predicción de la fracción de vacío: sobrepredicción con media de 0,018. Conservativo.



Predictor de PLC - Lazo de cálculo

¿Cómo estimar PLC a partir de la predicción de DNBR y fracción de vacío de la DNN?



Factor de corrección para asegurar con 95 % de probabilidad y confianza subpredicción de PLC.

$$PLC^* = PLC \cdot F_{PLC} \quad (1)$$


ZH	F_{PLC}	
	DNBR	α
1	0,933	0,985
5	0,995	0,997

Predictor de PLC - Resultados de predicción de PLC

Errores medios de predicción de PLC por DNBR y por fracción de vacío.

ZH	Media del error	
	DNBR	α
1	1,047	1,008
3	1,018	1,002
5	1,001	1,001

Predicciones con y sin corrección para la ZH5.



Predictor de PLC - Tiempos de cómputo

Se estimó la PLC por DNBR y fracción de vacío para 100 estados del reactor.

Aproximadamente un 4 % de una estrategia de recambio de combustible completa.

DNBR: mejora de tiempo de cómputo entre 8 500 y 9 500 veces menor.

Fracción de vacío: mejora de tiempo de cómputo entre 2 000 y 2 500 veces menor.

	Tiempo COBRA3-CP	DNN		Mejora	
		CPU	GPU	CPU	GPU
DNBR	306 h	117 s	130 s	x9 445	x8 503
Fracción de vacío	74 h	108 s	120 s	x2 479	x2 224


DESARROLLO DE UNA HERRAMIENTA PREDICTIVA DE LA PLC Y EL CHF
PARA LA CNA-UII

Espacio latente de perfiles de potencia

Espacio latente de perfiles de potencia

¿Cómo se pueden aprovechar la IA para comprender las características relevantes de los perfiles de potencia de los elementos combustibles?

Autoencoder.



DESARROLLO DE UNA HERRAMIENTA PREDICTIVA DE LA PLC Y EL CHF
PARA LA CNA-UII

Predictor de CHF

Definición del enfoque

Conjuntos de datos disponibles:

- Ensayos experimentales de CHF en tubos, recopilados por Groeneveld $\implies$ alta disponibilidad, no representan la geometría de interés.
- Ensayos experimentales de CHF en bundle de la CNA-UII, realizados por la UColumbia $\implies$ baja disponibilidad de ensayos y de puntos medidos.
- Replicación numérica con COBRA-3CP de los ensayos experimentales de CHF en bundle de la CNA-UII $\implies$ pocos ensayos pero se tienen datos de todos los puntos, sujeto a error por los modelos implementados en COBRA-3CP.

Características adicionales del problema:

- No se tiene una ecuación de conservación a resolver.
- Se tienen tendencias físicas conocidas y validadas con datos experimentales.
- Los ensayos no reportan la ubicación de la ocurrencia de CHF.

Definición del enfoque

Conjuntos de datos disponibles:

Ensayos en tubo	Alta disponibilidad No representan la geometría de interés
Ensayos en bundle CNA-UII	Baja disponibilidad Representan la geometría de interés No informan la ubicación de CHF
Replicación de ensayos con COBRA-3CP	Baja disponibilidad de ensayos Alta disponibilidad de puntos medidos Representan la geometría de interés No informan CHF

Características adicionales del problema:

- No se tiene una ecuación de conservación a resolver.
- Se tienen tendencias físicas conocidas y validadas con datos experimentales.
- Los ensayos no reportan la ubicación de la ocurrencia de CHF.


Definición del enfoque

¿Cómo se puede aprovechar la IA considerando las limitaciones que impone el problema de predecir CHF para la CNA-UII?

Combinación de 2 conceptos:

- Redes Neuronales de **Multifidelidad** (MFNN).
 - Red de baja fidelidad (LFNN) predice CHF en tubos, a partir de condiciones locales.
 - Red de alta fidelidad (HFNN) predice CHF en bundle de la CNA-UII, a partir de condiciones locales y la predicción de la LFNN.
- Redes Neuronales **Informadas por Física** (PINN).
 - Relaciones diferenciales del CHF con las condiciones locales.
 - A partir de los ensayos en tubo.

Arquitectura MFPINN



Relaciones físicas

Entrenamiento de la MFPINN

Entrenamiento con los puntos obtenidos de COBRA-3CP.

Problema: se tiene sólo el mínimo de CHF del ensayo para comparar, y COBRA-3CP obtiene 9060 datos por ensayo. El mínimo hace imposible el entrenamiento.

- **Solución:** entrenamiento con mínimo suave. Se ponderan los puntos con menor predicción de CHF, disminuyendo la cantidad al avanzar las épocas de entrenamiento.

Evaluación de modelos con penalización: se entrena con los ensayos de alto caudal y evalúa con los de bajo caudal. Los modelos con correctas relaciones físicas logran generalizar a la región de menor CHF.

Entrenamiento de la MFPINN

Se evaluó el valor de:

- **La arquitectura de multifidelidad.** Aporta consistencia en la predicción en regiones no entrenadas a través de la información de la LFNN.
- **La incorporación de relaciones físicas.** La correcta combinación de ellas permite reducir la incerteza en la predicción. Asegura predicciones consistentes con la física en regiones no entrenadas.
- **La incorporación de variables adicionales.** No se obtuvo beneficio de ellas, incluso se observó que la predicción empeoraba al incorporarlas.

Predictor de CHF - Modelos finales

DESARROLLO DE UNA HERRAMIENTA PREDICTIVA DE LA PLC Y EL CHF
PARA LA CNA-UII

Conclusiones y trabajo futuro

Conclusiones y trabajo futuro
