

Desarrollo de una herramienta predictiva de la PLC y el CHF para la CNA-UII

Ing. Juan Ignacio Teich

Carrera de Especialización en Inteligencia Artificial

Director

Mg. Ing. Martín Sebastián Silva

Jurado

Ing. Gaston H. Pintos
Dr. Ing. Benjamín A. Tourn
Esp. Ing. Fabricio Lopretto

4 de octubre de 2026


1. Introducción general
2. Contexto y motivación
3. Predictor de PLC
4. Espacio latente de perfiles de potencia
5. Predictor de CHF
6. Conclusiones y trabajo futuro

Introducción general

Primero un poco de Ingeniería Nuclear...

Central Nuclear Atucha II (CNA-UII)


- Lima, Pcia. de Buenos Aires, Argentina.
- PHWR de 2 160 MWt y 745 MWe.
- Combustible: uranio natural.
- Refrigerante y moderador: agua pesada (D_2O).
- 451 canales refrigerantes.



Primero un poco de Ingeniería Nuclear...

Criterios de limitación de la potencia térmica.

- Fracción de vapor o vacío (α) a la salida de los canales refrigerantes.
- Distancia al Apartamiento de la Ebullición Nucleada (DNBR, del inglés Departure from Nucleate Boiling Ratio).



Primero un poco de Ingeniería Nuclear...

¿Cuándo es necesario recalcular las potencias límite de canal (PLC)?

- Cambios de estrategia de recambio de combustible, cambios de condiciones de operación, operación con canales refrigerantes vacíos previo a parada programada, etc.
- Algunos casos pueden implicar más de 1 millón de cálculos individuales.

¿Cómo se calculan las PLC?

- Código de subcanales COBRA-3CP, especialmente calibrado para la predicción de las condiciones termohidráulicas de los canales refrigerantes de la CNA-UII.

¿Cómo se calcula la distancia al DNB o DNBR?

- Correlaciones de CHF en un tubo.
- Correcciones para la geometría de la CNA-UII a partir de ensayos experimentales.

Contexto y motivación

IA + TH

Inteligencia Artificial

+

Termohidráulica

¿Cómo puede la Inteligencia Artificial ayudar a la Termohidráulica Nuclear?

- Velocidad de predicción.
- Nuevas metodologías y mejores predicciones en campos de aplicación complejos.

Objetivos

Objetivos estratégicos:

- Disminuir el tiempo y costo computacional del cálculo de PLC, manteniendo precisión.
- Mejorar la precisión de la predicción de CHF para el bundle de la CNA-UII.

Objetivos específicos:

1. Desarrollar una herramienta predictiva de PLC por fracción de vapor y DNBR, entrenada con simulaciones de código de subcanales.
2. Implementar reducción de dimensionalidad por medio de autoencoders para comprender las características relevantes de los perfiles de potencia de los elementos combustibles.
3. Desarrollar una metodología basada en Inteligencia Artificial para mejorar la precisión de la predicción de CHF para el bundle de la CNA-UII.

Predictor de PLC

¿Cómo se pueden aprovechar la IA para obtener mayor velocidad en el cálculo de PLC?

Cálculo de la fracción de vapor y el DNBR, a partir de condiciones termohidráulicas de entrada y perfiles de potencia de los elementos combustibles.

- Pocas variables de entrada.
- Muchos datos disponibles para entrenamiento.


Una red neuronal profunda (DNN) puede aprender la relación entre las condiciones de entrada y los resultados de salida.

Un lazo de cálculo iterativo permite utilizar la DNN para obtener las PLC según las condiciones.

Predictor de PLC - Entrenamiento de la DNN

Conjunto de entrenamiento:


- Potencia entre 5 % y 30 % sobre nominal.
- Temperatura entre 268 y 288 °C (± 10 °C nominal).
- Presión entre 105 y 125 bar (± 10 bar nominal).



Predictor de PLC - Resultados de predicción


Predicción de DNBR: subpredicción con media de 0,006. Conservativo.

Predicción de la fracción de vacío: sobrepredicción con media de 0,018. Conservativo.



Predictor de PLC - Lazo de cálculo

¿Cómo estimar PLC a partir de la predicción de DNBR y fracción de vacío de la DNN?



Factor de corrección para asegurar con 95 % de probabilidad y confianza subpredicción de PLC.

$$PLC^* = PLC \cdot F_{PLC}$$


ZH	F_{PLC}	
	DNBR	α
1	0,933	0,985
5	0,995	0,997

Predictor de PLC - Resultados de predicción de PLC

Errores medios de predicción de PLC por DNBR y por fracción de vacío.

ZH	Media del error	
	DNBR	α
1	1,047	1,008
3	1,018	1,002
5	1,001	1,001

Predicciones con y sin corrección para la ZH5.



Predictor de PLC - Tiempos de cómputo

Se estimó la PLC por DNBR y fracción de vacío para 100 estados del reactor.

Aproximadamente un 4 % de una estrategia de recambio de combustible completa.

DNBR: mejora de tiempo de cómputo entre 8 500 y 9 500 veces menor.

Fracción de vacío: mejora de tiempo de cómputo entre 2 000 y 2 500 veces menor.


	Tiempo		Mejora		
	COBRA3-CP	DNN			
		CPU	GPU	CPU	GPU
DNBR	306 h	117 s	130 s	x9 445	x8 503
Fracción de vacío	74 h	108 s	120 s	x2 479	x2 224

Espacio latente de perfiles de potencia

Espacio latente de perfiles de potencia

¿Cómo se pueden aprovechar la IA para comprender las características relevantes de los perfiles de potencia de los elementos combustibles?

Autoencoder.



Predictor de CHF

Definición del enfoque

Conjuntos de datos disponibles:

Ensayos en tubo	Alta disponibilidad No representan la geometría de interés
Ensayos en bundle CNA-UII	Baja disponibilidad Representan la geometría de interés No informan la ubicación de CHF
Replicación de ensayos con COBRA-3CP	Baja disponibilidad de ensayos Alta disponibilidad de puntos medidos Representan la geometría de interés No informan CHF

Características adicionales del problema:

- No se tiene una ecuación de conservación a resolver.
- Se tienen tendencias físicas conocidas y validadas con datos experimentales.
- Los ensayos no reportan la ubicación de la ocurrencia de CHF.


Definición del enfoque

¿Cómo se puede aprovechar la IA considerando las limitaciones que impone el problema de predecir CHF para la CNA-UII?

Combinación de 2 conceptos:

- Redes Neuronales de **Multifidelidad** (MFNN).
 - Red de baja fidelidad (LFNN) predice CHF en tubos, a partir de condiciones locales.
 - Red de alta fidelidad (HFNN) predice CHF en bundle de la CNA-UII, a partir de condiciones locales y la predicción de la LFNN.
- Redes Neuronales **Informadas por Física** (PINN).
 - Relaciones diferenciales del CHF con las condiciones locales.
 - A partir de los ensayos en tubo.

Arquitectura MFPINN



Relaciones físicas

Basadas en conceptos de termohidráulica nuclear y validadas con ensayos experimentales de CHF en tubos:

- $\frac{\partial \text{CHF}}{\partial G} \begin{cases} > 0 & (x < 0,15) \cup (G > 3\,000 \text{ kg/m}^2\text{s}) \\ < 0 & (x > 0,15) \cap (G < 3\,000 \text{ kg/m}^2\text{s}) \end{cases}$
- $\frac{\partial \text{CHF}}{\partial x} < 0$
- $\frac{\partial \text{CHF}}{\partial P} > 0 \quad ; \quad P > 60 \text{ bar}$
- $\frac{\partial^2 \text{CHF}}{\partial x^2} > 0 \quad ; \quad x > 0,2$

Entrenamiento de la MFPINN

Entrenamiento con los puntos obtenidos de COBRA-3CP.

Problema: se tiene sólo el mínimo de CHF del ensayo para comparar, y COBRA-3CP obtiene 9060 datos por ensayo. El mínimo hace imposible el entrenamiento por gradiente.

- **Solución:** entrenamiento con mínimo suave. Se ponderan los puntos con menor predicción de CHF, disminuyendo la cantidad al avanzar las épocas de entrenamiento.


Evaluación de modelos con penalización: se entrena con los ensayos de alto caudal y evalúa con los de bajo caudal. Los modelos con correctas relaciones físicas logran generalizar a la región de menor CHF.

Se evaluó el valor de:


- **La arquitectura de multifidelidad.** Aporta robustez en la predicción en regiones no entrenadas a través de la información de la LFNN.
- **La incorporación de relaciones físicas.** La correcta combinación de ellas permite reducir la incerteza en la predicción. Asegura predicciones consistentes con la física en regiones no entrenadas.
- **La incorporación de variables adicionales.** No se obtuvo beneficio de ellas, incluso se observó que la predicción empeoraba al incorporarlas.

Entrenamiento de la MFPINN

MFDNN



MFPINN



$$\text{DNBR}_{\min} = 1,233 (*)$$

$$\text{DNBR}_{\min} = 1,203 (*)$$


Referencia INVAP: $\text{DNBR}_{\min} = 1,212$ (sin penalización).

$\text{DNBR}_{\min}$ en el orden de INVAP pero con modelos penalizados.

(*) $\text{DNBR}_{\min}$ obtenido del conjunto de evaluación.

Predictor de CHF - Modelos finales

MFDNN




$$\text{DNBR}_{\min} = 1,113 (*)$$

Referencia INVAP: $\text{DNBR}_{\min} = 1,212$.

Considerable mejora en $\text{DNBR}_{\min}$ para ambas metodologías.

(*) $\text{DNBR}_{\min}$ obtenido del conjunto de evaluación.

MFPINN



$$\text{DNBR}_{\min} = 1,084 (*)$$

¿Qué impacto tiene la mejora en $\text{DNBR}_{\min}$ sobre la PLC?

	Zona Hidráulica				
	1	2	3	4	5
Diferencia	+2,6 %	+7,6 %	+9,7 %	+3,6 %	+3,0 %

Tener en cuenta:

- Sólo la ZH5 se encuentra limitada por DNBR. Las zonas 1 a 4 están limitadas por la fracción de vacío.
- El cambio de metodología de predicción de CHF podría modificar el $\text{SDL}_{\max}$, impactando en el DNBR_{LCO} .

Conclusiones y trabajo futuro

Conclusiones y trabajo futuro

Objetivos específicos:

- ✓ Herramienta predictiva de PLC.
- ✓ Análisis de características relevantes de los perfiles de potencia de los elementos combustibles.
- ✓ Metodología de predicción de CHF para la CNA-UII, basada en IA.

Objetivos estratégicos:

- ✓ Disminución en entre 2 000 y 9 500 veces el tiempo de cómputo para estimación de PLC.
- ✓ Mejora de la predicción de CHF para el bundle de la CNA-UII, obteniendo un $\text{DNBR}_{\min} = 1,084$ y un posible aumento de PLC de +3,0 %.

Conclusiones y trabajo futuro

Predictor de PLC:

- ☐ Análisis de casos anómalos fuera del conjunto de entrenamiento. ¿Es conservativa la extrapolación?
- ☐ Investigar si se predicen los mismos casos y canales limitantes que con COBRA-3CP.
- ☐ Analizar mejoras en predicción para zonas periféricas. ¿Es necesario entrenar con aun más sobrepotencia en estas zonas?
- ☐ Implementar el modelo en un entorno de cálculo real.

Conclusiones y trabajo futuro

Predictor de CHF:

- ☐ Realizar un análisis cuantitativo de los límites de aplicación de las relaciones diferenciales físicas propuestas.
- ☐ Mejorar el modelo de baja fidelidad, específicamente en el rango de operación de la CNA-UII. ¿Permite mejorar aún más la predicción del modelo MFPINN?
- ☐ Optimización de hiperparámetros por medio de Optuna.
- ☐ Implementación del modelo final en COBRA-3CP.
- ☐ Cálculo del diseño termohidráulico completo para definir el impacto real en PLC.