

Desarrollo de una herramienta predictiva de la potencia límite de canal de la Central Nuclear Atucha II entrenada con simulaciones de código de subcanales

Ing. Juan Ignacio Teich

Carrera de Especialización en Inteligencia Artificial

Director: Mg. Ing. Martín Sebastián Silva (Nucleoeléctrica Argentina S.A.)

Jurados:

Jurado 1 (pertenencia)

Jurado 2 (pertenencia)

Jurado 3 (pertenencia)

Ciudad de [lugar], [mes] de [año]

Resumen

Se desarrolló una metodología para estimar la Potencia Límite de Canal de la Central Nuclear Atucha II, basada en Redes Neuronales, con tiempos de cómputo órdenes de magnitud inferiores a los códigos termohidráulicos empleados en Nucleoeléctrica Argentina S.A. Esto permite disminuir considerablemente los tiempos y costos computacionales de los cálculos termohidráulicos para las estrategias de recambio de combustibles.

Adicionalmente, se propone una metodología novedosa para el cálculo del Flujo Crítico de Calor, incorporando Redes Neuronales Informadas por Física y Redes Neuronales de Multifidelidad, utilizando fuentes de datos de multifidelidad provenientes de ensayos simples, ensayos numéricos y ensayos del *bundle* de la Central Nuclear Atucha II.

Agradecimientos

Esta sección es para agradecimientos personales y es totalmente **OPCIONAL**.

Índice general

Resumen	I
1. Introducción general	1
1.1. Introducción general	1
1.2. Contexto y motivación	4
1.3. Estado del arte	4
1.4. Objetivos	5
2. Introducción específica	7
2.1. Frameworks y bibliotecas	7
2.2. Datasets y datos de entrenamiento	10
2.3. Infraestructura de cómputo	10
3. Diseño e implementación	11
3.1. Pipeline de datos	11
3.2. Arquitectura del modelo	11
3.3. Entrenamiento y optimización	11
3.4. Integración e implementación del sistema	11
4. Ensayos y resultados	13
4.1. Pruebas funcionales del hardware	13
5. Conclusiones	15
5.1. Conclusiones generales	15
5.2. Próximos pasos	15
Bibliografía	17

Índice de figuras

1.1. Fotografía aérea de la Central Nuclear Atucha II ¹	2
1.2. Esquematización de los canales refrigerantes en el núcleo de la CNA-UII y las 5 zonas hidráulicas ²	3
1.3. Curva de Nukiyama ³	3
2.1. Esquema de arquitectura encoder-decoder ⁴	9
2.2. Esquema de PINN ⁵	9
2.3. Esquema de MFDNN y MFPINN ⁶	9

Índice de tablas

1.1. Principales parámetros de diseño y condiciones de operación de la Central Nuclear Atucha II. [1]	2
---	---

Dedicado a... [OPCIONAL]

Capítulo 1

Introducción general

A continuación, se presentan los lineamientos básicos en cuanto al funcionamiento de la Central Nuclear Atucha II, el diseño termohidráulico de la misma, y los métodos de cálculo de Potencia Límite de Canal y estimación de Flujo Crítico de Calor. Se plantea el contexto y la motivación de este trabajo, y el estado del arte de aplicaciones similares. Por último, se establecen los objetivos del trabajo.

1.1. Introducción general

La Central Nuclear Atucha II (CNA-UII) se ubica en la localidad de Lima, en la provincia de Buenos Aires, Argentina. Es una central nuclear de tipo PHWR (del inglés, *Pressurized Heavy Water Reactor*), que utiliza agua pesada (óxido de deuterio) como moderador y refrigerante, y uranio natural como combustible. El reactor nuclear genera 2175 MW térmicos, proveyendo 745 MW eléctricos al Sistema Argentino de Interconexión (SADI). En la figura 1.1 se aprecia una foto aérea de la central.

En la tabla 1.1 se presentan los principales parámetros de diseño y condiciones de operación de la CNA-UII. El núcleo se encuentra dividido en 5 zonas hidráulicas, cada una con un caudal másico característico, dado por un restrictor de caudal o *drossel* distintivo para cada zona de 1 a 4, y sin *drossel* para la zona 5, de forma de obtener el mismo salto entálpico en todos los canales. En la figura 1.2 se presenta una imagen esquemática de la distribución de los canales en el núcleo de la CNA-UII, y las zonas hidráulicas del mismo.

Para cumplir con los criterios de diseño y operación segura establecidos en el Informe Final de Seguridad (IFS) [1], se deben cumplir dos principales criterios en cuanto a la potencia a la que pueden operar los combustibles dentro del núcleo, o Potencia Límite de Canal (PLC): el criterio de límite de vacío a la salida de los canales refrigerantes y el criterio de Apartamiento de la Ebullición Nucleada (DNB, del inglés *Departure from Nucleate Boiling*).

En primer lugar, el límite por vacío establece la cantidad máxima de vapor que se puede tener a la salida de los canales refrigerantes, de forma de evitar vibraciones excesivas en los canales refrigerantes y los elementos combustibles dentro de los mismos. En particular, para la CNA-UII, el límite está establecido en 25 %.

En segundo lugar, el DNB es un cambio en el patrón de flujo que se desarrolla dentro de los canales refrigerantes, pasando de un régimen de ebullición nucleada (en inglés, *Nucleate Boiling*) a un régimen de ebullición en película (en inglés, *Film Boiling*). Este cambio de régimen se llama crisis de la ebullición, y genera un

aumento súbito de la temperatura de la pared calefaccionada, como podemos ver en la curva de Nukiyama [2] en la figura 1.3. Teniendo en cuenta que el criterio de seguridad primordial del diseño termohidráulico de una central es garantizar la integridad de las vainas combustibles y las pastillas combustibles dentro de ellas, evitar el DNB es el criterio principal de diseño. El DNB se caracteriza con el Flujo Crítico de Calor (CHF, del inglés *Critical Heat Flux*), por lo que la estimación del CHF según las condiciones locales de operación es el paso fundamental en el cálculo del límite por DNB. Adicionalmente, se evalúa el margen al DNB (DNBR, del inglés *DNB Ratio*), definido como el cociente entre el calor local y el CHF según las condiciones, que debe estar por encima de un valor fijo que considera la incerteza en la estimación del CHF, la sensibilidad de esta respecto de las condiciones de operación, y que garantiza que ante cualquier transitorio operacional no se tiene DNB.



FIGURA 1.1. Fotografía aérea de la Central Nuclear Atucha II¹.

TABLA 1.1. Principales parámetros de diseño y condiciones de operación de la Central Nuclear Atucha II. [1]

Condiciones Generales de Operación	CNA-UII
Potencia térmica del reactor	2 160 MW _{th}
Caudal másico total	10 576 kg/s
Presión del Sistema Primario	115 bar
Temperatura de entrada del refrigerante	277,8 °C
Temperatura de salida del refrigerante	314,6 °C
Cantidad de zonas hidráulicas del núcleo	5
Cantidad de elementos combustibles en el núcleo	451
Cantidad de barras combustibles por elemento combustible	37

¹Imagen tomada de <https://shorturl.at/9R1O5>

²Imagen tomada del IFS de CNA-UII [1].

³Imagen tomada de <https://www.sciencedirect.com/topics/engineering/pool-boiling-curve>




FIGURA 1.2. Esquematización de los canales refrigerantes en el núcleo de la CNA-UII y las 5 zonas hidráulicas².




FIGURA 1.3. Curva de Nukiyama³.

1.2. Contexto y motivación

Uno de los cálculos más importantes en el diseño termohidráulico de un reactor PHWR es el de las PLC. Este cálculo puede necesitar repetirse más de un millón de veces durante cada iteración del cálculo de una estrategia de recambio de combustibles, lo que implica un alto costo computacional. Por lo tanto, obtener una herramienta que permita computar de manera eficiente las PLC e identificar los casos más críticos a ser evaluados con los códigos termohidráulicos, es de elevado interés. Dado que se cuenta con una amplia variedad de cálculos realizados por la División de Termohidráulica con el código COBRA3-CP [3], es factible plantear una herramienta basada en redes neuronales que permita estimar de manera preliminar las PLC con una alta eficiencia computacional. Debido a que los casos de interés para el diseño son los casos más limitantes, una herramienta que permita la selección de ellos de forma rápida y eficiente permitiría reducir los tiempos de cómputo en órdenes de magnitud.

Adicionalmente, en el cálculo con los códigos termohidráulicos, un paso fundamental es la estimación del CHF en función de las condiciones locales del fluido. Hoy en día, esto se realiza con métodos que se dividen en dos: fórmulas semi-empíricas que buscan capturar la alta dimensionalidad del problema, y tablas de CHF obtenidas de ensayos en geometrías simples que luego son modificadas por factores ad-hoc para replicar lo mejor posible los ensayos realizados sobre las geometrías reales del canal refrigerante del reactor. Se cuentan con datos de ensayos en geometrías sencillas, ensayos para el *bundle* de la CNA-UII realizados por la Universidad de Columbia, y la replicación de los ensayos de manera numérica con el código de subcanales COBRA3-CP. Este caso particular de disponibilidad de datos puede ser aprovechado por redes neuronales de tipo de multifidelidad, como se plantea en el trabajo de Meng y Karniadakis [4]. Además, ya que se está planteando un fenómeno físico, evaluar el impacto de introducir ecuaciones de conservación o relaciones monótonas es de interés, utilizando un enfoque informado por física como se plantea en el trabajo fundacional de las Redes Neuronales Informadas por Física (PINN, del inglés *Physics Informed Neural Network*) de Raissi, Perdikaris y Karniadakis [5].

1.3. Estado del arte

En cuanto al cálculo de PLC, actualmente para la CNA-UII, son calculadas por medio del código de subcanales COBRA3-CP [3] y el código de planta AXCNA2 [6]. Este cálculo es específico de cada central, y al ser confidencial, no se cuenta con información bibliográfica de aplicación de *Machine Learning* (ML).

Por otro lado, para la estimación del CHF, los métodos clásicos se dividen en relaciones semi-empíricas y datos tabulados modificados por factores de ajuste para la geometría de interés. Como ejemplo de relación semi-empírica se tiene la correlación Westinghouse-3 (W-3) [7], utilizada en el diseño de la Central Nuclear Atucha I (CNA-UI), obtenida a partir de observación experimental del efecto individual de presión, caudal y título termodinámico sobre el CHF. Por otro lado, la referencia en cuanto a datos tabulados de CHF son las *Look-up Tables* de Groeneveld (1995 [8] y 2006 [9]), obtenidas a partir de más de 25 000 ensayos de CHF

en un tubo calefaccionado. Para obtener CHF en una geometría real de un reactor, se utilizan factores de corrección, como los *Taylor-made Factors* para el bundle CNA-UII desarrollados por INVAP [10].

Métodos más modernos para la estimación de CHF utilizan ML para mejorar la predicción de las herramientas clásicas, especialmente para las Look-up Tables. Ejemplos de ello se hayan en los trabajos de Zhao et al. [11] [12] y Jin et al. [13], donde se utiliza una PIMLAF (*Physics-Informed Machine Learning-Aided Framework*) para estimar la modificación a realizar a la predicción por Look-up Table para obtener CHF en una geometría compleja. Por otro lado, Mao y Jin [14] aplican PINN para estimar el CHF, pero utilizando como guía física a los enfoques clásicos de estimación de CHF.

1.4. Objetivos

A continuación, se describen brevemente los objetivos del trabajo:

- Desarrollar una herramienta basada en DNN para predecir PLC, a partir de los datos de entrada utilizados en los cálculos termohidráulicos.
- Realizar un análisis de reducción de dimensionalidad de los perfiles de potencia axiales y por barra.
- Desarrollar una herramienta basada en MFPINN para predicción de CHF en función de condiciones locales, a partir de datos de multifidelidad.

Capítulo 2

Introducción específica

A continuación, se explican los frameworks, arquitecturas y bibliotecas utilizadas en el trabajo, los conjuntos de datos utilizados para el entrenamiento y validación de los modelos, y por último, una breve mención a la infraestructura de cómputo utilizada.

2.1. Frameworks y bibliotecas

Las Redes Neuronales Profundas (DNN, del inglés *Deep Neural Networks*) son el modelo fundamental de Aprendizaje Profundo. El objetivo de una DNN es aproximar una función f^* , definiendo un mapeo $y = f(x; \theta)$ del cual se aprenden los parámetros θ para lograr la mejor aproximación de la función objetivo. La unidad básica de las DNN es el perceptrón, el cual aplica una transformación lineal seguido de una transformación no-lineal, llamada activación. Decimos redes neuronales, debido a que se aplican múltiples perceptrones en capas consecutivas. Podemos pensar a las DNN como "máquinas de aproximación de funciones, diseñadas para obtener generalización estadística"[15]. Esto las hace interesantes para su aplicación en la resolución del primer problema planteado en este trabajo: la estimación rápida de PLC, aprovechando la basta cantidad de datos acumulados.

También es de interés en este trabajo analizar la aplicación de reducción de dimensionalidad a partir de algunos *set* de *features*. Para realizar esto, se utiliza una arquitectura *encoder-decoder*. Esta arquitectura se encuentra representada en la figura 2.1, donde se observa una primera DNN, llamada *encoder*, que reduce de dimensión el *input* al vector *feature* o *embedding*, y luego una segunda DNN, llamada *decoder*, que reconstruye a partir del *embedding* el *input*. Esto permite representar la misma información con una menor dimensionalidad, capturando las características representativas del vector de entrada.

Por otro lado, para el planteo de una nueva metodología de estimación de CHF utilizando ML, nos centramos en dos arquitecturas particulares derivadas de las DNN. En el trabajo de Raissi, Perdikaris y Karniadakis [5] se presentan las PINN, las cuales permiten obtener una función de pérdida que busque cumplir una ecuación diferencial en derivadas parciales (PDE, del inglés *Partial Differential Equation*), además de la función de pérdida respecto de los datos tabulados para entrenamiento.

En la figura 2.2 se presenta un esquema general de una arquitectura PINN. Se tiene una DNN que predice $\hat{u}$ a partir de las entradas x y t . Luego se computa por medio de diferenciación automática las derivadas necesarias de $\hat{u}$, como pueden

ser la derivada temporal, el gradiente, el laplaciano, etc. Luego, se calcula el error cuadrático medio (MSE, del inglés *Mean Squared Error*) del residuo del ajuste de los datos rotulados, el residuo de la ecuación de gobierno, el residuo de las condiciones de borde y el residuo de las condiciones iniciales, para luego computar la pérdida global y su gradiente para aplicar el algoritmo de aprendizaje basado en gradiente.

Este enfoque se puede denominar como *grey box*, ya que el modelo, si bien tiene una componente desconocida al entrenarse y ajustar sus parámetros, tiene a la función de pérdida de forma conocida que nos da información de su funcionamiento interno. Los modelos de DNN típicamente se llaman *black box*, mientras que modelos más tradicionales de resolución de problemas físicos como las diferencias finitas, los elementos finitos o los volúmenes finitos, son considerados modelos *white box*. Esta característica es interesante para su aplicación en el ámbito nuclear, ya que este requiere de alta certeza en las predicciones debido a los altos estándares de seguridad que se deben cumplir.

Por otro lado, en el trabajo de Meng y Karniadakis [4] se presenta una arquitectura novedosa de redes neuronales, llamadas Redes Neuronales Profundas de Multi-Fidelidad (MFDNN, del inglés *Multi-Fidelity Deep Neural Networks*). Esta arquitectura permite considerar conjuntos de datos de distinta fidelidad, por ejemplo, datos obtenidos a partir de ensayos experimentales (alta fidelidad, disponibilidad acotada o baja), datos obtenidos a partir de ensayos numéricos (baja fidelidad, disponibilidad acotada o alta), datos de ensayos experimentales en geometrías o condiciones diferentes (baja fidelidad, disponibilidad alta), etc. Para realizar esto, propone la hipótesis de que los datos de alta fidelidad tienen una relación no-lineal con los datos de baja fidelidad de la forma:

$$y_H = \mathcal{F}(\mathbf{x}, y_L), \quad (2.1)$$

siendo y_H la información de alta fidelidad, y_L la información de baja fidelidad y $\mathbf{x}$ los datos de entrada. Esta relación no-lineal es posible de representar con una DNN, por lo que se construye una arquitectura que consiste de una DNN que estima y_L a partir de $\mathbf{x}$, y luego otra que estima y_H a partir de $\hat{y}_L$ y $\mathbf{x}$. En la figura 2.3 se esquematiza esta arquitectura. Debe notarse que el trabajo original propone estimar la relación entre alta y baja fidelidad por medio de dos redes, una lineal ($\mathcal{F}_l$) y otra no-lineal ($\mathcal{F}_{nl}$), pero esto es redundante, ya que una red no-lineal puede capturar la relación lineal.




Si agregamos una función de pérdida basada en lo propuesto en las PINN, obtenemos la variante informada por física de las MFDNN, las Redes Neuronales Informadas por Física de Multi-Fidelidad (MFPINN, del inglés *Multi-Fidelity Physics-Informed Neural Networks*). Esto es lo que se representa en la figura 2.3 con el cómputo de las derivadas de $\hat{y}_H$ y el posterior cálculo de f_e .

Para realizar el desarrollo de las arquitecturas mencionadas, en este trabajo se utiliza la librería PyTorch [16] [17].

¹Imagen tomada de <https://muditb.com>.

²Imagen tomada del curso *Redes Neuronales Informadas por Física* de la CEIA.

³Imagen tomada de Meng y Karniadakis [4].

FIGURA 2.1. Esquema de arquitectura encoder-decoder¹.FIGURA 2.2. Esquema de PINN².FIGURA 2.3. Esquema de MFDNN y MFPINN³.

2.2. Datasets y datos de entrenamiento

En cuanto a los datos de entrenamiento, debemos dividir esta sección en los datos utilizados para la estimación de las PLC y para la estimación de CHF.

Para la estimación de PLC, se utilizan datos de simulaciones realizadas por la División de Diseño Termohidráulico de la Gerencia de Análisis de Seguridad y Diseño del Núcleo (GASyDN) de Nucleoeléctrica Argentina S.A. (NA-SA), los cuales son de carácter confidencial. Los datos fueron generados con el código de simulación termohidráulica de subcanales COBRA3-CP [3], a partir de estados del reactor calculados en las simulaciones de estrategias de recambio de combustibles. De las salidas de las simulaciones de COBRA3-CP se extrae:

- Perfil axial de potencia.
- Perfil de potencia por barra combustible.
- Mínimo DNBR.
- Temperatura de entrada.
- Presión de salida.
- Potencia total.
- Zona hidráulica.

Por otro lado, para la estimación de CHF, se tiene múltiples fuentes de datos. Se incluyen: los datos de ensayos en un tubo usados por Groeneveld en su LUT 2006 [9], obtenidos de [18]; los datos de ensayos sobre el *bundle* de la CNA-UII realizados por la Universidad de Columbia [19]; y el replicado de los ensayos de Columbia con COBRA3-CP, ampliando la cantidad de puntos de ensayo. Estas últimas dos fuentes de datos son de carácter confidencial.

Los datos de ensayos en un tubo tienen los siguientes datos disponibles: diámetro, longitud, presión a la salida, flujo másico, título termodinámico a la salida, entalpía a la entrada, flujo de calor y temperatura de entrada.

Los datos de los ensayos de Columbia tienen los siguientes datos disponibles: presión a la salida, temperatura de entrada, flujo másico, flujo de calor, título termodinámico a la salida y diferencia de presión a la entrada.

2.3. Infraestructura de cómputo

En cuanto a infraestructura de cómputo, debido al carácter confidencial de los datos utilizados, se opta por realizar todo el proceso de entrenamiento en un entorno local. Para ello se dispone de dos computadoras, una provista por la empresa NA-SA, con una placa gráfica NVIDIA A2000 y 32GB de RAM, y otra de uso personal del autor, con una placa gráfica NVIDIA RTX 3090 y 64GB de RAM. Ambas computadoras tienen capacidad apta para el trabajo en cuestión.

Capítulo 3

Diseño e implementación

3.1. Pipeline de datos

3.2. Arquitectura del modelo

3.3. Entrenamiento y optimización

3.4. Integración e implementación del sistema

Capítulo 4

Ensayos y resultados

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

4.1. Pruebas funcionales del hardware

La idea de esta sección es explicar cómo se hicieron los ensayos, qué resultados se obtuvieron y analizarlos.

Capítulo 5

Conclusiones

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

5.1. Conclusiones generales

La idea de esta sección es resaltar cuáles son los principales aportes del trabajo realizado y cómo se podría continuar. Debe ser especialmente breve y concisa. Es buena idea usar un listado para enumerar los logros obtenidos.

En esta sección no se deben incluir ni tablas ni gráficos.

Algunas preguntas que pueden servir para completar este capítulo:

- ¿Cuál es el grado de cumplimiento de los requerimientos?
- ¿Cuán fielmente se pudo seguir la planificación original (cronograma incluido)?
- ¿Se manifestó algunos de los riesgos identificados en la planificación? ¿Fue efectivo el plan de mitigación? ¿Se debió aplicar alguna otra acción no contemplada previamente?
- Si se debieron hacer modificaciones a lo planificado ¿Cuáles fueron las causas y los efectos?
- ¿Qué técnicas resultaron útiles para el desarrollo del proyecto y cuáles no tanto?

5.2. Próximos pasos

Acá se indica cómo se podría continuar el trabajo más adelante.

Bibliografía

- [1] Nucleoeléctrica Argentina S.A. *Informe Final de Seguridad de la Central Nuclear Atucha II*. Confidencial. 2025.
- [2] S. Nukiyama. «The maximum and minimum values of the heat Q transmitted from metal to boiling water under atmospheric pressure». En: *International Journal of Heat and Mass Transfer* 9.12 (1966), págs. 1419-1433. ISSN: 0017-9310. DOI: [https://doi.org/10.1016/0017-9310\(66\)90138-4](https://doi.org/10.1016/0017-9310(66)90138-4). URL: <https://www.sciencedirect.com/science/article/pii/0017931066901384>.
- [3] N.E. Todreas J.W. Jackson e INVAP. COBRA3-CP. *An improved version of COBRA IIIC/MIT-2: a digital computer program for steady state and transient thermal-hydraulic analysis of rod bundle nuclear fuel elements*. Confidencial. 1981.
- [4] X. Meng y G.E. Karniadakis. «A composite neural network that learns from multi-fidelity data: Application to function approximation and inverse PDE problems». En: *Journal of Computational Physics* 401 (2020), pág. 109020. ISSN: 0021-9991. DOI: <https://doi.org/10.1016/j.jcp.2019.109020>. URL: <https://www.sciencedirect.com/science/article/pii/S0021999119307260>.
- [5] M. Raissi, P. Perdikaris y G.E. Karniadakis. «Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations». En: *Journal of Computational Physics* 378 (2019), págs. 686-707. ISSN: 0021-9991. DOI: <https://doi.org/10.1016/j.jcp.2018.10.045>. URL: <https://www.sciencedirect.com/science/article/pii/S0021999118307125>.
- [6] H. Ballesteros. *Descripción y Teoría del Programa AXENA*. Inf. téc. 22-12. Confidencial. Gerencia de Análisis de Seguridad y Diseño del Núcleo, Nucleoeléctrica Argentina S.A., 2012.
- [7] L. S. Tong e Y. S. Tang. *Boiling Heat Transfer and Two-Phase Flow*. 2nd. New York: Taylor & Francis, 1997. ISBN: 1560324855. URL: <https://www.taylorfrancis.com/books/mono/10.1201/9781315138510/boiling-heat-transfer-two-phase-flow-tong>.
- [8] D.C. Groeneveld et al. «The 1995 look-up table for critical heat flux in tubes». En: *Nuclear Engineering and Design* 163.1 (1996), págs. 1-23. ISSN: 0029-5493. DOI: [https://doi.org/10.1016/0029-5493\(95\)01154-4](https://doi.org/10.1016/0029-5493(95)01154-4). URL: <https://www.sciencedirect.com/science/article/pii/0029549395011544>.
- [9] D.C. Groeneveld et al. «The 2006 CHF look-up table». En: *Nuclear Engineering and Design* 237.15 (2007). NURETH-11, págs. 1909-1922. ISSN: 0029-5493. DOI: <https://doi.org/10.1016/j.nucengdes.2007.02.014>. URL: <https://www.sciencedirect.com/science/article/pii/S0029549307002002>.
- [10] INVAP. *Incorporation of the 1995 AECL Lookup Table for CHF to the COBRA3-CP code*. Inf. téc. CNA2-1152-3BEIN-004-A. Confidencial. 2008.
- [11] Xingang Zhao et al. «On the prediction of critical heat flux using a physics-informed machine learning-aided framework». En: *Applied Thermal Engineering* 164 (2020), pág. 114540. ISSN: 1359-4311. DOI: <https://doi.org/10.1016/j.applthermaleng.2020.114540>.

- 1016/j.applthermaleng.2019.114540. URL: <https://www.sciencedirect.com/science/article/pii/S1359431119332065>.
- [12] Xingang Zhao, Robert K. Salko y Koroush Shirvan. «Improved departure from nucleate boiling prediction in rod bundles using a physics-informed machine learning-aided framework». En: *Nuclear Engineering and Design* 374 (2021), pág. 111084. ISSN: 0029-5493. DOI: <https://doi.org/10.1016/j.nucengdes.2021.111084>. URL: <https://www.sciencedirect.com/science/article/pii/S0029549321000364>.
- [13] Yue Jin, Xingang Zhao y Koroush Shirvan. «Constructing A New CHF Look-Up Table Based on the Domain Knowledge Informed Machine Learning Methodology». En: Oak Ridge National Laboratory (ORNL), Oak Ridge, TN (United States). Mar. de 2022. URL: <https://www.osti.gov/biblio/1867773>.
- [14] Congshan Mao y Yue Jin. «Uncertainty quantification study of the physics-informed machine learning models for critical heat flux prediction». En: *Progress in Nuclear Energy* 170 (2024), pág. 105097. ISSN: 0149-1970. DOI: <https://doi.org/10.1016/j.pnucene.2024.105097>. URL: <https://www.sciencedirect.com/science/article/pii/S0149197024000477>.
- [15] Ian Goodfellow, Yoshua Bengio y Aaron Courville. *Deep Learning*. <http://www.deeplearningbook.org>. MIT Press, 2016.
- [16] Adam Paszke et al. *PyTorch: An Imperative Style, High-Performance Deep Learning Library*. 2019. arXiv: 1912.01703 [cs.LG]. URL: <https://arxiv.org/abs/1912.01703>.
- [17] Adam Paszke et al. *PyTorch*. URL: <https://pytorch.org/>.
- [18] D. C. Groeneveld. *Critical Heat Flux Data Used to Generate the 2006 Groeneveld Critical Heat Flux Lookup Tables*. NUREG/KM 0011. Washington, DC: U.S. Nuclear Regulatory Commission, 2019. URL: <https://www.nrc.gov/reading-rm/doc-collections/nuregs/knowledge/km0011/index>.
- [19] L.Lencina y H. Ballesteros. *Recopilación datos experimentales obtenidos de los ensayos termohidráulicos realizados en el Elemento Combustible Atucha II en los Circuitos Experimentales de la CNEA (CEBP y CEAP) y en la Universidad de Columbia*. Inf. téc. 11-08. Confidencial. Gerencia de Análisis de Seguridad y Diseño del Núcleo, Nucleoeléctrica Argentina S.A., 2008.