

Desarrollo de una herramienta predictiva de la potencia límite de canal de la Central Nuclear Atucha II entrenada con simulaciones de código de subcanales

Ing. Juan Ignacio Teich

Carrera de Especialización en Inteligencia Artificial

Director: Mg. Ing. Martín Sebastián Silva (Nucleoeléctrica Argentina S.A.)

Jurados:

Jurado 1 (pertenencia)

Jurado 2 (pertenencia)

Jurado 3 (pertenencia)

Ciudad de [lugar], [mes] de [año]

Resumen

En el presente trabajo se expone el desarrollo de una metodología para estimar la Potencia Límite de Canal de la Central Nuclear Atucha II, basada en redes neuronales, con tiempos de cómputo órdenes de magnitud inferiores a los códigos termohidráulicos empleados en Nucleoeléctrica Argentina S.A. Esto permite disminuir considerablemente los tiempos y costos computacionales de los cálculos termohidráulicos para las estrategias de recambio de combustibles.

Adicionalmente, se propone una metodología para estimar el Flujo Crítico de Calor, que incorpora redes neuronales informadas por física y redes neuronales de multifidelidad. El enfoque integra datos provenientes de ensayos experimentales con geometrías simples y con la geometría del *bundle* de la Central Nuclear Atucha II, y ensayos numéricos.

Para el desarrollo del trabajo se aplicaron conocimientos en redes neuronales, redes neuronales informadas por física, redes neuronales de multifidelidad, y su entrenamiento y optimización.

Agradecimientos

Esta sección es para agradecimientos personales y es totalmente **OPCIONAL**.

Índice general

Resumen	I
1. Introducción general	1
1.1. Introducción a termohidráulica nuclear	1
1.2. Contexto y motivación	4
1.3. Estado del arte	4
1.4. Objetivos	5
2. Introducción específica	7
2.1. Frameworks y bibliotecas	7
2.2. Datasets y datos de entrenamiento	10
3. Diseño e implementación	13
3.1. Estimación de PLC	13
3.1.1. Pipeline de datos	13
3.1.2. Arquitectura del modelo, entrenamiento y optimización	15
3.1.3. Integración e implementación del sistema	17
3.1.4. Arquitectura de embeddings, entrenamiento y aplicación	19
3.1.5. Evaluación del modelo	20
3.2. Estimación de CHF	21
3.2.1. Pipeline de datos	21
3.2.2. Arquitectura del modelo	25
3.2.3. Evaluación del modelo	29
4. Ensayos y resultados	31
4.1. Estimación de PLC	31
4.1.1. Optimización de hiperparámetros	31
4.1.2. Resultados de DNBR y fracción de vacío	32
4.1.3. Estimación de PLC por DNBR y fracción de vacío	35
4.1.4. Aplicación de embeddings	37
4.2. Estimación de CHF	40
4.2.1. Optimización de hiperparámetros	40
4.2.2. Resultados de CHF	40
4.2.3. Comparativa de metodologías	40
5. Conclusiones	41
5.1. Conclusiones generales	41
5.2. Próximos pasos	41
A. Implementación Embeddings	43
Bibliografía	45

Índice de figuras

1.1. Fotografía aérea de la Central Nuclear Atucha II ¹	1
1.2. Esquematación de los canales refrigerantes en el núcleo de la CNA-UII y las 5 zonas hidráulicas ²	2
1.3. Curva de Nukiyama ³	3
2.1. Esquema del loop de cálculo iterativo de la PLC por DNBR con COBRA3-CP.	7
2.2. Comparación de resultados preliminares de estimación de PLC y DNBR por DNN.	8
2.3. Histogramas de las variables de los ensayos de CHF en un tubo recopilados por Groeneveld.	11
2.4. Histogramas de las variables de los ensayos de CHF de la Universidad de Columbia.	11
3.1. Histogramas de fracción de vacío y MDNBR para las simulaciones con COBRA3-CP.	14
3.2. Arquitectura de la DNN para estimación de MDNBR y fracción de vacío, para predicción de PLC.	16
3.3. Lazo de cálculo del flujo de calor que alcanza el MDNBR objetivo.	18
3.4. Esquema del autoencoder: el codificador comprime la entrada en un embedding de baja dimensión y el decodificador reconstruye la entrada a partir de él.	19
3.5. Comparativa de distribuciones de datos de flujo másico, presión, temperatura y título termodinámico entre ensayos de un tubo de Groeneveld y todos los puntos de los ensayos numéricos con COBRA3-CP.	25
3.6. Esquema de la arquitectura de red neuronal de multifidelidad informada por física.	26
4.1. Resultados de los distintos intentos de la optimización.	31
4.2. Resultados de predicción de DNBR y fracción de vacío, para los conjuntos de test y train.	32
4.3. Resultados de predicción de DNBR y fracción de vacío, para el conjunto excluido.	34
4.4. Distribución del error para cada objetivo, por conjunto de datos.	34
4.5. Resultados de estimación de PLC por DNBR y fracción de vacío con factor de corrección, por zona hidráulica.	36
4.6. Gráficos de perfiles axiales con valores más altos, medianos y bajos de cada componente del espacio latente.	38
4.7. Gráficos de perfiles radiales con valores más altos, medianos y bajos de cada componente del espacio latente.	38

Índice de tablas

1.1. Principales parámetros de diseño y condiciones de operación de la Central Nuclear Atucha II.	2
4.1. Hiperparámetros de la arquitectura final.	32
4.2. Media y desvío estándar del error con signo para cada objetivo. . .	33
4.3. Media y desvío estándar del error con signo para cada objetivo, segmentado por rangos de cada objetivo.	33
4.4. Media y desvío estándar de cociente predicho-real, y factor de 95 % de probabilidad y confianza. Por zona hidráulica.	37
4.5. Tiempos de cómputo para cálculo de PLC.	37
4.6. Márgen perdido medio y máximo por utilizar DNN, según zona hidráulica y total.	37
4.7. Media y desvío estándar del error con signo para cada objetivo, para modelos con embeddings.	38
4.8. Márgen perdido medio y máximo por utilizar DNN y embeddings, según zona hidráulica y total.	39

Dedicado a Osvaldo, Susana y Alicia.

Capítulo 1

Introducción general

En este capítulo se presentan los lineamientos básicos en cuanto al funcionamiento de la Central Nuclear Atucha II, su diseño termohidráulico y los métodos de cálculo de Potencia Límite de Canal y estimación de Flujo Crítico de Calor. Se plantea el contexto y la motivación de este trabajo, y el estado del arte de aplicaciones similares. Por último, se establecen los objetivos del trabajo.

1.1. Introducción a termohidráulica nuclear

La Central Nuclear Atucha II (CNA-UII) se ubica en la localidad de Lima, en la provincia de Buenos Aires, Argentina. Es una central nuclear de tipo PHWR (del inglés, *Pressurized Heavy Water Reactor*), que utiliza agua pesada (óxido de deuterio, D_2O) como moderador y refrigerante, y uranio natural como combustible. El reactor nuclear genera 2160 MW térmicos, de los cuales provee 745 MW eléctricos al Sistema Argentino de Interconexión (SADI). En la figura 1.1 se aprecia una foto aérea de la central.



FIGURA 1.1. Fotografía aérea de la Central Nuclear Atucha II¹.

En la tabla 1.1, obtenida del Informe Final de Seguridad (IFS) de la CNA-UII [1], se presentan los principales parámetros de diseño y condiciones de operación de la CNA-UII. El núcleo está compuesto por 451 canales refrigerantes que contienen los elementos combustibles (EECC). Los canales se encuentran agrupados en 5 zonas hidráulicas (ZZHH), cada una con un caudal másico característico. El caudal está determinado por un restrictor de caudal o *drossel* distintivo para las 4 zonas periféricas, y la zona central no tiene *drossel*. La diferenciación de caudal

¹Imagen tomada de <https://na-sa.com.ar/>.

fue realizada durante el diseño de la central, con el objetivo de obtener el mismo salto entálpico en todos los canales. En la figura 1.2 se presenta una imagen esquemática de la distribución de los canales en el núcleo de la CNA-UII y sus ZZHH.

TABLA 1.1. Principales parámetros de diseño y condiciones de operación de la Central Nuclear Atucha II.

Condiciones Generales de Operación	CNA-UII
Potencia térmica del reactor	2 160 MW _{th}
Caudal másico total	10 576 kg/s
Presión del Sistema Primario	115 bar
Temperatura de entrada del refrigerante	277,8 °C
Temperatura de salida del refrigerante	314,6 °C
Cantidad de zonas hidráulicas del núcleo	5
Cantidad de elementos combustibles en el núcleo	451
Cantidad de barras combustibles por elemento combustible	37




FIGURA 1.2. Esquematización de los canales refrigerantes en el núcleo de la CNA-UII y las 5 zonas hidráulicas².

Para cumplir con los criterios de diseño y operación segura establecidos en el IFS, se deben satisfacer dos criterios principales en cuanto a la potencia a la que pueden operar los combustibles dentro del núcleo, o Potencia Límite de Canal (PLC). Los criterios son: por límite de fracción de vacío (α) a la salida de los canales refrigerantes, y por Apartamiento de la Ebullición Nucleada (DNB, del inglés *Departure from Nucleate Boiling*).

En primer lugar, el límite por fracción de vacío establece la cantidad máxima de vapor admisible a la salida de los canales refrigerantes, de forma de evitar

²Imagen tomada del IFS de CNA-UII [1].

vibraciones excesivas en los EECC. En particular, para la CNA-UII, el límite está establecido en 25 %.

En segundo lugar, el criterio de seguridad primordial del diseño de una central nuclear es garantizar la contención de los productos de fisión. Dado que las vainas son la segunda defensa en profundidad para ello, asegurar su integridad es fundamental. Además, el DNB es el mecanismo principal para la degradación de las vainas por efectos térmicos. Por lo tanto, evitar el DNB es el criterio principal del diseño termohidráulico.

El DNB es un cambio en el patrón de flujo que se desarrolla dentro de los canales refrigerantes, en el que se pasa de un régimen de ebullición nucleada (en inglés, *Nucleate Boiling*) a un régimen de ebullición en película (en inglés, *Film Boiling*). Este cambio de régimen se llama crisis de la ebullición y genera un aumento súbito de la temperatura de la pared calefaccionada, como se observa en la curva de Nukiyama [2] en la figura 1.3. Se caracteriza con el Flujo Crítico de Calor (CHF, del inglés *Critical Heat Flux*), por lo que la estimación del CHF según las condiciones locales de operación es el paso fundamental en el cálculo del límite por DNB. Adicionalmente, se evalúa el margen al DNB (DNBR, del inglés *DNB Ratio*), que se define como el cociente entre el flujo de calor local y el CHF según las condiciones. El DNBR debe estar por encima de un valor fijo que considera la incerteza en la estimación del CHF, la sensibilidad de esta respecto de las condiciones de operación, y que garantiza que ante cualquier transitorio esperable (AOO, del inglés *Anticipated Operational Occurrences*) no se tiene DNB.




FIGURA 1.3. Curva de Nukiyama³.

³Imagen tomada y traducida de <https://www.sciencedirect.com/topics/engineering/pool-boiling-curve>.

1.2. Contexto y motivación

Uno de los cálculos más importantes en el diseño termohidráulico de un reactor PHWR es la estimación de las PLC. Este cálculo puede requerir más de un millón de ejecuciones durante cada iteración del diseño de una estrategia de recambio de EECC, lo que implica un alto costo computacional. Por lo tanto, obtener una herramienta que permita computar de manera eficiente las PLC e identificar los casos más críticos a ser evaluados con los códigos termohidráulicos es de elevado interés. Dado que se cuenta con una amplia variedad de cálculos realizados por la División de Termohidráulica con el código COBRA3-CP [3], es factible plantear una herramienta basada en redes neuronales que permita estimar de manera preliminar las PLC con una alta eficiencia computacional. Debido a que los casos de interés para el diseño son los casos más limitantes, una herramienta que permita la selección de ellos de forma rápida y eficiente permitiría reducir los tiempos de cómputo en órdenes de magnitud.

Adicionalmente, en el cálculo con los códigos termohidráulicos, un paso fundamental es la estimación del CHF en función de las condiciones locales del fluido. Hoy en día, esto se realiza con métodos que se dividen en dos: fórmulas semi-empíricas que buscan capturar la alta dimensionalidad del problema, y tablas de CHF obtenidas de ensayos en geometrías simples que luego son modificadas por factores ad-hoc para replicar lo mejor posible los ensayos realizados sobre las geometrías reales del canal refrigerante del reactor. Se cuenta con datos de ensayos en geometrías sencillas, ensayos para el bundle de la CNA-UII realizados por la Universidad de Columbia, y la replicación de los ensayos de manera numérica con el código de subcanales COBRA3-CP. Este caso particular de disponibilidad de datos puede ser aprovechado por redes neuronales de tipo multifidelidad, como se plantea en el trabajo de Meng y Karniadakis [4]. Además, ya que se plantea un fenómeno físico, evaluar el impacto de introducir ecuaciones de conservación o relaciones monótonas es de interés, mediante un enfoque informado por física como se plantea en el trabajo fundacional de las redes neuronales informadas por física (PINN, del inglés *Physics Informed Neural Network*) de Raissi, Perdikaris y Karniadakis [5].

1.3. Estado del arte

En cuanto al cálculo de PLC, actualmente para la CNA-UII se realiza por medio del código de subcanales COBRA3-CP y el código de planta AXCNA2 [6]. Este cálculo es específico de cada central y, al ser confidencial, no se cuenta con información bibliográfica de aplicación de aprendizaje automático (ML, del inglés *Machine Learning*).

Por otro lado, para la estimación del CHF, los métodos clásicos se dividen en relaciones semi-empíricas y datos tabulados modificados por factores de ajuste para la geometría de interés. Como ejemplo de relación semiempírica se tiene la correlación Westinghouse-3 (W-3) [7], utilizada en el diseño de la Central Nuclear Atucha I (CNA-UI), obtenida a partir de observación experimental del efecto individual de presión, caudal y título termodinámico sobre el CHF. Por otro lado, la referencia en cuanto a datos tabulados de CHF son las Look-up Tables de Groeneveld (1995 [8] y 2006 [9]), obtenidas a partir de más de 25 000 ensayos de CHF en un tubo calefaccionado. Para obtener CHF en una geometría real de un reactor, se

utilizan factores de corrección, como los *Taylor-made Factors* (TMF) para el bundle CNA-UII desarrollados por INVAP [10].

Métodos más modernos para la estimación de CHF utilizan ML para mejorar la predicción de las herramientas clásicas, especialmente para las Look-up Tables. Ejemplos de ello se encuentran en los trabajos de Zhao et al. [11], [12] y Jin et al. [13], donde se utiliza una PIMLAF (*Physics-Informed Machine Learning-Aided Framework*) para estimar la modificación a realizar a la predicción por Look-up Table para obtener CHF en una geometría compleja. Por otro lado, Mao y Jin [14] aplican PINN para estimar el CHF, pero con la guía física de los enfoques clásicos de estimación de CHF.

1.4. Objetivos

En función del problema descripto, se orientaron los objetivos específicos al desarrollo y evaluación de la viabilidad de modelos basados en redes neuronales para asistir en cálculos termohidráulicos de la CNA-UII. Se establecieron los siguientes objetivos específicos:

- Desarrollar una herramienta basada en DNN para predecir PLC, a partir de los datos de entrada utilizados en los cálculos termohidráulicos.
- Realizar un análisis de reducción de dimensionalidad de los perfiles de potencia axiales y por barra.
- Desarrollar una herramienta basada en MFPINN para predicción de CHF en función de condiciones locales, a partir de datos de multifidelidad.

Capítulo 2

Introducción específica

En este capítulo se explican los frameworks, arquitecturas y bibliotecas utilizados en el trabajo, los conjuntos de datos para el entrenamiento y validación de los modelos y por último, se describe la infraestructura de cómputo utilizada.

2.1. Frameworks y bibliotecas

En esta sección se establecen los frameworks y bibliotecas utilizados para resolver los dos problemas planteados en este trabajo: la estimación de PLC y la estimación del CHF.

En primer lugar, la estimación de las PLC se realizó con redes neuronales profundas (DNN, del inglés *Deep Neural Networks*). Esta metodología fue elegida principalmente debido a su elevada capacidad de representar funciones no lineales, característica fundamental para el cálculo de las PLC que presentan un alto grado de no linealidad. Para su implementación se consideraron dos posibilidades: un modelo que calcule directamente PLC, y un modelo que reemplace el paso realizado por COBRA3-CP en el procedimiento de cálculo. En la figura 2.1 se esquematiza el procedimiento de cálculo con COBRA3-CP de la PLC por DNBR. El procedimiento para cálculo de PLC por vacío es similar, pero se aproxima al valor deseado de vacío por el método de la secante [15].




FIGURA 2.1. Esquema del loop de cálculo iterativo de la PLC por DNBR con COBRA3-CP.

Se realizaron pruebas conceptuales de ambas metodologías, y se identificó una dificultad relevante para estimar la PLC de manera directa, que se ejemplifica en la figura 2.2a. Por lo tanto, se decidió implementar un modelo que reemplace a COBRA3-CP y, a partir de las condiciones termohidráulicas del canal, estime el DNBR mínimo (MDNBR). Esta implementación demostró una capacidad predictiva superior, que se evidencia en la figura 2.2b. Se estimó que se tendría un comportamiento similar para la estimación de la PLC por vacío, por lo que se aplicó la misma metodología. También se evaluó la aplicación de una DNN para obtener tanto el MDNBR como el vacío a la salida del canal con un único modelo.




FIGURA 2.2. Comparación de resultados preliminares de estimación de PLC y DNBR por DNN.

Esta metodología adicionalmente permite una mayor adquisición de datos, dado que cada canal tiene una única PLC, pero se tienen infinitas posibilidades de MDNBR al variar su potencia. Si se recuerda que las DNN pueden ser pensadas como “máquinas de aproximación de funciones, diseñadas para obtener generalización estadística” [16], cuanto mayor disponibilidad de datos, mejor el comportamiento final del modelo.

También es de interés en este trabajo analizar la aplicación de reducción de dimensionalidad a partir de las features de los perfiles de potencia axiales y por barra. Para realizar esto, se utilizó una arquitectura encoder-decoder. Esta arquitectura consiste de dos DNN: la primera, el encoder, reduce la dimensión del vector de entrada; la segunda, el decoder, amplifica la dimensión reducida, para recuperar el vector original. Este tipo de arquitectura permite encontrar características relevantes, lo que puede reducir la cantidad de features que necesita como entrada la DNN de estimación de DNBR.

Por otro lado, en cuanto a la estimación de CHF, se debe tener en cuenta que implica la predicción de un fenómeno físico. Por lo tanto, la aplicación de una arquitectura PINN, presentada por Raissi, Perdikaris y Karniadakis [5], resultó la primera alternativa a considerar. Este tipo de arquitectura permite utilizar una función de pérdida que busque cumplir una ecuación diferencial en derivadas parciales (PDE, del inglés *Partial Differential Equation*), además de la función de pérdida respecto de los datos tabulados para entrenamiento. En principio esto resulta un problema complicado, ya que definir una ecuación que permita describir la fenomenología del DNB es una cuestión aún no resuelta. Existen intentos de deducir una ecuación que dependa lo menos posible de factores empíricos, como la de Zhao et al. [12], pero estos no son del todo satisfactorios. Adicionalmente, la información disponible de los ensayos del bundle de la CNA-UII sólo provee información a la salida de la sección ensayada, por lo que computar derivadas espaciales resulta imposible.

Por este motivo, se propuso utilizar una metodología novedosa para la estimación de CHF basada en redes neuronales profundas de multifidelidad (MFDNN, del inglés *Multi-Fidelity Deep Neural Networks*), propuestas por Meng y Karniadakis [4]. Esta arquitectura permite considerar conjuntos de datos de distinta fidelidad, por ejemplo, datos obtenidos a partir de ensayos experimentales (alta fidelidad, disponibilidad acotada o baja), datos obtenidos a partir de ensayos numéricos (baja fidelidad, disponibilidad acotada o alta), datos de ensayos experimentales en geometrías o condiciones diferentes (baja fidelidad, disponibilidad alta), etc. Para realizar esto, se propone la hipótesis de que los datos de alta fidelidad tienen una relación no lineal con los datos de baja fidelidad, que puede ser aproximada por medio de una DNN. Esta metodología se ajusta a los datos disponibles, que combinan información de muy alta fidelidad pero muy acotados, y múltiples fuentes de datos de baja o mediana fidelidad con gran volumen.

Para realizar el desarrollo de las arquitecturas mencionadas, en este trabajo se utilizó la biblioteca PyTorch [17], [18]. Esta biblioteca permite la implementación de arquitecturas derivadas de un módulo `torch.nn.Module()`, que facilita el desarrollo de modelos complejos. Para evaluar las propiedades termofísicas del agua se utilizó la biblioteca CoolProp [19], de amplia adopción y frecuente actualización. La biblioteca Pandas [20, 21] se utilizó para la manipulación de datos en formato tabulado. Para diversas funciones de transformación de los datos en el pipeline se hizo uso de las bibliotecas Scikit-learn [22] y NumPy [23]. Para graficado de resultados se utilizaron las bibliotecas Matplotlib [24] y Seaborn [25]. Para la optimización de los hiperparámetros se utilizó la biblioteca Optuna [26].

2.2. Datasets y datos de entrenamiento

En cuanto a los datos de entrenamiento, se debe dividir esta sección en los datos utilizados para la estimación de las PLC y para la estimación de CHF.

Para la estimación de PLC, se utilizaron datos de simulaciones realizadas por la División de Diseño Termohidráulico de la Gerencia de Análisis de Seguridad y Diseño del Núcleo (GASyDN) de Nucleoeléctrica Argentina S.A. (NA-SA), que son de carácter confidencial. Los datos fueron generados con el código de simulación termohidráulica de subcanales COBRA3-CP [3], a partir de estados del reactor calculados en las simulaciones de estrategias de recambio de combustibles. De las salidas de las simulaciones de COBRA3-CP se extrajeron los datos de entrada al código (perfiles de potencia axiales y por barra combustible, temperatura de entrada, presión de salida, potencia total, zona hidráulica, caudal, etc.), y los datos de salida del código (mínimo DNBR, fracción de vacío a la salida).

Por otro lado, para la estimación de CHF, se tienen múltiples fuentes de datos. Se incluyen los datos de ensayos en un tubo usados por Groeneveld en su LUT 2006, obtenidos de [27]; los datos de ensayos sobre el bundle de la CNA-UII realizados por la Universidad de Columbia [28]; y la réplica de los ensayos de Columbia con COBRA3-CP, que permite ampliar la cantidad de puntos de ensayo y obtener datos en función de la coordenada z . Estas últimas dos fuentes de datos son de carácter confidencial.

Los datos de ensayos en un tubo tienen las siguientes variables disponibles: diámetro, longitud, presión a la salida, flujo másico, título termodinámico a la salida, entalpía a la entrada, flujo de calor y temperatura de entrada. En la figura 2.3 se muestran los histogramas de las variables de estos ensayos.

En los ensayos de Columbia se registraron las siguientes variables: presión a la salida, temperatura de entrada, flujo másico, flujo de calor, título termodinámico a la salida y diferencia de presión a la entrada. En la figura 2.4 se presentan los histogramas de las variables de estos ensayos.

En cuanto a infraestructura de cómputo, debido al carácter confidencial de los datos utilizados, se optó por realizar todo el proceso de entrenamiento en un entorno local. Para ello se dispuso de dos computadoras, una provista por la empresa NA-SA, con una placa gráfica NVIDIA A2000 y 32 GB de RAM, y otra de uso personal del autor, con una placa gráfica NVIDIA RTX 3090 y 64 GB de RAM. Ambas computadoras tienen capacidad apta para el trabajo en cuestión.




FIGURA 2.3. Histogramas de las variables de los ensayos de CHF en un tubo recopilados por Groeneveld.




FIGURA 2.4. Histogramas de las variables de los ensayos de CHF de la Universidad de Columbia.

Capítulo 3

Diseño e implementación

En este capítulo se describe el diseño e implementación de los dos modelos desarrollados en este trabajo. Debido a ello, se divide el capítulo en dos secciones, una para la estimación de PLC y otra para la de CHF.

3.1. Estimación de PLC

En esta sección se describe el modelo desarrollado para estimar PLC. Se presentan el pipeline de datos, la arquitectura de la DNN para estimar DNBR y fracción de vacío, su entrenamiento y optimización, y la implementación del modelo para el cálculo de PLC.

Se construyó un archivo Python llamado `plc.py` con funciones auxiliares, empleadas a lo largo del flujo de procesamiento, entrenamiento y evaluación.

3.1.1. Pipeline de datos

Para la estimación de PLC, los datos provienen de simulaciones con COBRA3-CP de estados del reactor correspondientes al diseño de la estrategia de recambio de combustibles. Se evaluaron 100 estados del reactor, cada uno implica una simulación por canal refrigerante, es decir, 451 simulaciones.

De las simulaciones de COBRA3-CP, se extrajeron dos conjuntos de información: por un lado, la información de entrada al código y, por otro, la información de salida del código. La información de entrada al código de interés está compuesta por la zona hidráulica de ejecución, el perfil axial de potencia, el perfil por barra o radial de potencia, la potencia total del EECC, el caudal de entrada, la temperatura de entrada y la presión a la salida. En cuanto a la información de salida, se provee la fracción de vacío promedio a la salida del canal, y el MDNBR. Estos valores se extrajeron para cada caso y canal.

Debido a que los datos de una estrategia están alrededor de los parámetros de operación del reactor, se agregó una varianza a los parámetros de potencia total, temperatura de entrada y presión a la salida. Esto fue realizado por medio de un script de Python, con las funciones `random()` y `randint()` de la biblioteca `random`, que proveen una distribución uniforme en el rango establecido. Se incrementó la potencia con aumentos de entre 5 % y 30 %, con intervalos de 5 %. La temperatura se evaluó dentro de un intervalo uniforme entre 268 °C y 288 °C (± 10 °C respecto de la temperatura nominal de operación), y la presión entre 105 bar y 125 bar (± 10 bar respecto de la presión nominal de operación). Estos rangos

son similares a los utilizados para calcular el límite de operación segura (SDL, del inglés *Safety Design Limit*) en el diseño termohidráulico de la CNA-UII.

Las simulaciones se realizaron en paralelo y fueron procesadas al finalizar, para luego borrar el directorio de ejecución. De esta manera se evitó un excesivo volumen de datos en disco que no proveían valor.

La distribución de fracción de vacío y MDNBR obtenida se presenta en la figura 3.1. Se observa que el MDNBR presenta una fuerte dependencia con la ZH. Esto es esperable ya que cada ZH tiene un rango de caudales y una relación potencia-caudal características, y los límites de DNBR aumentan hacia las ZH periféricas. Es entonces un criterio de evaluación del modelo final la correcta predicción para cada ZH de la PLC. Por otro lado, la fracción de vacío presenta una distribución uniforme en casi todo el dominio, con un pico en 0, es decir, condiciones sin presencia de vapor a la salida del canal.




FIGURA 3.1. Histogramas de fracción de vacío y MDNBR para las simulaciones con COBRA3-CP.

Al realizar las simulaciones y procesarlas se generó un archivo con extensión `csv`, que tiene las siguientes columnas: `caso`, `canal`, `zh`, `pa1`, ..., `pa22`, `pr1`, ..., `pr37`, `power`, `void`, `caudal`, `temperatura`, `presion`, `MDNBR`. Este archivo fue importado como un objeto `pandas.DataFrame`, de la biblioteca `Pandas`. Las columnas `caso`, `canal` y `zh` se descartaron, las primeras dos debido a que no aportan información y la zona hidráulica debido a que queda unívocamente representada por el caudal.

Se filtraron los resultados a utilizar por el valor de MDNBR y fracción de vacío, para utilizar sólo valores en el rango de interés al calcular las PLC. Los datos que exceden estos rangos sirvieron de set adicional de evaluación, para determinar la capacidad de generalización del modelo ante valores no incluidos en el entrenamiento. Se filtraron los casos con MDNBR entre 1,7 y 2,5, o fracción de vacío entre 15 % y 35 %.

Con los resultados filtrados el pipeline es el siguiente:

1. Conversión a tensores (`torch.tensor(, dtype=torch.float32)`) para las features (todas las variables menos MDNBR y void) y target.

2. División entre train y test por medio de `train_test_split` de scikit-learn.
3. Normalización de tensores de features y targets por medio de la función `plc.scale_tensors()`, que utiliza por dentro `StandardScaler()` de scikit-learn.

3.1.2. Arquitectura del modelo, entrenamiento y optimización

El estimador de PLC utiliza una arquitectura estándar de DNN, a partir del módulo `torch.nn.Sequential` y su método `add_module()`. Los hiperparámetros a configurar son cantidad de capas ocultas, cantidad de neuronas en las capas ocultas, función de activación, aplicación de regularización por dropout, learning rate y tamaño del batch de entrenamiento.

En la figura 3.2 se esquematiza la arquitectura implementada. La entrada reúne las 63 variables mencionadas previamente: 22 componentes del perfil axial, las 37 componentes del perfil radial, y las condiciones termohidráulicas de operación. A estas se aplica en la capa de entrada una función de activación σ . A continuación, estas variables ingresan en una red de L capas ocultas con h neuronas cada una, que aplican σ en cada nodo. Por último, la capa de salida está compuesta por dos variables, el MDNBR y la fracción de vacío.

Para el armado de la arquitectura se desarrolló la función `plc.build_model` que permite en una línea obtener el modelo con los hiperparámetros deseados.

Para entrenar al modelo se utilizó Adam [29] como optimizador, debido a su alta capacidad y adopción en casos clásicos de DNN. Como función de pérdida se utilizó la raíz del error cuadrático medio (RMSE, del inglés *Root Mean Squared Error*), debido a que penaliza fuertemente los errores grandes y tiene magnitud del orden de las variables a optimizar.

Durante el entrenamiento se evaluó, además de la función de pérdida, el coeficiente de correlación R^2 , tanto para el set de entrenamiento como el de evaluación. Al predecir sobre el set de evaluación, se utilizó la condición `torch.no_grad()` para evitar que se aprenda de este set de datos y genere data leakage. Se desarrolló la función de ayuda `plc.train_model` para realizar el entrenamiento sobre la cantidad de épocas deseadas de forma sencilla.

La definición de los hiperparámetros se realizó por medio de su optimización con Optuna. Para ello se planteó un estudio de hiperparámetros con 50 trials de 200 épocas cada uno. Se consideraron DNN con entre 2 y 15 capas ocultas, de entre 32 y 512 neuronas cada uno, con un learning rate de entre 10^{-2} y 10^{-5} y batches de entrenamiento de entre 16 y 256. Las funciones de activación consideradas fueron ReLU [30], GELU [31], SiLU/Swish [32], Tanh, Leaky ReLU [33] y ELU [34].

Es importante señalar que la DNN predice dos valores con distinta escala y criticidad. Por lo tanto, es necesario un criterio para equiparar o ponderarlos en el cálculo de la función de pérdida en entrenamiento.

En el capítulo 4 se presentan los resultados de la optimización realizada.




FIGURA 3.2. Arquitectura de la DNN para estimación de MDNBR y fracción de vacío, para predicción de PLC.

3.1.3. Integración e implementación del sistema

La integración consiste en realizar el lazo de cálculo de PLC de COBRA, pero con la DNN entrenada en su lugar. Se tiene un lazo para cada límite de PLC, pero son idénticos en concepto. Únicamente se debe modificar la variable objetivo según si el criterio es de DNB o de fracción de vacío.

El lazo de cálculo se esquematiza en la figura 3.3. Allí se observa que, en primer lugar, se deben definir las condiciones operativas de temperatura y presión, y el límite objetivo, ya sea de MDNBR o de fracción de vacío. Luego se realizan dos cálculos, uno de piso y otro de techo, donde se evalúan los flujos de calor mínimo y máximo. Estos valores se establecen previamente y deben contener al flujo de calor correspondiente al límite objetivo, por lo que un rango amplio es recomendable. Se obtiene el valor del límite para el flujo de calor mínimo y máximo y por el método de la secante se estima el flujo de calor que debería obtener el límite objetivo. Se recalcula el caudal másico con dicho flujo de calor, y se vuelve a estimar el límite. Si se obtiene convergencia tanto en el límite objetivo como en caudal y flujo de calor, se termina el lazo de cálculo. Si no se obtiene convergencia, se realiza una nueva iteración del método de la secante.

Para calcular el flujo másico en función del flujo de calor, se recurrió a la relación caudal-potencia desarrollada por INVAP en [35], donde para cada ZH y condición operativa se tiene una tabla para interpolar caudal másico a partir de potencia de canal.




FIGURA 3.3. Lazo de cálculo del flujo de calor que alcanza el MDNBR objetivo.

3.1.4. Arquitectura de embeddings, entrenamiento y aplicación

Como se definió en la sección de objetivos 1.4, se realizó un análisis de reducción de dimensionalidad de los perfiles de potencia axiales y por barra. Para ello, se planteó una arquitectura de codificador-decodificador (en inglés, encoder-decoder o autoencoder). Esto permite llevar el vector de entrada, en $\mathbb{R}^n$, a un espacio latente, $\mathbb{R}^d$, de menor dimensión, $d < n$. De esta forma se obtiene una representación compacta del vector de origen. Para lograr esto, el autoencoder se compone de dos DNN. La primera, el encoder, codifica al espacio latente, y la segunda, el decoder, decodifica nuevamente al espacio original. En la figura 3.4 se presenta un esquema del autoencoder.




FIGURA 3.4. Esquema del autoencoder: el codificador comprime la entrada en un embedding de baja dimensión y el decodificador reconstruye la entrada a partir de él.

Se entrenó un autoencoder independiente para cada perfil, ya que se trata de magnitudes de distinta naturaleza y dimensión: el perfil axial, con $n = 22$ componentes, y el perfil radial o por barra, con $n = 37$ componentes. Los perfiles se extrajeron del mismo archivo csv descrito en el pipeline de datos, se convirtieron a tensores de `torch`, se dividieron en `train` y `test` con `train_test_split`, y se normalizaron con `StandardScaler()`, de la misma manera que las features del estimador de PLC.

Tanto el codificador como el decodificador se implementaron como DNN con el módulo `torch.nn.Sequential`, con el mismo esquema que `plc.build_model`. El codificador toma las n componentes del perfil y las reduce progresivamente hasta la capa latente de dimensión d , mientras que el decodificador replica la estructura de forma espejada y expande de d a n . La capa latente no lleva función de activación, para no restringir el rango del embedding, y la capa de salida tampoco, dado que la reconstrucción se realiza sobre variables normalizadas que pueden tomar valores de ambos signos. Los hiperparámetros a configurar son entonces la dimensión latente d , la cantidad de capas ocultas de cada rama,

la cantidad de neuronas por capa, la función de activación, el learning rate y el tamaño del batch.

El entrenamiento es no supervisado: el propio perfil de entrada oficia de target, y la función de pérdida es el error cuadrático medio entre la entrada y su reconstrucción, $\mathcal{L}(\phi, \theta) = \|\mathbf{x} - \hat{\mathbf{x}}\|^2$, como se indica en la figura 3.4. Se utilizó nuevamente el optimizador Adam, con el mismo lazo de entrenamiento por épocas empleado en `plc.train_model`.

La elección de d se realizó por barrido: se entrenó un autoencoder para cada dimensión latente y se comparó el error de reconstrucción sobre el set de evaluación. De esta manera se identificó la menor dimensión que conserva la información relevante del perfil. Una vez entrenado el autoencoder, se descartó el decodificador y se conservó únicamente el codificador, que se aplicó sobre los perfiles para reemplazar las 22 y 37 componentes originales por sus respectivos embeddings de dimensión d .

Con las nuevas features se reentrenó el estimador de PLC descrito en las subsecciones anteriores, y en el capítulo 4 se comparan sus resultados contra los del modelo que utiliza los perfiles completos.

A partir de la transformación al espacio latente, se pueden evaluar cuáles son las componentes que caracterizan a los perfiles de potencia, y cómo impactan en la PLC. Como referencia, se realizó un análisis análogo por medio de análisis de componentes principales (PCA, del inglés *Principal Component Analysis*) [36].

3.1.5. Evaluación del modelo

Para evaluar los modelos predictores de PLC, no basta únicamente con presentar medidas estadísticas del error, como pueden ser el error cuadrático medio (MSE, del inglés *Mean Squared Error*), su raíz (RMSE, del inglés *Root Mean Squared Error*) o error absoluto medio (MAE, del inglés *Mean Absolute Error*). Por la naturaleza de la aplicación de este modelo, debe validarse también el conservadurismo de su predicción, esto es, asegurar con cierto grado de probabilidad y confianza que se predice una PLC por debajo de la referencia. Para ello, se aplicó un criterio similar al utilizado en el diseño termohidráulico de la CNA-UII para calcular el $\text{DNBR}_{\min}$, descrito en la sección 3.2.3.

Se definió el factor de ajuste de PLC, o F_{PLC} , que asegura con 95 % de probabilidad y confianza que se subestima la PLC. Entonces, se buscó el intervalo de tolerancia que con 95 % confianza contiene al 95 % de las predicciones por debajo del valor real. Se requería el factor de tolerancia o k y, en este caso, dada la alta cantidad de muestras, se pudo tomar el límite con infinitas muestras. Para 95 % de confianza, 95 % de probabilidad e infinitas muestras, se obtuvo $k_{95/95} = 1,645$. Entonces, F_{PLC} se obtiene según la ecuación 3.1,

$$\frac{1}{F_{\text{PLC}}} = \bar{R} + k_{95/95} \cdot \sigma(R), \quad (3.1)$$

donde R es el cociente entre el valor predicho y el de referencia de la PLC.

Definido el factor que permite asegurar una predicción conservativa, se evaluó el margen de potencia perdido al realizar la predicción por el método propuesto.

3.2. Estimación de CHF

En esta sección se presenta el modelo de multifidelidad informado por física para estimar CHF. Se explica el pipeline de datos, la arquitectura del modelo y la metodología para su evaluación.

Se desarrollaron múltiples códigos Python destinados a tareas auxiliares del proceso de cálculo, entre ellos `chf.py`, `ahmad_scaling.py`, `softmin.py`, `import_cobra.py`.

3.2.1. Pipeline de datos

Los datos disponibles para estimación de CHF se dividen en tres fuentes:

- Datos de ensayo en tubo, utilizados por Groeneveld para sus LUT (versión 2006). 24 579 observaciones.
- Datos de ensayos de la Universidad de Columbia, sobre el bundle de la CNA-UII. 146 observaciones.
- Datos de simulaciones de COBRA3-CP, que modelan la geometría y condiciones de los ensayos de la Universidad de Columbia. 1 322 760 observaciones, de 146 ensayos $\times$ 151 nodos axiales $\times$ 60 subcanales.

Estas fuentes tienen distintas características. Ambas fuentes experimentales tienen una disponibilidad similar, aunque los ensayos de bundle conllevan una mayor complejidad geométrica, propia del bundle, que podría ser tenida en cuenta por el modelo. Es posible realizar data augmentation de los datos experimentales por medio de modelos y relaciones termodinámicas. Por otro lado, las simulaciones permiten obtener datos muy detallados, tanto espacialmente como en variables termodinámicas informadas. En este trabajo se consideraron a los datos de las simulaciones como un dato de alta fidelidad. En rigor, las simulaciones de COBRA3-CP están sujetas a error. Se han observado en la práctica diferencias respecto de ensayos, en particular en cuanto al mezclado entre subcanales y el efecto del separador. Puesto que el trabajo busca proponer y validar una metodología, la hipótesis de COBRA3-CP como fuente de verdad resulta válida. En caso de ser usada como metodología de predicción de CHF en la práctica, los cambios en modelos termohidráulicos de COBRA3-CP deben acompañarse del reentrenamiento del modelo de predicción de CHF.

A su vez, se deben definir con cautela las features que ingresan al modelo para predecir CHF. Si se considera que no hay pérdidas de calor, la evolución de la entalpía del fluido en función de la coordenada z se expresa mediante la ecuación 3.2.

$$h(z) = h_{\text{inlet}} + \frac{\pi D}{\dot{m}} \int_0^z q'' dz'. \quad (3.2)$$

Por otro lado, el título termodinámico de equilibrio se relaciona con la entalpía según la ecuación 3.3.

$$x(z) = \frac{h(z) - h_f}{h_{fg}}. \quad (3.3)$$

Si $q'' = \text{cte}$, como lo es tanto en los ensayos de un tubo y del bundle de la CNA-UII, al reemplazar la ecuación 3.2 en la 3.3 se obtiene la ecuación 3.4,

$$x(z) = x_{\text{inlet}} + \frac{\pi D q'' z}{\dot{m} h_{fg}}, \quad (3.4)$$

por lo que el modelo, dado $x(z = 1) = x_{\text{outlet}}$, puede despejar q'' . Esto tiene dos implicancias: en primer lugar el modelo asume un perfil de flujo de calor constante; y en segundo lugar, considera que las variables de entrada corresponden a un estado de CHF. Ninguna de estas dos implicancias es deseable, ya que el modelo no podrá generalizar a los casos de interés, es decir, cuando no se conoce el valor del CHF ni se tiene un perfil de potencia uniforme.

En la bibliografía clásica de CHF existen dos enfoques: el método de sustitución directa (DSM, del inglés *Direct Substitution Method*) y el método de balance de calor (HBM, del inglés *Heat Balance Method*). El DSM tiene como principal hipótesis que el CHF es un fenómeno local, por lo que utiliza directamente variables locales para predecir CHF. Esta hipótesis se ha considerado relativamente válida en caso de DNB, como lo sugieren [37, 7, 38]. Por otro lado, el HBM, como lo indica su nombre, realiza el balance de calor a partir de las condiciones de entrada al tubo. Groeneveld et al. evaluaron sus tres versiones de las LUT (1986 [39], 1995 [8] y 2006 [9]) mediante ambos métodos, y obtuvieron predicciones más precisas mediante el HBM. Sin embargo, el DSM es el más utilizado en la práctica, y el más adecuado para su aplicación en códigos termohidráulicos, como señala Siman-Tov [40]. Esto se debe, por un lado, a su simplicidad y, por otro, a que los ensayos realizados en geometrías reales (de bundle) informan las condiciones promedio, mientras que el CHF ocurre a nivel de subcanal. Las condiciones locales a nivel de subcanal pueden ser estimadas por medio de códigos de subcanal como COBRA3-CP, pero esto agregaría un error de la herramienta de cálculo que sería deseable evitar. Adicionalmente, el DSM es el método utilizado en la estimación de CHF para el bundle de la CNA-UII, por medio de las LUT 1995 y los TMF de INVAP.

Adicionalmente, se debe considerar un detalle importante de los ensayos realizados en la Universidad de Columbia. La mayoría de estos ensayos fueron realizados en agua liviana (H_2O), pero una serie de ellos fue realizada en agua pesada (D_2O), el fluido de trabajo de la CNA-UII. Esto impone la necesidad de traducir los ensayos a un único fluido. Debido a que tradicionalmente los ensayos se han hecho con agua liviana en vistas de reactores PWR (del inglés, *Pressurized Water Reactors*), y que los ensayos en un tubo se realizaron con agua liviana, la práctica habitual es escalar el ensayo de agua pesada a agua liviana. Luego, la predicción de CHF para agua liviana se debe escalar a agua pesada, para poder predecir las condiciones dentro del reactor. En este trabajo se adoptó el mismo criterio. El escaleo de propiedades entre fluidos es dependiente del fenómeno estudiado, en particular, para CHF se utiliza la regla de escaleo de Ahmad [41]. Esta regla de escaleo propone cuatro números adimensionales a conservar entre el fluido “prototipo” y el fluido “modelo”, como se muestra en la ecuación 3.5.

$$\begin{cases} (\Psi_{\text{CHF}})_{\text{prototipo}} = (\Psi_{\text{CHF}})_{\text{modelo}} , \\ (\Delta H/\lambda)_{\text{prototipo}} = (\Delta H/\lambda)_{\text{modelo}} , \\ (\rho_L/\rho_V)_{\text{prototipo}} = (\rho_L/\rho_V)_{\text{modelo}} , \\ (L/D)_{\text{prototipo}} = (L/D)_{\text{modelo}} . \end{cases} \quad (3.5)$$

ΔH es el subenfriamiento a la entrada, λ es el calor latente de vaporización, ρ_L y ρ_V son las densidades de la fase líquida y vapor respectivamente, L es el largo de la sección de ensayo, D es el diámetro de la sección de ensayo, y Ψ_{CHF} es el número adimensional propuesto específicamente para CHF por Ahmad, expresado en la ecuación 3.6,

$$\Psi_{CHF} = \left[\left(\frac{G D}{\mu_L} \right) \cdot \left(\frac{\mu_L^2}{\sigma D \rho_L} \right)^{2/3} \cdot \left(\frac{\mu_V}{\mu_L} \right)^{1/5} \right], \quad (3.6)$$

donde G es el flujo másico por unidad de área, μ_L y μ_V son las viscosidades dinámicas de la fase líquido y vapor respectivamente, y σ es la tensión superficial. Esta regla de escaleo se encuentra implementada en un código de Python, por medio de la función `scaling_ahmad()`. Se resuelve el sistema implícito planteado por medio de la herramienta `scipy.optimize.fsolve`.

Al aplicar una arquitectura de red neuronal de multifidelidad, el pipeline se divide en dos: el pipeline para entrenar la DNN de baja fidelidad a partir de los datos de ensayos en tubo; y el pipeline para entrenar la PINN de alta fidelidad con los datos de los ensayos de la Universidad de Columbia y las simulaciones en COBRA3-CP de ellos.

Como se mencionó en la sección 2.2, los datos de ensayos en tubo proveen los siguientes labels: diámetro, longitud, presión a la salida, flujo másico, título termodinámico a la salida, entalpía a la entrada, flujo de calor y temperatura de entrada. De estos, se utilizaron la presión a la salida p , el flujo másico G , el título termodinámico a la salida x y el cociente entre la longitud y el diámetro L/D .

Para el pipeline de alta fidelidad, de las simulaciones de COBRA se extrajo, en cada nodo axial, para cada subcanal y en promedio en el bundle, diferencia de presión respecto de la salida (en [bar]), entalpía (en [kJ/kg]), temperatura (en [C]), título termodinámico, fracción de vapor, caudal másico (en [kg/s]) y flujo másico (en [kg/m²s]). Luego se realizó un aumento de la información en cada uno de los nodos. Se agregó la siguiente información:

- Presión en el nodo, ya que se debe evaluar en condiciones locales.
- Distancia axial al último separador adimensionalizada (z_{sep_adim}), para que la red pueda tener en cuenta el efecto del separador.
- Desbalance entre título local y título promedio del bundle ($x_{disbalance}$), para que la red pueda contemplar que un subcanal con alto título rodeado de subcanales fríos retrasa el DNB gracias a la transferencia lateral de masa.
- Factor de pico máximo del subcanal (f_{pico}), ya que no todos los subcanales están expuestos a la misma potencia.
- Relación entre perímetro calefaccionado y mojado del subcanal (p_{heat_wet}), para distinguir entre distintos tipos geométricos de subcanal.
- Derivadas respecto de la posición axial de la presión, la entalpía, la temperatura, el título termodinámico y el flujo másico, que se utilizan para la formulación de pérdida informada por física en la PINN.

A continuación se describe la metodología para obtener cada una de estas variables. La presión en cada nodo resultó de sumar la diferencia registrada en ese

punto al valor a la salida. La distancia al último separador se obtuvo al adimensionalizar la posición axial del nodo con la longitud total y buscar el separador más próximo aguas arriba, a partir de las ubicaciones relevadas en la sección de ensayo [28]. El desbalance de título surgió de restar, al valor local del nodo, el promedio del bundle a la misma altura. Los factores de pico provienen también de [28]: a cada subcanal se le asignó el máximo al que está expuesto, es decir, el de la corona de barras más exterior con la que limita. Por último, la relación entre perímetro calefaccionado y mojado se extrajo de las entradas de COBRA3-CP, que la definen por tipo de subcanal, y se replicó en todos los nodos correspondientes.

Las derivadas de las variables mencionadas respecto de la coordenada axial se calcularon por medio de la función `numpy.gradient`, que calcula de forma numérica el gradiente de un dado `numpy.array` respecto de otro, evaluado en los valores de este último.

El vector final de features de la `HFPINN` contiene las mismas features que la `LFDNN`, y además, la predicción de la `LFDNN`, `z_sep_adim`, `x_disbalance`, `f_pico` y `p_heat_wet`.

Ya que la red de multifidelidad realiza predicción tanto con la red de baja fidelidad como con la de alta fidelidad a partir de las mismas entradas, las redes deben entrenarse a partir de datos escalados de la misma manera. En la figura 3.5 se comparan los gráficos de densidad de probabilidad correspondientes a los datos de ensayos de un tubo y a los puntos obtenidos mediante simulaciones con COBRA3-CP. La comparación se realiza para las cuatro variables de mayor interés: flujo másico, presión, temperatura y título termodinámico. Se observa que los puntos de las simulaciones de COBRA3-CP tienen un mayor bias hacia flujos másicos elevados. Los valores de presión se encuentran concentrados alrededor de las 5 presiones de ensayo distintivas. La temperatura, por su parte, se concentra en valores elevados. Por último, el título termodinámico tiene una distribución más concentrada en valores menores a 0. Esto es esperable al considerar todos los puntos de la sección ensayada, a la que ingresa líquido subenfriado. Los casos de ensayos de un tubo presentan distribuciones casi uniformes en presión y temperatura.

Entonces, se combinaron los tensores de datos de entrenamiento de los datos de un tubo y de las simulaciones de COBRA3-CP para conformar el `StandardScaler`. Las features adicionales que utiliza la red de alta fidelidad se escalan independientemente, por medio de un `StandardScaler`. Para el valor del CHF también se pueden tener diferencias importantes, pero se realiza un escaleo independiente de las distribuciones, mediante la aplicación del logaritmo natural.

Para la aplicación final del modelo, se debe agregar un factor de corrección por perfil de potencia no uniforme. Este factor toma distintas formas en la bibliografía, como el propuesto por Groeneveld [39] o por Tong [7]. Para mantener consistencia respecto de la metodología actual, se utilizó el de Groeneveld, que se computa según la ecuación 3.7,

$$K_5 = \begin{cases} \frac{\bar{q}}{q_{\text{local}}} & x > 0 \\ 1 & x < 0 \end{cases}. \quad (3.7)$$

Es evidente que, en el caso de flujo uniforme, $K_5 = 1 \forall x$.




FIGURA 3.5. Comparativa de distribuciones de datos de flujo másico, presión, temperatura y título termodinámico entre ensayos de un tubo de Groeneveld y todos los puntos de los ensayos numéricos con COBRA3-CP.

3.2.2. Arquitectura del modelo

Como se explicó en la sección 2.1, el modelo planteado es una red de multifidelidad informada por física; se la denota $MFPINN$. La $MFPINN$ está compuesta por dos redes, una de baja fidelidad y otra de alta fidelidad. La de baja fidelidad es entrenada para predecir CHF en geometría de tubo, a partir de los datos crudos de las LUT de Groeneveld, y se la denota $LFDNN$. Esta no incorpora información física, ya que se cuenta con una gran cantidad de datos, y un enfoque puro sobre ellos resulta suficiente. Su entrenamiento se realiza de forma previa, y sus pesos quedan congelados. Por otro lado, la componente de alta fidelidad sí utiliza información física, y se la denota $HFPINN$. Los datos para su entrenamiento son las simulaciones con COBRA3-CP de los ensayos experimentales de la Universidad de Columbia. En la figura 3.6 se presenta un esquema de la arquitectura de $MFPINN$ explicada.

La $HFPINN$ entrena con los datos de las simulaciones con COBRA3-CP; cada una de ellas provee datos en 151 nodos axiales y 60 subcanales, para un total de 9 060 datos por ensayo. Por otro lado, la información provista por los ensayos de Columbia contiene 1 dato por ensayo, correspondiente al punto desconocido en el que comienza el DNB. Se tiene entonces un desajuste de dimensionalidad entre el producto de la red al evaluar en los ensayos numéricos y lo medido en los ensayos reales, expuesto en la ecuación 3.8.

$$\underbrace{\mathbf{y} \in \mathbb{R}^{9060}}_{\text{campo predicho}} \longrightarrow \underbrace{\hat{\mathbf{y}} \in \mathbb{R}}_{\text{campo medido}}. \quad (3.8)$$




FIGURA 3.6. Esquema de la arquitectura de red neuronal de multifidelidad informada por física.

La flecha en la ecuación 3.8 es la reducción de dimensionalidad que se debe hacer antes de poder comparar contra los datos experimentales. La elección natural es el mínimo, ya que el DNB ocurre en el nodo más limitante del bundle. Pero, en cuanto a la optimización numérica, la utilización del mínimo es poco eficiente, e incluso puede hacer imposible el entrenamiento de un modelo de red neuronal, ya que el mínimo genera un gradiente one-hot, como se expone en la ecuación 3.9.

$$\frac{\partial}{\partial y_j} \min_i y_i = \begin{cases} 1 & \text{si } j = \arg \min_i y_i \\ 0 & \text{en caso contrario} \end{cases} . \quad (3.9)$$

De esta forma el optimizador sólo recibe información del punto mínimo. Adicionalmente, al comenzar el entrenamiento, el punto que resulta mínimo es completamente aleatorio, por lo que es muy fácil condicionar negativamente la red y que esta no pueda salir del mínimo inicial.

Se planteó entonces utilizar un enfoque de mínimo suave o softmin, que permita utilizar una mayor cantidad de nodos para el aprendizaje. Un problema similar que utiliza este enfoque es el promedio ponderado o attention pooling propuesto por Ilse [42] en el contexto de MIL (del inglés, *Multiple Instance Learning*). Se propuso utilizar el softmin expuesto en la ecuación 3.10,

$$\text{softmin}_\tau(\mathbf{y}) = \sum_i w_i y_i, \quad (3.10)$$

donde w_i son los pesos para ponderar las distintas predicciones. En el trabajo de Ilse los pesos se aprenden con una red de atención aparte, pero en este trabajo se utiliza el propio campo predicho, a través de la función softmax de Bridle [43] y el parámetro de temperatura propuesto por Hinton, Vinyals y Dean [44], según la ecuación 3.11.

$$w_i = \text{softmax} \left(-\frac{\mathbf{y}}{\tau} \right)_i . \quad (3.11)$$

De esta forma, los nodos con baja predicción se ponderan con un mayor peso que los nodos con predicciones altas. El sesgo de esta concentración es controlado por el parámetro de temperatura τ , que se obtiene a partir del desvío estándar del vector de predicción, según la ecuación 3.12.

$$\tau = \alpha \cdot \text{std}(\mathbf{y}). \quad (3.12)$$

El parámetro α permite controlar la temperatura con la evolución del entrenamiento, y se lo controla por medio de un recocido o annealing, que lo recorre geométricamente desde α_0 hasta α_f .

Para evaluar si la temperatura τ a la que converge el entrenamiento es o no correcta, se debe analizar sobre cuántos nodos se promedia realmente. Para ello, se computa el número efectivo de nodos, que se define como la exponencial de la entropía de los pesos, presentada en la ecuación 3.13.

$$N_{\text{eff}} = \exp \left[- \sum_i w_i \log(w_i) \right]. \quad (3.13)$$

Esta definición es el número de Hill de orden 1 [45], la forma estándar de obtener un conteo efectivo a partir de una entropía. Si el entrenamiento es satisfactorio, N_{eff} debe ser menor a 5 hacia el final del entrenamiento.

Esta metodología, además de solucionar el problema del gradiente one-hot, tiene la ventaja de, al ser una combinación convexa de los y_i , estar acotada superiormente por la media de la predicción. Esto asegura que el valor predicho sea un valor físicamente válido y sin sesgo dependiente de la cantidad de nodos utilizados.

En cuanto a la información física que se le brinda a la HFPI_{INN} , se debe notar que no es posible hacer un planteo tradicional de PINN que provea una ecuación diferencial de conservación de alguna cantidad como función de pérdida. Esto es así puesto que la variable a predecir, el CHF, no responde a una ecuación de conservación, sino que es una propiedad del estado termodinámico y la geometría. Se podría realizar el ejercicio de proveer a la red de, por ejemplo, la ecuación de conservación de la energía. Esto haría que la red aprenda que siempre que reciba un set de datos locales, estos corresponden a una condición de CHF, ya que la red fue entrenada con casos en que se tiene DNB. Pero en el campo de aplicación del modelo, se busca estimar el CHF sin estar en DNB.

Se plantearon entonces distintos tipos de ecuaciones diferenciales a satisfacer por el modelo. Se implementaron las siguientes relaciones:

- Monotónicas, presentadas en la ecuación 3.14,

$$\frac{d \text{CHF}}{di} \leq 0. \quad (3.14)$$

- De derivada cruzada, presentadas en la ecuación 3.15,

$$\frac{d^2 \text{CHF}}{di dj} \leq 0. \quad (3.15)$$

- De convexidad, presentadas en la ecuación 3.16,

$$\frac{d^2 \text{CHF}}{di^2} > 0. \quad (3.16)$$

- De coincidencia entre la predicción del modelo y la simulación de COBRA3-CP.

Las relaciones monotónicas del CHF con las variables de entrada implementadas son positiva con el flujo másico, negativa con el título termodinámico y negativa con la presión. Estas relaciones tienen fundamento físico y aseguran que las salidas de la red en condiciones de extrapolación mantengan sentido físico. Es importante señalar que esta última es válida para el rango de aplicación de reactores PWR o PHWR, es decir, por encima de 100 bar.

Se implementó una relación negativa con la derivada cruzada respecto del flujo másico y el título termodinámico, fundamentada en que a mayor flujo másico, la caída del CHF con el título termodinámico es más pronunciada. Esto es consistente con las estimaciones de las LUT de Groeneveld.

En cuanto a la relación de convexidad, se planteó una derivada segunda positiva del CHF respecto del título termodinámico para la zona de alto título ($x > 0, 2$). Si bien de la figura 3.5 puede afirmarse que se tienen pocos datos que se encuentran en esa región, esta restricción es útil en puntos de colocación para asegurar que

el modelo no obtenga resultados indeseados al extrapolar fuera de los datos de entrenamiento.

Por último, se realiza la comparación de la derivada axial del valor predicho de CHF calculada por dos métodos. En primer lugar se computa la derivada observada según la ecuación 3.17.

$$\left. \frac{dCHF}{dz} \right|_{\text{obs}} = \frac{CHF_{z_{i+1}} - CHF_{z_i}}{z_{i+1} - z_i}. \quad (3.17)$$

Luego, la derivada por regla de la cadena se computa según la ecuación 3.18,

$$\left. \frac{dCHF}{dz} \right|_{\text{cadena}} = \sum_{j \in \text{feats}} \frac{\partial CHF}{\partial j} \frac{dj}{dz}, \quad (3.18)$$

donde las derivadas de las variables respecto de la coordenada axial dj/dz fueron computadas previamente a partir de los resultados de las simulaciones con COBRA3-CP. De esta manera se penaliza que la red invente dependencias axiales que no provengan de las condiciones locales, y, de alguna forma, es una expresión de la hipótesis de condiciones locales como PDE.

La evaluación de este conjunto de ecuaciones diferenciales se realizó sobre un set de datos aparte, tradicionalmente llamado puntos de colocación. Se formó un espacio de puntos de colocación con los límites inferiores y superiores de cada variable, y se expandió cada uno en un 10% de la media de la variable. De esta forma el espacio permitió evaluar la extrapolación del modelo por fuera de los datos rotulados. Se estableció el doble de puntos de colocación que de observaciones de simulaciones de COBRA3-CP, lo que resultó en un total de 2 645 520 puntos.

La pérdida total entonces se compone de las componentes de la ecuación 3.19,

$$\mathcal{L} = \mathcal{L}_{\text{data}} + \lambda_{\text{mon}} \sum_i \mathcal{L}_{\text{mon},i} + \lambda_{\text{cruz}} \mathcal{L}_{\text{cruz}} + \lambda_{\text{convex}} \mathcal{L}_{\text{convex}} + \lambda_{\text{coinc}} \mathcal{L}_{\text{coinc}}, \quad (3.19)$$

donde los λ son los factores de peso de las PDE. Estos factores de peso se optimizaron para obtener resultados que respeten las relaciones postuladas por fuera del rango de operación de los ensayos experimentales.

Para el entrenamiento del modelo, en primer lugar se entrena la LFDNN con sus datos. Su entrenamiento es estándar y puede realizarse con optimizador Adam y métrica MSE. Luego, con los pesos de la LFDNN congelados, se entrena la HFPIINN con la estructura completa de la MFPIINN. Para ello se realizaron pruebas para determinar si era necesario, debido a las restricciones tipo PINN, un optimizador de segundo orden como L-BFGS [46]. Sus resultados se exponen en el capítulo 4.

Al igual que para el predictor de PLC, se realizó la optimización de los hiperparámetros de la arquitectura por medio de Optuna. Los resultados de la optimización junto al modelo final se presentan en el capítulo 4.

3.2.3. Evaluación del modelo

Para la evaluación del modelo se utilizaron las métricas estadísticas tradicionales en conjunto con métricas particulares al problema. Las métricas estadísticas

utilizadas son el MSE, RMSE, y el coeficiente de correlación R^2 .

En cuanto a la métricas específicas al problema, se utilizó el $\text{DNBR}_{\min}$ del diseño termohidráulico de la CNA-UII, explicado en detalle en [1, 47]. Este es el valor para el que, si la predicción de DNBR está por encima, se asegura con 95 % de probabilidad y confianza que no se tiene DNB. Se define según la ecuación 3.20,

$$\text{DNBR}_{\min} = \overline{\text{DNBR}} + k_{95} \cdot \sigma(\text{DNBR}), \quad (3.20)$$

donde DNBR son las predicciones en las condiciones de los ensayos de la Universidad de Columbia, y k_{95} es el intervalo de tolerancia de una distribución normal para asegurar 95 % de probabilidad y confianza según la cantidad de observaciones [48, 49].

Otro criterio utilizado para evaluar el modelo fue la evolución predicha de CHF en función de las distintas variables. Esto no se restringe únicamente a las variables de entrenamiento del modelo, sino que también es importante verificar la evolución predicha de CHF respecto de la longitud axial. Además, la predicción de la ubicación del punto más limitante de la sección de ensayo para una dada condición debe ubicarse sobre el final de esta. Esto permite afirmar que el modelo realiza una predicción con sentido físico.

Capítulo 4

Ensayos y resultados

4.1. Estimación de PLC

A continuación, se presentan los resultados para el modelo de estimación de PLC: la optimización de hiperparámetros, las predicciones de DNBR y fracción de vacío del mejor modelo, y la estimación de PLC por ambos criterios.

4.1.1. Optimización de hiperparámetros

Como se mencionó en la sección 3.1.2, la optimización de hiperparámetros se realizó por medio de la biblioteca Optuna. Las métricas objetivo se establecieron por separado para cada criterio. Para el DNBR se utilizó el error porcentual medio, mientras que para la fracción de vacío se usó el error absoluto medio escalado 100 veces. Esta decisión se tomó al considerar que la fracción de vacío tiene valor exactamente 0 para un porcentaje importante de los datos, y con el objetivo de lograr una contribución equitativa de ambos criterios al rendimiento del modelo. De esta forma, se obtiene un único modelo con error similar en ambos criterios, y se evita entrenar un modelo por criterio.

La figura 4.1 muestra los resultados durante el proceso de optimización, mientras que la arquitectura final se resume en la tabla 4.1.




FIGURA 4.1. Resultados de los distintos intentos de la optimización.

TABLA 4.1. Hiperparámetros de la arquitectura final.

Hiperparámetro	Valor
Cantidad de capas ocultas	3
Cantidad de neuronas por capa	478
Learning rate	$1,38 \cdot 10^{-4}$
Batch	64
Función de activación	ReLU

4.1.2. Resultados de DNBR y fracción de vacío

En esta sección, se evalúan los resultados del modelo en cuanto a la predicción de DNBR y fracción de vacío. En la figura 4.2 se presentan los gráficos de valores predichos contra reales, para los conjuntos de test y train. Se observa una buena predicción del modelo en ambos objetivos, y una distribución equivalente entre conjuntos. No obstante, se aprecia una tendencia a subestimar la fracción de vacío en la región cercana a 25 %.




FIGURA 4.2. Resultados de predicción de DNBR y fracción de vacío, para los conjuntos de test y train.

En la tabla 4.2 se presentan la media y desvío estándar del error con signo para cada objetivo. El error con signo se define como la diferencia entre el valor real y el predicho, por lo que valores positivos de la media implican una subpredicción del objetivo, y los negativos una sobrepredicción. Para la fracción de vacío, se aplica un factor de 10 para que las magnitudes entre objetivos sean comparables. Se observa una tendencia a subpredecir DNBR y a sobrepredicir la fracción de

vacío, ambas tendencias en igual magnitud en train y test. Los desvíos estándar son menores en test que en train para DNBR, y al revés para fracción de vacío. En ambos casos, los valores de desvío estándar son bajos.

La tendencia general de la predicción de vacío es de sobrepredecir, cuando al observar el gráfico de predicho contra real parece indicar lo contrario. Para analizar esta discrepancia, se realizó el mismo cálculo del error al dividir en 5 regiones el dominio de cada variable objetivo. Los resultados se presentan en la tabla 4.3. Se obtiene para DNBR, una media aún más baja en la región de interés (1,7 – 2,5) y una subpredicción general del DNBR, lo que representa una tendencia conservativa. En cuanto a la fracción de vacío, no se tiene el mínimo de error en la zona de interés, sino alrededor de ella. En la zona de interés (0,15 – 0,35) se tiene una sobrepredicción de la fracción de vacío, también una tendencia conservativa. Se puede concluir entonces que el modelo tiene un buen rendimiento en ambos objetivos y tendencias conservativas respecto de las referencias.

TABLA 4.2. Media y desvío estándar del error con signo para cada objetivo.

Conjunto	DNBR		Fracción de vacío	
	media	σ	media	σ
Train	-0,006	0,021	0,018	0,040
Test	-0,006	0,017	0,018	0,032

TABLA 4.3. Media y desvío estándar del error con signo para cada objetivo, segmentado por rangos de cada objetivo.

Objetivo	Rango	Conjunto			
		Train		Test	
		media	σ	media	σ
DNBR	< 1,7	0,003	0,004	0,000	0,008
	1,7 – 2,5	-0,001	0,009	-0,001	0,013
	2,5 – 3,5	-0,013	0,013	-0,015	0,019
	3,5 – 5	-0,044	0,038	-0,042	0,051
	> 5	-0,051	0,039	-0,015	0,076
Fracción de vacío	0	-0,035	0,033	0,061	0,037
	0 – 0,15	0,013	0,021	0,010	0,032
	0,15 – 0,35	0,024	0,036	0,025	0,044
	0,35 – 0,6	0,007	0,021	0,007	0,027
	> 0,6	0,031	0,022	0,024	0,014

Como se explicó en la sección 3.1.1, se filtraron los datos disponibles para entrenar en la región de interés en ambas variables objetivo. Se filtró para utilizar valores de MDNBR entre 1,7 y 2,5, o fracción de vacío entre 15 % y 35 %. Por ello, resulta de interés evaluar la precisión del modelo por fuera de la región de entrenamiento. En la figura 4.3 se presentan las predicciones comparadas con los valores reales, para MDNBR y fracción de vacío. En primer lugar, se evidencia la dificultad del modelo para predecir en las regiones excluidas del entrenamiento, algo esperable en una arquitectura DNN. Luego, para DNBR se observa una

tendencia correcta a valores inferiores a los de interés, pero una tendencia a subpredecir el DNBR al aumentar. Si bien esto podría interpretarse generalmente como un resultado desfavorable, se puede considerar que el modelo entrega predicciones conservativas fuera de su zona de entrenamiento, y brinda seguridad en su aplicación. Por último, para la fracción de vacío, por debajo de la zona de interés se observan predicciones menores a 0, lo que constituye un resultado no físico. Se podría realizar un *clipping* de la predicción para que valores negativos se conviertan en 0, y se tendría un buen rendimiento por debajo de la zona de entrenamiento. Por encima de la zona de entrenamiento, se puede observar en primer lugar una tendencia a subpredecir hasta 60 %, y luego una sobrepredicción.

Para cuantificar el aumento del error en el conjunto excluido, la figura 4.4 presenta los errores para cada variable objetivo en los conjuntos de train, test y excluidos. Tal como se comentó previamente, los conjuntos de train y test presentan errores muy similares, y el conjunto excluido un error considerablemente mayor. Adicionalmente se grafican los cuantiles del 5 % y 95 %, que evidencian que el conjunto de excluidos también tiene una dispersión mucho mayor en su error.




FIGURA 4.3. Resultados de predicción de DNBR y fracción de vacío, para el conjunto excluido.

Distribución del error por conjunto (bigotes: percentiles 5–95)




FIGURA 4.4. Distribución del error para cada objetivo, por conjunto de datos.

4.1.3. Estimación de PLC por DNBR y fracción de vacío

La evaluación del modelo realizada hasta aquí responde a su capacidad de estimar el mínimo DNBR y la fracción de vacío a la salida de un canal refrigerante, dadas sus condiciones termohidráulicas y distribuciones de potencia. Sin embargo, este no es el objetivo último del modelo, sino que se debe estimar la PLC por DNBR y fracción de vacío. Esto responde a un lazo de cálculo iterativo, explicado en detalle en la sección 3.1.3. A continuación, se analiza el comportamiento del modelo en dicho escenario, por medio del criterio del factor de ajuste F_{PLC} explicado en la sección 3.1.5.

Para esta evaluación, se utilizan 100 estados del reactor correspondientes a una estrategia de recambio de elementos combustibles de la CNA-UII, con un total de 43 811 simulaciones. Se realizó con COBRA3-CP el cálculo de las PLC con la metodología tradicional para obtener los valores de referencia y los tiempos requeridos en este tipo de cálculos.

En la figura 4.5 se presentan los resultados, segmentados por ZH, para la versión base de la DNN y con la corrección por F_{PLC} . En la tabla 4.4 se observan los valores de media y desvío estándar para el cociente entre el valor predicho y el real, y el F_{PLC} , factor de ajuste para asegurar con 95 % de probabilidad y confianza que la PLC predicha está por debajo de la real. Los tres valores se encuentran segmentados por ZH y para los criterios de DNBR y fracción de vacío.

Se observa un buen desempeño, especialmente para las ZZHH 4 y 5, donde la nube de puntos azul, correspondiente a la DNN sin corregir se encuentra muy cerca de la recta identidad. Para las ZZHH 1 a 3, el desempeño es inferior, aunque los resultados se encuentran dentro de parámetros aceptables. Este comportamiento resulta esperable, ya que en el conjunto de datos de entrenamiento la representación de las ZZHH era la equivalente a la cantidad de canales de cada una en el reactor, que es muy despareja. Esto también se evidencia en los valores de media y desvío estándar del cociente predicho-real. La media y el desvío estándar son decrecientes de ZH 1 a 5, con un valor casi unitario en la última. Los factores de ajuste muestran una mayor sobreestimación de las PLC en las ZZHH periféricas.

En la tabla 4.5 se presenta un resumen de los tiempos de cómputo para el cálculo de PLC. Los resultados son contundentes: la mejora o *speedup* del proceso de cálculo alcanza una media de entre 8409 y 9519 para DNBR, y de entre 2197 y 2486 para fracción de vacío. El tiempo total de cómputo pasó de las 380 h con COBRA3-CP a tan solo alrededor de 4 minutos con la DNN. Esto sustenta el valor de este modelo, que no solo logra una predicción de las PLC con un error acotado, sino que además requiere un tiempo de cómputo varios órdenes de magnitud inferior. Adicionalmente, no se implementaron lógicas adicionales para lograr un cómputo más eficiente por medio de la DNN, como el procesamiento en *batch*. Se computaron todos los casos en serie, tanto en CPU como en GPU. Aquí se tienen oportunidades de mejora, como se explica en el capítulo 5.

FALTA COMENTARIO DE MÁRGEN DE POTENCIA PERDIDO.




FIGURA 4.5. Resultados de estimación de PLC por DNBR y fracción de vacío con factor de corrección, por zona hidráulica.

TABLA 4.4. Media y desvío estándar de cociente predicho-real, y factor de 95 % de probabilidad y confianza. Por zona hidráulica.

Zona Hidráulica	DNBR			Fracción de vacío		
	media	σ	F	media	σ	F
1	1,047	0,015	0,933	1,008	0,004	0,985
2	1,025	0,010	0,961	1,003	0,002	0,993
3	1,018	0,010	0,967	1,002	0,002	0,995
4	1,003	0,003	0,991	1,001	0,002	0,996
5	1,001	0,002	0,995	1,001	0,001	0,997

TABLA 4.5. Tiempos de cómputo para cálculo de PLC.

		Tiempo				Mejora	
		COBRA3-CP [s]	DNN [ms]		CPU	GPU	
			CPU	GPU			
DNBR	mínimo	8,53	0,28	0,47	3562	406	
	media	25,16	2,66	3,03	9519	8409	
	máximo	137,95	5,88	5,51	57 882	48 363	
	total	306 h	117 s	130 s	9445	8503	
Fracción de vacío	mínimo	1,07	0,21	0,33	432	405	
	media	6,09	2,46	2,80	2486	2197	
	máximo	14,70	5,70	6,69	5955	5385	
	total	74 h	108 s	120 s	2479	2224	

TABLA 4.6. Márgen perdido medio y máximo por utilizar DNN, según zona hidráulica y total.

Zona Hidráulica	Márgen perdido [%]			
	DNBR		Fracción de vacío	
	medio	máximo	medio	máximo
1	1.56	4.56	2.58	5.22
2	1.35	4.29	1.05	2.28
3	1.88	5.37	0.74	1.87
4	0.58	2.12	0.41	1.25
5	0.38	1.37	0.24	0.89
total	0.71	2.34	0.54	1.45

4.1.4. Aplicación de embeddings

- Curva de R^2 con dimensión del espacio latente. Para perfil axial y perfil por barra.
- Aplicación a la arquitectura ganadora anterior. 3 casos.
- Comparación con caso anterior.




FIGURA 4.6. Gráficos de perfiles axiales con valores más altos, medianos y bajos de cada componente del espacio latente.




FIGURA 4.7. Gráficos de perfiles radiales con valores más altos, medianos y bajos de cada componente del espacio latente.

TABLA 4.7. Media y desvío estándar del error con signo para cada objetivo, para modelos con embeddings.

Modelo	Conjunto	DNBR		Fracción de vacío	
		media	σ	media	σ
Base	Train	-0,006	0,021	0,018	0,040
	Test	-0,006	0,017	0,018	0,032
Emb. perfil axial	Train	-0,002	0,018	-0,002	0,021
	Test	-0,001	0,020	-0,002	0,022
Emb. perfil por barras	Train	0,001	0,013	-0,006	0,021
	Test	0,001	0,014	-0,006	0,022
Emb. ambos perfiles	Train	0,000	0,017	-0,011	0,016
	Test	0,000	0,020	-0,010	0,017

TABLA 4.8. Margen perdido medio y máximo por utilizar DNN y embeddings, según zona hidráulica y total.

Modelo	Margen perdido [%]			
	DNBR		Fracción de vacío	
	medio	máximo	medio	máximo
Base	0.71	2.34	0.54	1.45
Emb. perfil axial	0,84	3,05	0,13	0,39
Emb. perfil por barras	0,61	1,83	0,15	0,38
Emb. ambos perfiles	0,99	3,96	0,10	0,40

4.2. Estimación de CHF

4.2.1. Optimización de hiperparámetros

4.2.2. Resultados de CHF

4.2.3. Comparativa de metodologías

Capítulo 5

Conclusiones

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

5.1. Conclusiones generales

La idea de esta sección es resaltar cuáles son los principales aportes del trabajo realizado y cómo se podría continuar. Debe ser especialmente breve y concisa. Es buena idea usar un listado para enumerar los logros obtenidos.

En esta sección no se deben incluir ni tablas ni gráficos.

Algunas preguntas que pueden servir para completar este capítulo:

- ¿Cuál es el grado de cumplimiento de los requerimientos?
- ¿Cuán fielmente se pudo seguir la planificación original (cronograma incluido)?
- ¿Se manifestó algunos de los riesgos identificados en la planificación? ¿Fue efectivo el plan de mitigación? ¿Se debió aplicar alguna otra acción no contemplada previamente?
- Si se debieron hacer modificaciones a lo planificado ¿Cuáles fueron las causas y los efectos?
- ¿Qué técnicas resultaron útiles para el desarrollo del proyecto y cuáles no tanto?

5.2. Próximos pasos

Acá se indica cómo se podría continuar el trabajo más adelante.

Apéndice A

Implementación Embeddings

Bibliografía

- [1] Nucleoeléctrica Argentina S.A. *Informe Final de Seguridad de la Central Nuclear Atucha II*. Confidencial. 2025.
- [2] S. Nukiyama. «The maximum and minimum values of the heat Q transmitted from metal to boiling water under atmospheric pressure». En: *International Journal of Heat and Mass Transfer* 9.12 (1966), págs. 1419-1433. ISSN: 0017-9310. DOI: [https://doi.org/10.1016/0017-9310\(66\)90138-4](https://doi.org/10.1016/0017-9310(66)90138-4). URL: <https://www.sciencedirect.com/science/article/pii/0017931066901384>.
- [3] N.E. Todreas J.W. Jackson e INVAP. COBRA3-CP. *An improved version of COBRA IIIC/MIT-2: a digital computer program for steady state and transient thermal-hydraulic analysis of rod bundle nuclear fuel elements*. Confidencial. 1981.
- [4] X. Meng y G.E. Karniadakis. «A composite neural network that learns from multi-fidelity data: Application to function approximation and inverse PDE problems». En: *Journal of Computational Physics* 401 (2020), pág. 109020. ISSN: 0021-9991. DOI: <https://doi.org/10.1016/j.jcp.2019.109020>. URL: <https://www.sciencedirect.com/science/article/pii/S0021999119307260>.
- [5] M. Raissi, P. Perdikaris y G.E. Karniadakis. «Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations». En: *Journal of Computational Physics* 378 (2019), págs. 686-707. ISSN: 0021-9991. DOI: <https://doi.org/10.1016/j.jcp.2018.10.045>. URL: <https://www.sciencedirect.com/science/article/pii/S0021999118307125>.
- [6] H. Ballesteros. *Descripción y Teoría del Programa AXENA*. Inf. téc. 22-12. Confidencial. Gerencia de Análisis de Seguridad y Diseño del Núcleo, Nucleoeléctrica Argentina S.A., 2012.
- [7] L. S. Tong e Y. S. Tang. *Boiling Heat Transfer and Two-Phase Flow*. 2nd. New York: Taylor & Francis, 1997. ISBN: 1560324855. URL: <https://www.taylorfrancis.com/books/mono/10.1201/9781315138510/boiling-heat-transfer-two-phase-flow-tong>.
- [8] D.C. Groeneveld et al. «The 1995 look-up table for critical heat flux in tubes». En: *Nuclear Engineering and Design* 163.1 (1996), págs. 1-23. ISSN: 0029-5493. DOI: [https://doi.org/10.1016/0029-5493\(95\)01154-4](https://doi.org/10.1016/0029-5493(95)01154-4). URL: <https://www.sciencedirect.com/science/article/pii/0029549395011544>.
- [9] D.C. Groeneveld et al. «The 2006 CHF look-up table». En: *Nuclear Engineering and Design* 237.15 (2007). NURETH-11, págs. 1909-1922. ISSN: 0029-5493. DOI: <https://doi.org/10.1016/j.nucengdes.2007.02.014>. URL: <https://www.sciencedirect.com/science/article/pii/S0029549307002002>.
- [10] INVAP. *Incorporation of the 1995 AECL Lookup Table for CHF to the COBRA3-CP code*. Inf. téc. CNA2-1152-3BEIN-004-A. Confidencial. 2008.
- [11] Xingang Zhao et al. «On the prediction of critical heat flux using a physics-informed machine learning-aided framework». En: *Applied Thermal Engineering* 164 (2020), pág. 114540. ISSN: 1359-4311. DOI: <https://doi.org/10.1016/j.applthermaleng.2020.114540>.

- 1016/j.applthermaleng.2019.114540. URL: <https://www.sciencedirect.com/science/article/pii/S1359431119332065>.
- [12] Xingang Zhao, Robert K. Salko y Koroush Shirvan. «Improved departure from nucleate boiling prediction in rod bundles using a physics-informed machine learning-aided framework». En: *Nuclear Engineering and Design* 374 (2021), pág. 111084. ISSN: 0029-5493. DOI: <https://doi.org/10.1016/j.nucengdes.2021.111084>. URL: <https://www.sciencedirect.com/science/article/pii/S0029549321000364>.
- [13] Yue Jin, Xingang Zhao y Koroush Shirvan. «Constructing A New CHF Look-Up Table Based on the Domain Knowledge Informed Machine Learning Methodology». En: Oak Ridge National Laboratory (ORNL), Oak Ridge, TN (United States). Mar. de 2022. URL: <https://www.osti.gov/biblio/1867773>.
- [14] Congshan Mao y Yue Jin. «Uncertainty quantification study of the physics-informed machine learning models for critical heat flux prediction». En: *Progress in Nuclear Energy* 170 (2024), pág. 105097. ISSN: 0149-1970. DOI: <https://doi.org/10.1016/j.pnucene.2024.105097>. URL: <https://www.sciencedirect.com/science/article/pii/S0149197024000477>.
- [15] Richard L. Burden, J. Douglas Faires y Annette M. Burden. *Numerical Analysis*. 10th. Boston, MA: Cengage Learning, 2015.
- [16] Ian Goodfellow, Yoshua Bengio y Aaron Courville. *Deep Learning*. <http://www.deeplearningbook.org>. MIT Press, 2016.
- [17] Adam Paszke et al. *PyTorch: An Imperative Style, High-Performance Deep Learning Library*. 2019. arXiv: [1912.01703](https://arxiv.org/abs/1912.01703) [cs.LG]. URL: <https://arxiv.org/abs/1912.01703>.
- [18] Adam Paszke et al. *PyTorch*. URL: <https://pytorch.org/>.
- [19] Ian H. Bell et al. «Pure and Pseudo-pure Fluid Thermophysical Property Evaluation and the Open-Source Thermophysical Property Library CoolProp». En: *Industrial & Engineering Chemistry Research* 53.6 (2014). DOI: [10.1021/ie4033999](https://doi.org/10.1021/ie4033999).
- [20] The pandas development team. *pandas-dev/pandas: Pandas*. Ver. latest. Feb. de 2020. DOI: [10.5281/zenodo.3509134](https://doi.org/10.5281/zenodo.3509134). URL: <https://doi.org/10.5281/zenodo.3509134>.
- [21] Wes McKinney. «Data Structures for Statistical Computing in Python». En: *Proceedings of the 9th Python in Science Conference*. Ed. por Stéfan van der Walt y Jarrod Millman. 2010, págs. 56 -61. DOI: [10.25080/Majora-92bf1922-00a](https://doi.org/10.25080/Majora-92bf1922-00a).
- [22] Fabian Pedregosa et al. «Scikit-learn: Machine Learning in Python». En: *Journal of Machine Learning Research* 12 (2011), págs. 2825-2830. URL: <http://arxiv.org/abs/1201.0490>.
- [23] Charles R. Harris et al. «Array programming with NumPy». En: *Nature* 585.7825 (sep. de 2020), págs. 357-362. DOI: [10.1038/s41586-020-2649-2](https://doi.org/10.1038/s41586-020-2649-2). URL: <https://doi.org/10.1038/s41586-020-2649-2>.
- [24] J. D. Hunter. «Matplotlib: A 2D graphics environment». En: *Computing in Science & Engineering* 9.3 (2007), págs. 90-95. DOI: [10.1109/MCSE.2007.55](https://doi.org/10.1109/MCSE.2007.55).
- [25] Michael L. Waskom. «seaborn: statistical data visualization». En: *Journal of Open Source Software* 6.60 (2021), pág. 3021. DOI: [10.21105/joss.03021](https://doi.org/10.21105/joss.03021). URL: <https://doi.org/10.21105/joss.03021>.
- [26] Takuya Akiba et al. «Optuna: A Next-generation Hyperparameter Optimization Framework». En: *KDD*. Ed. por Ankur Teredesai et al. ACM, 2019,

- págs. 2623-2631. ISBN: 978-1-4503-6201-6. URL: <http://dblp.uni-trier.de/db/conf/kdd/kdd2019.html#AkibaSYOK19>.
- [27] D. C. Groeneveld. *Critical Heat Flux Data Used to Generate the 2006 Groeneveld Critical Heat Flux Lookup Tables*. NUREG/KM 0011. Washington, DC: U.S. Nuclear Regulatory Commission, 2019. URL: <https://www.nrc.gov/reading-rm/doc-collections/nuregs/knowledge/km0011/index>.
- [28] L. Lencina y H. Ballesteros. *Recopilación datos experimentales obtenidos de los ensayos termohidráulicos realizados en el Elemento Combustible Atucha II en los Circuitos Experimentales de la CNEA (CEBP y CEAP) y en la Universidad de Columbia*. Inf. téc. 11-08. Confidencial. Gerencia de Análisis de Seguridad y Diseño del Núcleo, Nucleoeléctrica Argentina S.A., 2008.
- [29] Diederik P. Kingma y Jimmy Ba. «Adam: A Method for Stochastic Optimization». En: *International Conference on Learning Representations (ICLR)*. 2015.
- [30] Vinod Nair y Geoffrey E. Hinton. «Rectified Linear Units Improve Restricted Boltzmann Machines». En: *Proceedings of the 27th International Conference on Machine Learning (ICML-10)*. 2010, págs. 807-814.
- [31] Dan Hendrycks y Kevin Gimpel. «Gaussian Error Linear Units (GELUs)». En: *arXiv preprint arXiv:1606.08415* (2016).
- [32] Stefan Elfving, Eiji Uchibe y Kenji Doya. «Sigmoid-Weighted Linear Units for Neural Network Function Approximation in Reinforcement Learning». En: *Neural Networks* 107 (2018), págs. 3-11.
- [33] Andrew L. Maas, Awni Y. Hannun y Andrew Y. Ng. «Rectifier Nonlinearities Improve Neural Network Acoustic Models». En: *Proceedings of the 30th International Conference on Machine Learning (ICML)*. Vol. 30. 1. 2013.
- [34] Djork-Arné Clevert, Thomas Unterthiner y Sepp Hochreiter. «Fast and Accurate Deep Network Learning by Exponential Linear Units (ELUs)». En: *arXiv preprint arXiv:1511.07289* (2015).
- [35] INVAP. *Flow Rate Versus Power in the Hot Coolant Channel for Each Hydraulic Zone*. Inf. téc. CNA2-1152-3BEIN-010-B. Confidencial. 2008.
- [36] Harold Hotelling. «Analysis of a complex of statistical variables into principal components». En: *Journal of Educational Psychology* 24.6 (1933), 417-441. DOI: [10.1037/h0071325](https://doi.org/10.1037/h0071325).
- [37] J Weisman y B S Pei. «Prediction of critical heat flux in flow boiling at low qualities». en. En: (1983). DOI: [https://doi.org/10.1016/S0017-9310\(83\)80047-7](https://doi.org/10.1016/S0017-9310(83)80047-7). URL: <https://www.sciencedirect.com/science/article/pii/S0017931083800477>.
- [38] Jean-Marie Le Corre, Shi-Chune Yao y Cristina H. Amon. «A mechanistic model of critical heat flux under subcooled flow boiling conditions for application to one- and three-dimensional computer codes». en. En: *Nuclear Engineering and Design* 240.2 (feb. de 2010), págs. 235-244. ISSN: 00295493. DOI: [10.1016/j.nucengdes.2008.12.007](https://doi.org/10.1016/j.nucengdes.2008.12.007). URL: <https://linkinghub.elsevier.com/retrieve/pii/S0029549308006225> (visitado 22-07-2026).
- [39] D. C. Groeneveld, S. C. Cheng y T. Doan. «1986 AECL-UO Critical Heat Flux Lookup Table». En: *Heat Transfer Engineering* 7.1-2 (1986), págs. 46-62. URL: <https://doi.org/10.1080/01457638608939644>.
- [40] Moshe Siman-Tov. «Application of energy balance and direct substitution methods for thermal margins and data evaluation». en. En: *Nuclear Engineering and Design* 163.1-2 (jun. de 1996), págs. 249-258. ISSN: 00295493. DOI: [10.1016/0029-5493\(95\)01174-9](https://doi.org/10.1016/0029-5493(95)01174-9). URL: <https://linkinghub.elsevier.com/retrieve/pii/S0029549395011749> (visitado 21-07-2026).

- [41] S.Y. Ahmad. «Fluid to fluid modeling of critical heat flux: A compensated distortion model». en. En: *International Journal of Heat and Mass Transfer* 16.3 (mar. de 1973), págs. 641-662. ISSN: 00179310. DOI: [10.1016/0017-9310\(73\)90229-9](https://doi.org/10.1016/0017-9310(73)90229-9). URL: <https://linkinghub.elsevier.com/retrieve/pii/S0017931073902299> (visitado 22-07-2026).
- [42] Maximilian Ilse, Jakub M. Tomczak y Max Welling. «Attention-based Deep Multiple Instance Learning». En: *Proceedings of the 35th International Conference on Machine Learning*. Vol. 80. PMLR. 2018, págs. 2127-2136.
- [43] John S. Bridle. «Probabilistic Interpretation of Feedforward Classification Network Outputs, with Relationships to Statistical Pattern Recognition». En: *Neurocomputing: Algorithms, Architectures and Applications*. Vol. F68. NATO ASI Series. Berlin, Heidelberg: Springer, 1990, págs. 227-236. DOI: [10.1007/978-3-642-76153-9_28](https://doi.org/10.1007/978-3-642-76153-9_28).
- [44] Geoffrey Hinton, Oriol Vinyals y Jeff Dean. *Distilling the Knowledge in a Neural Network*. NIPS 2014 Deep Learning Workshop. 2015. arXiv: [1503.02531](https://arxiv.org/abs/1503.02531).
- [45] M. O. Hill. «Diversity and Evenness: A Unifying Notation and Its Consequences». En: *Ecology* 54.2 (1973), págs. 427-432. DOI: [10.2307/1934352](https://doi.org/10.2307/1934352).
- [46] Dong C. Liu y Jorge Nocedal. «On the limited memory BFGS method for large scale optimization». En: *Mathematical Programming* 45.1-3 (1989), págs. 503-528. DOI: [10.1007/BF01589116](https://doi.org/10.1007/BF01589116).
- [47] INVAP. *Proposed Thermal Design Procedure*. Inf. téc. CNA2-1152-3BEIN-005-B. Confidencial. 2008.
- [48] NIST/SEMATECH. 7.2.6.3. *Tolerance Intervals for a Normal Distribution*. <https://www.itl.nist.gov/div898/handbook/prc/section2/prc263.htm>. NIST/SEMATECH e-Handbook of Statistical Methods. 2012. (Visitado 17-08-2026).
- [49] Mary Gibbons Natrella. *Experimental Statistics*. Vol. 91. National Bureau of Standards Handbook. Washington, D.C.: U.S. Government Printing Office, 1963.