

Desarrollo de una herramienta predictiva de la potencia límite de canal de la Central Nuclear Atucha II entrenada con simulaciones de código de subcanales

Ing. Juan Ignacio Teich

Carrera de Especialización en Inteligencia Artificial

Director: Mg. Ing. Martín Sebastián Silva (Nucleoeléctrica Argentina S.A.)

Jurados:

Jurado 1 (pertenencia)

Jurado 2 (pertenencia)

Jurado 3 (pertenencia)

Ciudad de [lugar], [mes] de [año]

Resumen

Se desarrolló una metodología para estimar la Potencia Límite de Canal de la Central Nuclear Atucha II, basada en redes neuronales, con tiempos de cómputo órdenes de magnitud inferiores a los códigos termohidráulicos empleados en Nucleoeléctrica Argentina S.A. Esto permite disminuir considerablemente los tiempos y costos computacionales de los cálculos termohidráulicos para las estrategias de recambio de combustibles.

Adicionalmente, se propone una metodología novedosa para el cálculo del Flujo Crítico de Calor, que incorpora redes neuronales informadas por física y redes neuronales de multifidelidad, con fuentes de datos de fidelidad diversa, provenientes de ensayos experimentales con geometrías simples y con la geometría del *bundle* de la Central Nuclear Atucha II, y ensayos numéricos.

Para el desarrollo del trabajo se aplicaron conocimientos en redes neuronales, redes neuronales informadas por física, redes neuronales de multifidelidad, y su entrenamiento y optimización.

Agradecimientos

Esta sección es para agradecimientos personales y es totalmente **OPCIONAL**.

Índice general

Resumen	I
1. Introducción general	1
1.1. Introducción a termohidráulica nuclear	1
1.2. Contexto y motivación	4
1.3. Estado del arte	4
1.4. Objetivos	5
2. Introducción específica	7
2.1. Frameworks y bibliotecas	7
2.2. Datasets y datos de entrenamiento	10
3. Diseño e implementación	13
3.1. Estimación de PLC	13
3.1.1. Pipeline de datos	13
3.1.2. Arquitectura del modelo	14
3.1.3. Entrenamiento y optimización	15
3.1.4. Integración e implementación del sistema	15
3.2. Estimación de CHF	16
3.2.1. Pipeline de datos	16
3.2.2. Arquitectura del modelo	18
3.2.3. Entrenamiento y optimización	18
3.2.4. Integración e implementación del sistema	18
4. Ensayos y resultados	19
4.1. Pruebas funcionales del hardware	19
5. Conclusiones	21
5.1. Conclusiones generales	21
5.2. Próximos pasos	21
Bibliografía	23

Índice de figuras

1.1. Fotografía aérea de la Central Nuclear Atucha II ¹	1
1.2. Esquematización de los canales refrigerantes en el núcleo de la CNA-UII y las 5 zonas hidráulicas ²	2
1.3. Curva de Nukiyama ³	3
2.1. Esquema del loop de cálculo iterativo de la PLC por DNBR con COBRA3-CP.	8
2.2. Comparación de resultados preliminares de estimación de PLC y DNBR por DNN.	8
2.3. Histogramas de las variables de los ensayos de CHF en un tubo recopilados por Groeneveld.	11
2.4. Histogramas de las variables de los ensayos de CHF de la Universidad de Columbia.	11
3.1. Histogramas de fracción de vacío y MDNBR para las simulaciones con COBRA3-CP.	14
3.2. Resultados de los distintos intentos de la optimización.	15

Índice de tablas

1.1. Principales parámetros de diseño y condiciones de operación de la Central Nuclear Atucha II.	2
---	---

Dedicado a... [OPCIONAL]

Capítulo 1

Introducción general

En este capítulo se presentan los lineamientos básicos en cuanto al funcionamiento de la Central Nuclear Atucha II, su diseño termohidráulico y los métodos de cálculo de Potencia Límite de Canal y estimación de Flujo Crítico de Calor. Se plantea el contexto y la motivación de este trabajo, y el estado del arte de aplicaciones similares. Por último, se establecen los objetivos del trabajo.

1.1. Introducción a termohidráulica nuclear

La Central Nuclear Atucha II (CNA-UII) se ubica en la localidad de Lima, en la provincia de Buenos Aires, Argentina. Es una central nuclear de tipo PHWR (del inglés, *Pressurized Heavy Water Reactor*), que utiliza agua pesada (óxido de deuterio, D_2O) como moderador y refrigerante, y uranio natural como combustible. El reactor nuclear genera 2160 MW térmicos, de los cuales provee 745 MW eléctricos al Sistema Argentino de Interconexión (SADI). En la figura 1.1 se aprecia una foto aérea de la central.



FIGURA 1.1. Fotografía aérea de la Central Nuclear Atucha II¹.

En la tabla 1.1, obtenida del Informe Final de Seguridad (IFS) de la CNA-UII [1], se presentan los principales parámetros de diseño y condiciones de operación de la CNA-UII. El núcleo está compuesto por 451 canales refrigerantes que contienen los elementos combustibles (EECC). Los canales se encuentran agrupados en 5 zonas hidráulicas (ZZHH), cada una con un caudal másico característico. El caudal viene dado por un restrictor de caudal o *drossel* distintivo para las 4 zonas periféricas, y la zona central no tiene *drossel*. La diferenciación de caudal fue

¹Imagen tomada de <https://na-sa.com.ar/>.

realizada durante el diseño de la central, de forma de obtener el mismo salto entálpico en todos los canales. En la figura 1.2 se presenta una imagen esquemática de la distribución de los canales en el núcleo de la CNA-UII, y sus ZZHH.

TABLA 1.1. Principales parámetros de diseño y condiciones de operación de la Central Nuclear Atucha II.

Condiciones Generales de Operación	CNA-UII
Potencia térmica del reactor	2 160 MW _{th}
Caudal másico total	10 576 kg/s
Presión del Sistema Primario	115 bar
Temperatura de entrada del refrigerante	277,8 °C
Temperatura de salida del refrigerante	314,6 °C
Cantidad de zonas hidráulicas del núcleo	5
Cantidad de elementos combustibles en el núcleo	451
Cantidad de barras combustibles por elemento combustible	37




FIGURA 1.2. Esquematzación de los canales refrigerantes en el núcleo de la CNA-UII y las 5 zonas hidráulicas².

Para cumplir con los criterios de diseño y operación segura establecidos en el IFS, se deben cumplir dos principales criterios en cuanto a la potencia a la que pueden operar los combustibles dentro del núcleo, o Potencia Límite de Canal (PLC). Los criterios son: por límite de fracción de vacío (α) a la salida de los canales refrigerantes, y por Apartamiento de la Ebullición Nucleada (DNB, del inglés *Departure from Nucleate Boiling*).

En primer lugar, el límite por fracción de vacío establece la cantidad máxima de vapor que se puede tener a la salida de los canales refrigerantes, de forma de

²Imagen tomada del IFS de CNA-UII [1].

evitar vibraciones excesivas en los EECC. En particular, para la CNA-UII, el límite está establecido en 25 %.

En segundo lugar, si se tiene en cuenta que el criterio de seguridad primordial del diseño de una central es garantizar la contención de los productos de fisión, y que la vaina es la segunda defensa en profundidad para ello, asegurar la integridad de estas es primordial. Además, el DNB es el mecanismo principal para la degradación de las vainas por efectos térmicos. Por lo tanto, evitar el DNB es el criterio principal del diseño termohidráulico.

El DNB es un cambio en el patrón de flujo que se desarrolla dentro de los canales refrigerantes, donde se pasa de un régimen de ebullición nucleada (en inglés, *Nucleate Boiling*) a un régimen de ebullición en película (en inglés, *Film Boiling*). Este cambio de régimen se llama crisis de la ebullición, y genera un aumento súbito de la temperatura de la pared calefaccionada, como se observa en la curva de Nukiyama [2] en la figura 1.3. Se caracteriza con el Flujo Crítico de Calor (CHF, del inglés *Critical Heat Flux*), por lo que la estimación del CHF según las condiciones locales de operación es el paso fundamental en el cálculo del límite por DNB. Adicionalmente, se evalúa el margen al DNB (DNBR, del inglés *DNB Ratio*), que se define como el cociente entre el flujo de calor local y el CHF según las condiciones. El DNBR debe estar por encima de un valor fijo que considera la incerteza en la estimación del CHF, la sensibilidad de esta respecto de las condiciones de operación, y que garantiza que ante cualquier transitorio esperable (AOO, del inglés *Anticipated Operational Occurrences*) no se tiene DNB.




FIGURA 1.3. Curva de Nukiyama³.

³Imagen tomada de <https://www.sciencedirect.com/topics/engineering/pool-boiling-curve>.

1.2. Contexto y motivación

Uno de los cálculos más importantes en el diseño termohidráulico de un reactor PHWR es la estimación de las PLC. Este cálculo puede necesitar repetirse más de un millón de veces durante cada iteración del diseño de una estrategia de recambio de EECC, lo que implica un alto costo computacional. Por lo tanto, obtener una herramienta que permita computar de manera eficiente las PLC e identificar los casos más críticos a ser evaluados con los códigos termohidráulicos es de elevado interés. Dado que se cuenta con una amplia variedad de cálculos realizados por la División de Termohidráulica con el código COBRA3-CP [3], es factible plantear una herramienta basada en redes neuronales que permita estimar de manera preliminar las PLC con una alta eficiencia computacional. Debido a que los casos de interés para el diseño son los casos más limitantes, una herramienta que permita la selección de ellos de forma rápida y eficiente permitiría reducir los tiempos de cómputo en órdenes de magnitud.

Adicionalmente, en el cálculo con los códigos termohidráulicos, un paso fundamental es la estimación del CHF en función de las condiciones locales del fluido. Hoy en día, esto se realiza con métodos que se dividen en dos: fórmulas semi-empíricas que buscan capturar la alta dimensionalidad del problema, y tablas de CHF obtenidas de ensayos en geometrías simples que luego son modificadas por factores ad-hoc para replicar lo mejor posible los ensayos realizados sobre las geometrías reales del canal refrigerante del reactor. Se cuenta con datos de ensayos en geometrías sencillas, ensayos para el *bundle* de la CNA-UII realizados por la Universidad de Columbia, y la replicación de los ensayos de manera numérica con el código de subcanales COBRA3-CP. Este caso particular de disponibilidad de datos puede ser aprovechado por redes neuronales de tipo multifidelidad, como se plantea en el trabajo de Meng y Karniadakis [4]. Además, ya que se plantea un fenómeno físico, evaluar el impacto de introducir ecuaciones de conservación o relaciones monótonas es de interés, mediante un enfoque informado por física como se plantea en el trabajo fundacional de las redes neuronales informadas por física (PINN, del inglés *Physics Informed Neural Network*) de Raissi, Perdikaris y Karniadakis [5].

1.3. Estado del arte

En cuanto al cálculo de PLC, actualmente para la CNA-UII, son calculadas por medio del código de subcanales COBRA3-CP y el código de planta AXCNA2 [6]. Este cálculo es específico de cada central, y al ser confidencial, no se cuenta con información bibliográfica de aplicación de aprendizaje automático (ML, del inglés *Machine Learning*).

Por otro lado, para la estimación del CHF, los métodos clásicos se dividen en relaciones semi-empíricas y datos tabulados modificados por factores de ajuste para la geometría de interés. Como ejemplo de relación semi-empírica se tiene la correlación Westinghouse-3 (W-3) [7], utilizada en el diseño de la Central Nuclear Atucha I (CNA-UI), obtenida a partir de observación experimental del efecto individual de presión, caudal y título termodinámico sobre el CHF. Por otro lado, la referencia en cuanto a datos tabulados de CHF son las *Look-up Tables* de Groeneveld (1995 [8] y 2006 [9]), obtenidas a partir de más de 25 000 ensayos de CHF en un tubo calefaccionado. Para obtener CHF en una geometría real de un reactor, se

utilizan factores de corrección, como los *Taylor-made Factors* (TMF) para el bundle CNA-UII desarrollados por INVAP [10].

Métodos más modernos para la estimación de CHF utilizan ML para mejorar la predicción de las herramientas clásicas, especialmente para las Look-up Tables. Ejemplos de ello se encuentran en los trabajos de Zhao et al. [11], [12] y Jin et al. [13], donde se utiliza una PIMLAF (*Physics-Informed Machine Learning-Aided Framework*) para estimar la modificación a realizar a la predicción por Look-up Table para obtener CHF en una geometría compleja. Por otro lado, Mao y Jin [14] aplican PINN para estimar el CHF, pero con la guía física de los enfoques clásicos de estimación de CHF.

1.4. Objetivos

En función del problema descripto, se orientaron los objetivos específicos al desarrollo y evaluación de la viabilidad de modelos basados en redes neuronales para asistir en cálculos termohidráulicos de la CNA-UII. Se establecieron los siguientes objetivos específicos:

- Desarrollar una herramienta basada en DNN para predecir PLC, a partir de los datos de entrada utilizados en los cálculos termohidráulicos.
- Realizar un análisis de reducción de dimensionalidad de los perfiles de potencia axiales y por barra.
- Desarrollar una herramienta basada en MFPINN para predicción de CHF en función de condiciones locales, a partir de datos de multifidelidad.

Capítulo 2

Introducción específica

En este capítulo se explican los frameworks, arquitecturas y bibliotecas utilizadas en el trabajo, los conjuntos de datos para el entrenamiento y validación de los modelos, y por último, se describe la infraestructura de cómputo utilizada.

2.1. Frameworks y bibliotecas

En esta sección se establecen los frameworks y bibliotecas utilizados para resolver los dos problemas planteados en este trabajo: la estimación de PLC y la estimación del CHF.

En primer lugar, la estimación de las PLC se realiza con redes neuronales profundas (DNN, del inglés *Deep Neural Networks*). Esta metodología fue elegida principalmente debido a su elevada capacidad de representar funciones no lineales, característica fundamental para el cálculo de las PLC que presentan un alto grado de no-linealidad. Para su implementación se consideraron dos posibilidades: un modelo que calcule directamente PLC, y un modelo que reemplace el paso realizado por COBRA3-CP en el procedimiento de cálculo. En la figura 2.1 se esquematiza el procedimiento de cálculo con COBRA3-CP de la PLC por DNBR. El procedimiento para cálculo de PLC por vacío es similar, pero se aproxima al valor deseado de vacío por el método de la secante.

Se realizaron pruebas conceptuales de ambas metodologías, y se identificó una dificultad relevante para estimar la PLC de manera directa, que se ejemplifica en la figura 2.2a. Por lo tanto, se decidió implementar un modelo que reemplace a COBRA3-CP, y, a partir de las condiciones termohidráulicas del canal, estime el DNBR mínimo (MDNBR). Esta implementación demostró una capacidad predictiva superior, que se evidencia en la figura 2.2b. Se estima que un comportamiento similar se tendrá para la estimación de la PLC por vacío, por lo que se realiza la misma metodología. También se evalúa la aplicación de una DNN para obtener tanto el MDNBR como el vacío a la salida del canal con un único modelo.

Esta metodología adicionalmente permite una mayor adquisición de datos, dado que cada canal tiene una única PLC, pero se tienen infinitas posibilidades de MDNBR al variar su potencia. Recordando que las DNN pueden ser pensadas como "máquinas de aproximación de funciones, diseñadas para obtener generalización estadística"[15], cuanto mayor disponibilidad de datos, mejor el comportamiento final del modelo.

También, es de interés en este trabajo analizar la aplicación de reducción de dimensionalidad a partir de las features de los perfiles de potencia axiales y por






FIGURA 2.1. Esquema del loop de cálculo iterativo de la PLC por DNBR con COBRA3-CP.



(A) Resultados preliminares de estimación de PLC por DNN.



(B) Resultados preliminares de estimación de DNBR por DNN.

FIGURA 2.2. Comparación de resultados preliminares de estimación de PLC y DNBR por DNN.

barra. Para realizar esto, se utiliza una arquitectura *encoder-decoder*. Esta arquitectura consiste de dos DNN: la primera, el *encoder*, reduce la dimensión del vector de entrada; la segunda, el *decoder*, amplifica la dimensión de reducida, para recuperar el vector original. Este tipo de arquitectura permiten encontrar características relevantes, que puede permitir reducir la cantidad de features que necesita de entrada la DNN de estimación de DNB.

Por otro lado, en cuanto a la estimación de CHF, se debe tener en cuenta que implica la predicción de un fenómeno físico. Por lo tanto, la aplicación de una arquitectura PINN, presentada por Raissi, Perdikaris y Karniadakis [5], es lo primero que se pensó en intentar aplicar. Este tipo de arquitecturas permiten utilizar una función de pérdida que busque cumplir una ecuación diferencial en derivadas parciales (PDE, del inglés *Partial Differential Equation*), además de la función de pérdida respecto de los datos tabulados para entrenamiento. A priori esto resulta un problema complicado, ya que definir una ecuación que permita describir la fenomenología del DNB es algo no resuelto actualmente. Se tienen intentos de deducir una ecuación que dependa lo menos posible de factores empíricos, como la de Zhao et al. [12], pero estos no son del todo satisfactorios. Adicionalmente, la información disponible de los ensayos del *bundle* de la CNA-UII sólo provee información a la salida de la sección ensayada, por lo que computar derivadas espaciales resulta imposible.

Es entonces que se propone utilizar una metodología novedosa para la estimación de CHF, las redes neuronales profundas de multifidelidad (MFDNN, del inglés *Multi-Fidelity Deep Neural Networks*), propuestas por Meng y Karniadakis [4]. Esta arquitectura permite considerar conjuntos de datos de distinta fidelidad, por ejemplo, datos obtenidos a partir de ensayos experimentales (alta fidelidad, disponibilidad acotada o baja), datos obtenidos a partir de ensayos numéricos (baja fidelidad, disponibilidad acotada o alta), datos de ensayos experimentales en geometrías o condiciones diferentes (baja fidelidad, disponibilidad alta), etc. Para realizar esto, propone la hipótesis de que los datos de alta fidelidad tienen una relación no-lineal con los datos de baja fidelidad, la cual puede ser aproximada por medio de una DNN. Esta metodología se ajusta a la situación de los datos disponibles, donde tenemos datos de muy alta fidelidad pero muy acotados, y múltiples fuentes de datos de baja fidelidad con gran volumen.

Para realizar el desarrollo de las arquitecturas mencionadas, en este trabajo se utiliza la biblioteca PyTorch [16], [17]. Esta biblioteca permite la implementación de arquitecturas derivadas de un módulo base `torch.nn.Module()`, que facilita el desarrollo de modelos complejos. Para evaluar las propiedades termofísicas del agua se utiliza la biblioteca CoolProp [18], de amplia adopción y frecuente actualización. La biblioteca Pandas [19, 20] se utiliza para la manipulación de datos en formato tabulado. Para diversas funciones de transformación de los datos en el *pipeline* se hace uso de la biblioteca Scikit-learn [21]. Para graficado de resultados se utilizan las bibliotecas Matplotlib [22] y Seaborn [23].

2.2. Datasets y datos de entrenamiento

En cuanto a los datos de entrenamiento, se debe dividir esta sección en los datos utilizados para la estimación de las PLC y para la estimación de CHF.

Para la estimación de PLC, se utilizan datos de simulaciones realizadas por la División de Diseño Termohidráulico de la Gerencia de Análisis de Seguridad y Diseño del Núcleo (GASyDN) de Nucleoeléctrica Argentina S.A. (NA-SA), que son de carácter confidencial. Los datos fueron generados con el código de simulación termohidráulica de subcanales COBRA3-CP [3], a partir de estados del reactor calculados en las simulaciones de estrategias de recambio de combustibles. De las salidas de las simulaciones de COBRA3-CP se extraen los datos de entrada al código (perfiles de potencia axiales y por barra combustible, temperatura de entrada, presión de salida, potencia total, zona hidráulica, caudal, etc.), y los datos de salida del código (mínimo DNBR, fracción de vacío a la salida).

Por otro lado, para la estimación de CHF, se tiene múltiples fuentes de datos. Se incluyen: los datos de ensayos en un tubo usados por Groeneveld en su LUT 2006, obtenidos de [24]; los datos de ensayos sobre el *bundle* de la CNA-UII realizados por la Universidad de Columbia [25]; y el replicado de los ensayos de Columbia con COBRA3-CP, que permite ampliar la cantidad de puntos de ensayo y obtener datos en función de la coordenada z . Estas últimas dos fuentes de datos son de carácter confidencial.

Los datos de ensayos en un tubo tienen las siguientes variables disponibles: diámetro, longitud, presión a la salida, flujo másico, título termodinámico a la salida, entalpía a la entrada, flujo de calor y temperatura de entrada. En la figura 2.3 se muestran los histogramas de las variables de estos ensayos.

Los datos de los ensayos de Columbia tienen las siguientes variables disponibles: presión a la salida, temperatura de entrada, flujo másico, flujo de calor, título termodinámico a la salida y diferencia de presión a la entrada. En la figura 2.4 se presentan los histogramas de las variables de estos ensayos.

En cuanto a infraestructura de cómputo, debido al carácter confidencial de los datos utilizados, se opta por realizar todo el proceso de entrenamiento en un entorno local. Para ello se dispone de dos computadoras, una provista por la empresa NA-SA, con una placa gráfica NVIDIA A2000 y 32GB de RAM, y otra de uso personal del autor, con una placa gráfica NVIDIA RTX 3090 y 64GB de RAM. Ambas computadoras tienen capacidad apta para el trabajo en cuestión.




FIGURA 2.3. Histogramas de las variables de los ensayos de CHF en un tubo recopilados por Groeneveld.




FIGURA 2.4. Histogramas de las variables de los ensayos de CHF de la Universidad de Columbia.

Capítulo 3

Diseño e implementación

En este capítulo, se describe el diseño e implementación de los dos modelos desarrollados en este trabajo. Debido a la naturaleza del trabajo, se divide el capítulo en dos secciones, una para la estimación de PLC y otra para la de CHF.

3.1. Estimación de PLC

Intro...

Archivo `plc.py` con funciones de ayuda. **Nota: lo dejo en el anexo? Vale la pena?**

3.1.1. Pipeline de datos

Para la estimación de PLC, los datos provienen de simulaciones con COBRA-3CP de estados del reactor simulados para el diseño de la estrategia de recambio de combustibles. Se evaluaron 100 estados del reactor, cada uno implicando 451 simulaciones.

Debido a que los datos de una estrategia están alrededor de los parámetros de operación del reactor, se agregó una varianza a los parámetros de potencia total, temperatura de entrada, y presión a la salida. Esto fue realizado por medio de un *script* de Python, utilizando las funciones `random()` y `randint()` de la biblioteca `random`, que proveen una distribución uniforme en el rango establecido. Se varió la potencia aumentando la misma entre 5 % y 30 %, con intervalos de 5 %. La temperatura se varió en un intervalo uniforme entre 268 °C y 288 °C (± 10 °C respecto de la temperatura nominal de operación), y la presión entre 105 bar y 125 bar (± 10 bar respecto de la presión nominal de operación).

Las simulaciones se realizaron en paralelo y fueron procesadas al finalizar, para luego borrar el directorio de ejecución. De esta manera se evitó un excesivo volumen de datos en disco que no proveían valor. Se extrajo, para cada caso y canal: la zona hidráulica de ejecución, el perfil axial de potencia, el perfil por barra o radial de potencia, la potencia total del EECC, la fracción de vacío promedio a la salida del canal, el caudal de entrada, la temperatura de entrada, la presión a la salida y el MDNBR.

La distribución de fracción de vacío y MDNBR obtenida se puede observar en la figura 3.1. Se observa que el MDNBR tiene una fuerte dependencia con la ZH. Esto es esperable ya que cada ZH tiene una relación potencia-caudal característica, y los límites de DNBR son mayores cuanto más periférica la ZH. Será entonces un criterio de evaluación del modelo final si logra predecir correctamente para cada ZH la PLC. Por otro lado, la fracción de vacío presenta una distribución uniforme

en casi todo el dominio, con un pico en 0, es decir líquido sin vapor a la salida del canal.




FIGURA 3.1. Histogramas de fracción de vacío y MDNBR para las simulaciones con COBRA3-CP.

Al realizar las simulaciones y procesarlas se genera un archivo con extensión `csv`, el cual tiene las siguientes columnas: `caso`, `canal`, `zh`, `pa1`, ..., `pa22`, `pr1`, ..., `pr37`, `power`, `void`, `caudal`, `temperatura`, `presion`, `MDNBR`. Este archivo fue importado como un objeto `pandas.DataFrame`, de la biblioteca `pandas`.

Se filtraron los resultados a utilizar por el valor de MDNBR y fracción de vacío, para utilizar sólo valores en el rango de interés al calcular las PLC. Los datos por fuera de estos rangos sirvan de set adicional de evaluación, para determinar la capacidad de generalización del modelo por fuera del rango entrenado. Se filtraron los casos con MDNBR entre 1.7 y 2.5, o fracción de vacío entre 15 % y 35 %.

Con los resultados filtrados el pipeline es el siguiente:

1. Conversión a tensores (`torch.tensor(, dtype=torch.float(32))`) para las *features* (todas las variables menos MDNBR y void) y *target*.
2. División entre *train* y *test* por medio de `train_test_split` de `scikit-learn`.
3. Normalización de tensores de *features* y *targets* por medio de la función `plc.scale_tensors()`, que utiliza por dentro `StandardScaler()` de `scikit-learn`.

Nota para el corrector: tengo que poner los códigos de las funciones de ayuda que arme en un anexo? Acá me parece que ocuparían mucho espacio sin sentido, pero a la vez las funciones tampoco son revolucionarias como para que agreguen valor.

Ídem con funciones de adquisición de datos. Son funciones que modifican archivos y ejecutan COBRA3-CP. Algo que sólo a mi me interesa porque es parte de mi trabajo.

3.1.2. Arquitectura del modelo

- Función para armado de arquitectura dinámica

Adam [26] como optimizador.

3.1.3. Entrenamiento y optimización

Función de ayuda `train_model`.

Optimización con optuna




FIGURA 3.2. Resultados de los distintos intentos de la optimización.

Las funciones de activación consideradas son: ReLU [27], GELU [28], SiLU/Swish [29], Tanh, Leaky ReLU [30] y ELU [31].

3.1.4. Integración e implementación del sistema

3.2. Estimación de CHF

Intro...

Archivos con funciones de ayuda: `chf.py`, `ahmad_scaling.py`. **Nota: lo dejo en el anexo? Vale la pena?**

3.2.1. Pipeline de datos

Los datos disponibles para estimación de CHF se dividen en tres fuentes:

- Datos de ensayo en tubo, utilizados por Groeneveld para sus LUT (versión 2006).
- Datos de ensayos de la Universidad de Columbia, sobre el bundle de la CNA-UII.
- Datos de simulaciones de COBRA3-CP, modelando la geometría y condiciones de los ensayos de la Universidad de Columbia.

Estas fuentes tienen distintas características. Los datos de ensayos experimentales tienen una disponibilidad similar de datos, aunque los ensayos de bundle conllevan una mayor complejidad geométrica, propia del bundle, que podría ser tenida en cuenta por el modelo. Es posible realizar *data augmentation* de los datos experimentales por medio de modelos y relaciones termodinámicas. Por otro lado, las simulaciones permiten obtener datos muy detallados, tanto espacialmente como en variables termodinámicas informadas.

Por otro lado, se debe definir con cautela qué *features* dar al modelo para predecir CHF. Si consideramos que no tenemos pérdidas de calor, la evolución de la entalpía del fluido en función de la coordenada z va a venir dada por:

$$h(z) = h_{\text{inlet}} + \frac{\pi D}{\dot{m}} \int_0^z q'' dz'. \quad (3.1)$$

Por otro lado, el título termodinámico de equilibrio se relaciona con la entalpía de la siguiente forma:

$$x(z) = \frac{h(z) - h_f}{h_{fg}}. \quad (3.2)$$

Si $q'' = \text{cte}$, como lo es tanto en los ensayos de un tubo y del bundle de la CNA-UII, reemplazando 3.1 en 3.2 tenemos:

$$x(z) = x_{\text{inlet}} + \frac{\pi D q'' z}{\dot{m} h_{fg}}, \quad (3.3)$$

por lo que el modelo, dado $x(z = 1) = x_{\text{outlet}}$, puede despejar q'' . Pero esto tiene dos implicancias: en primer lugar el modelo está asumiendo perfil de flujo de calor constante; y en segundo lugar, está considerando que las variables de entrada corresponden a un estado de CHF. Ninguna de estas dos implicancias son deseables, ya que el modelo no podrá generalizar a los casos de interés: cuando no sabemos cuál es el valor del CHF, ni estamos en condición de CHF.

En la bibliografía clásica de CHF existen dos enfoques: el método de sustitución directa (DSM, del inglés *Direct Substitution Method*) y el método de balance de calor (HBM, del inglés *Heat Balance Method*). El DSM tiene como principal hipótesis

que el CHF es un fenómeno local, por lo que utiliza directamente con variables locales para predecir CHF. Esta hipótesis se ha considerado relativamente válida en caso de DNB, como lo sugieren [32, 7, 33]. Por otro lado, el HBM, como lo indica su nombre, realiza el balance de calor a partir de las condiciones de entrada al tubo. Groeneveld et al. evaluaron sus tres versiones de las LUT (1986 [34], 1995 y 2006) mediante ambos métodos, y obtuvieron predicciones más precisas utilizando el HBM. Sin embargo, el DSM es el más utilizado en la práctica, y el más adecuado para su aplicación en códigos termohidráulicos, como señala Siman-Tov [35]. Esto se debe, por un lado, a su simplicidad, y por otro, a que los ensayos realizados en geometrías reales (de bundle) informan las condiciones promedio, mientras que el CHF ocurre a nivel de subcanal. Las condiciones locales a nivel de subcanal pueden ser estimadas por medio de códigos de subcanal como COBRA3-CP, pero esto agregaría un error de la herramienta de cálculo que sería deseable evitar. Adicionalmente, el DSM es el método utilizado en la estimación de CHF para el bundle de la CNA-UII, por medio de las LUT 1995 y los TMF de INVAP.

Entonces, en este trabajo, se analizarán dos *pipelines* de datos, ambas basadas en DSM. En primer lugar considerar las mismas entradas que toma el método actual: **completar con lo que toma la LUT + lo que toman los factores de corrección de Groeneveld y los TMF de INVAP. Hay algunos datos que son específicos de la corrección de bundle.** A este pipeline lo llamaremos *pipeline vanilla*.

En segundo lugar, se realizará una transformación de las variables en números adimensionales, y se evaluará por medio de regularización y validación cruzada su relevancia. Las variables planteadas en este pipeline son: **completar!! Tener en cuenta que algunos datos son particulares de bundle (distancia al separador por ej).**

$$We = \quad (3.4)$$

$$Re = \quad (3.5)$$

A este pipeline lo llamaremos *pipeline novel*.

Adicionalmente, debemos considerar un detalle importante de los ensayos realizados en la Universidad de Columbia. La mayoría de estos ensayos fueron realizados en agua liviana (H_2O), pero una serie de los mismos fue realizada en agua pesada, el fluido de trabajo de la CNA-UII. Esto impone la necesidad de traducir los ensayos a un único fluido. Debido a que tradicionalmente los ensayos se han hecho con agua liviana en vistas de reactores PWR (del inglés, *Pressurized Water Reactors*), y que los ensayos en un tubo se realizaron con agua liviana, tradicionalmente se escaló el ensayo de agua pesado a agua liviana. Luego, la predicción de CHF para agua liviana se debe escalar a agua pesada, para poder predecir las condiciones dentro del reactor. En este trabajo se continúa con esta línea de trabajo. El escaleo de propiedades entre fluidos es dependiente del fenómeno estudiado, en particular, para CHF se utiliza la regla de escaleo de Ahmad [36]. Esta regla de escaleo propone cuatro números adimensionales a conservar entre el fluido “prototipo” y el fluido “modelo”:

$$\begin{cases} (\Psi_{CHF})_{\text{prototipo}} = (\Psi_{CHF})_{\text{modelo}} , \\ (\Delta H/\lambda)_{\text{prototipo}} = (\Delta H/\lambda)_{\text{modelo}} , \\ (\rho_L/\rho_V)_{\text{prototipo}} = (\rho_L/\rho_V)_{\text{modelo}} , \\ (L/D)_{\text{prototipo}} = (L/D)_{\text{modelo}} . \end{cases} \quad (3.6)$$

Siendo ΔH el subenfriamiento a la entrada, λ el calor latente de vaporización, ρ_L y ρ_V las densidades de la fase líquida y vapor respectivamente, L el largo de la sección de ensayo, D el diámetro de la sección de ensayo, y Ψ_{CHF} el número adimensional propuesto específicamente para CHF por Ahmad:

$$\Psi_{CHF} = \left[\left(\frac{G D}{\mu_L} \right) \cdot \left(\frac{\mu_L^2}{\sigma D \rho_L} \right)^{2/3} \cdot \left(\frac{\mu_V}{\mu_L} \right)^{1/5} \right], \quad (3.7)$$

siendo G el flujo másico por unidad de área, μ_L y μ_V las viscosidades dinámicas de la fase líquido y vapor respectivamente, y σ la tensión superficial. Esta regla de escaleo se encuentra implementada en un código python, por medio de la función `scaling_ahmad()`. **Nota: Lo dejo en un anexo?**

3.2.2. Arquitectura del modelo

3.2.3. Entrenamiento y optimización

- Optimización con optuna

3.2.4. Integración e implementación del sistema

Capítulo 4

Ensayos y resultados

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

4.1. Pruebas funcionales del hardware

La idea de esta sección es explicar cómo se hicieron los ensayos, qué resultados se obtuvieron y analizarlos.

Capítulo 5

Conclusiones

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

5.1. Conclusiones generales

La idea de esta sección es resaltar cuáles son los principales aportes del trabajo realizado y cómo se podría continuar. Debe ser especialmente breve y concisa. Es buena idea usar un listado para enumerar los logros obtenidos.

En esta sección no se deben incluir ni tablas ni gráficos.

Algunas preguntas que pueden servir para completar este capítulo:

- ¿Cuál es el grado de cumplimiento de los requerimientos?
- ¿Cuán fielmente se pudo seguir la planificación original (cronograma incluido)?
- ¿Se manifestó algunos de los riesgos identificados en la planificación? ¿Fue efectivo el plan de mitigación? ¿Se debió aplicar alguna otra acción no contemplada previamente?
- Si se debieron hacer modificaciones a lo planificado ¿Cuáles fueron las causas y los efectos?
- ¿Qué técnicas resultaron útiles para el desarrollo del proyecto y cuáles no tanto?

5.2. Próximos pasos

Acá se indica cómo se podría continuar el trabajo más adelante.

Bibliografía

- [1] Nucleoeléctrica Argentina S.A. *Informe Final de Seguridad de la Central Nuclear Atucha II*. Confidencial. 2025.
- [2] S. Nukiyama. «The maximum and minimum values of the heat Q transmitted from metal to boiling water under atmospheric pressure». En: *International Journal of Heat and Mass Transfer* 9.12 (1966), págs. 1419-1433. ISSN: 0017-9310. DOI: [https://doi.org/10.1016/0017-9310\(66\)90138-4](https://doi.org/10.1016/0017-9310(66)90138-4). URL: <https://www.sciencedirect.com/science/article/pii/0017931066901384>.
- [3] N.E. Todreas J.W. Jackson e INVAP. COBRA3-CP. *An improved version of COBRA IIIC/MIT-2: a digital computer program for steady state and transient thermal-hydraulic analysis of rod bundle nuclear fuel elements*. Confidencial. 1981.
- [4] X. Meng y G.E. Karniadakis. «A composite neural network that learns from multi-fidelity data: Application to function approximation and inverse PDE problems». En: *Journal of Computational Physics* 401 (2020), pág. 109020. ISSN: 0021-9991. DOI: <https://doi.org/10.1016/j.jcp.2019.109020>. URL: <https://www.sciencedirect.com/science/article/pii/S0021999119307260>.
- [5] M. Raissi, P. Perdikaris y G.E. Karniadakis. «Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations». En: *Journal of Computational Physics* 378 (2019), págs. 686-707. ISSN: 0021-9991. DOI: <https://doi.org/10.1016/j.jcp.2018.10.045>. URL: <https://www.sciencedirect.com/science/article/pii/S0021999118307125>.
- [6] H. Ballesteros. *Descripción y Teoría del Programa AXENA*. Inf. téc. 22-12. Confidencial. Gerencia de Análisis de Seguridad y Diseño del Núcleo, Nucleoeléctrica Argentina S.A., 2012.
- [7] L. S. Tong e Y. S. Tang. *Boiling Heat Transfer and Two-Phase Flow*. 2nd. New York: Taylor & Francis, 1997. ISBN: 1560324855. URL: <https://www.taylorfrancis.com/books/mono/10.1201/9781315138510/boiling-heat-transfer-two-phase-flow-tong>.
- [8] D.C. Groeneveld et al. «The 1995 look-up table for critical heat flux in tubes». En: *Nuclear Engineering and Design* 163.1 (1996), págs. 1-23. ISSN: 0029-5493. DOI: [https://doi.org/10.1016/0029-5493\(95\)01154-4](https://doi.org/10.1016/0029-5493(95)01154-4). URL: <https://www.sciencedirect.com/science/article/pii/0029549395011544>.
- [9] D.C. Groeneveld et al. «The 2006 CHF look-up table». En: *Nuclear Engineering and Design* 237.15 (2007). NURETH-11, págs. 1909-1922. ISSN: 0029-5493. DOI: <https://doi.org/10.1016/j.nucengdes.2007.02.014>. URL: <https://www.sciencedirect.com/science/article/pii/S0029549307002002>.
- [10] INVAP. *Incorporation of the 1995 AECL Lookup Table for CHF to the COBRA3-CP code*. Inf. téc. CNA2-1152-3BEIN-004-A. Confidencial. 2008.
- [11] Xingang Zhao et al. «On the prediction of critical heat flux using a physics-informed machine learning-aided framework». En: *Applied Thermal Engineering* 164 (2020), pág. 114540. ISSN: 1359-4311. DOI: <https://doi.org/10.1016/j.applthermaleng.2020.114540>.

- 1016/j.applthermaleng.2019.114540. URL: <https://www.sciencedirect.com/science/article/pii/S1359431119332065>.
- [12] Xingang Zhao, Robert K. Salko y Koroush Shirvan. «Improved departure from nucleate boiling prediction in rod bundles using a physics-informed machine learning-aided framework». En: *Nuclear Engineering and Design* 374 (2021), pág. 111084. ISSN: 0029-5493. DOI: <https://doi.org/10.1016/j.nucengdes.2021.111084>. URL: <https://www.sciencedirect.com/science/article/pii/S0029549321000364>.
- [13] Yue Jin, Xingang Zhao y Koroush Shirvan. «Constructing A New CHF Look-Up Table Based on the Domain Knowledge Informed Machine Learning Methodology». En: Oak Ridge National Laboratory (ORNL), Oak Ridge, TN (United States). Mar. de 2022. URL: <https://www.osti.gov/biblio/1867773>.
- [14] Congshan Mao y Yue Jin. «Uncertainty quantification study of the physics-informed machine learning models for critical heat flux prediction». En: *Progress in Nuclear Energy* 170 (2024), pág. 105097. ISSN: 0149-1970. DOI: <https://doi.org/10.1016/j.pnucene.2024.105097>. URL: <https://www.sciencedirect.com/science/article/pii/S0149197024000477>.
- [15] Ian Goodfellow, Yoshua Bengio y Aaron Courville. *Deep Learning*. <http://www.deeplearningbook.org>. MIT Press, 2016.
- [16] Adam Paszke et al. *PyTorch: An Imperative Style, High-Performance Deep Learning Library*. 2019. arXiv: 1912.01703 [cs.LG]. URL: <https://arxiv.org/abs/1912.01703>.
- [17] Adam Paszke et al. *PyTorch*. URL: <https://pytorch.org/>.
- [18] Ian H. Bell et al. «Pure and Pseudo-pure Fluid Thermophysical Property Evaluation and the Open-Source Thermophysical Property Library CoolProp». En: *Industrial & Engineering Chemistry Research* 53.6 (2014). DOI: [10.1021/ie4033999](https://doi.org/10.1021/ie4033999).
- [19] The pandas development team. *pandas-dev/pandas: Pandas*. Ver. latest. Feb. de 2020. DOI: [10.5281/zenodo.3509134](https://doi.org/10.5281/zenodo.3509134). URL: <https://doi.org/10.5281/zenodo.3509134>.
- [20] Wes McKinney. «Data Structures for Statistical Computing in Python». En: *Proceedings of the 9th Python in Science Conference*. Ed. por Stéfan van der Walt y Jarrod Millman. 2010, págs. 56 -61. DOI: [10.25080/Majora-92bf1922-00a](https://doi.org/10.25080/Majora-92bf1922-00a).
- [21] Fabian Pedregosa et al. «Scikit-learn: Machine Learning in Python». En: *Journal of Machine Learning Research* 12 (2011), págs. 2825-2830. URL: <http://arxiv.org/abs/1201.0490>.
- [22] J. D. Hunter. «Matplotlib: A 2D graphics environment». En: *Computing in Science & Engineering* 9.3 (2007), págs. 90-95. DOI: [10.1109/MCSE.2007.55](https://doi.org/10.1109/MCSE.2007.55).
- [23] Michael L. Waskom. «seaborn: statistical data visualization». En: *Journal of Open Source Software* 6.60 (2021), pág. 3021. DOI: [10.21105/joss.03021](https://doi.org/10.21105/joss.03021). URL: <https://doi.org/10.21105/joss.03021>.
- [24] D. C. Groeneveld. *Critical Heat Flux Data Used to Generate the 2006 Groeneveld Critical Heat Flux Lookup Tables*. NUREG/KM 0011. Washington, DC: U.S. Nuclear Regulatory Commission, 2019. URL: <https://www.nrc.gov/reading-rm/doc-collections/nuregs/knowledge/km0011/index>.
- [25] L. Lencina y H. Ballesteros. *Recopilación datos experimentales obtenidos de los ensayos termohidráulicos realizados en el Elemento Combustible Atucha II en los Circuitos Experimentales de la CNEA (CEBP y CEAP) y en la Universidad de*

- Columbia. Inf. téc. 11-08. Confidencial. Gerencia de Análisis de Seguridad y Diseño del Núcleo, Nucleoeléctrica Argentina S.A., 2008.
- [26] Diederik P. Kingma y Jimmy Ba. «Adam: A Method for Stochastic Optimization». En: *International Conference on Learning Representations (ICLR)*. 2015.
- [27] Vinod Nair y Geoffrey E. Hinton. «Rectified Linear Units Improve Restricted Boltzmann Machines». En: *Proceedings of the 27th International Conference on Machine Learning (ICML-10)*. 2010, págs. 807-814.
- [28] Dan Hendrycks y Kevin Gimpel. «Gaussian Error Linear Units (GELUs)». En: *arXiv preprint arXiv:1606.08415* (2016).
- [29] Stefan Elfving, Eiji Uchibe y Kenji Doya. «Sigmoid-Weighted Linear Units for Neural Network Function Approximation in Reinforcement Learning». En: *Neural Networks* 107 (2018), págs. 3-11.
- [30] Andrew L. Maas, Awni Y. Hannun y Andrew Y. Ng. «Rectifier Nonlinearities Improve Neural Network Acoustic Models». En: *Proceedings of the 30th International Conference on Machine Learning (ICML)*. Vol. 30. 1. 2013.
- [31] Djork-Arné Clevert, Thomas Unterthiner y Sepp Hochreiter. «Fast and Accurate Deep Network Learning by Exponential Linear Units (ELUs)». En: *arXiv preprint arXiv:1511.07289* (2015).
- [32] J Weisman y B S Pei. «Prediction of critical heat flux in flow boiling at low qualities». en. En: (1983). DOI: [https://doi.org/10.1016/S0017-9310\(83\)80047-7](https://doi.org/10.1016/S0017-9310(83)80047-7). URL: <https://www.sciencedirect.com/science/article/pii/S0017931083800477>.
- [33] Jean-Marie Le Corre, Shi-Chune Yao y Cristina H. Amon. «A mechanistic model of critical heat flux under subcooled flow boiling conditions for application to one- and three-dimensional computer codes». en. En: *Nuclear Engineering and Design* 240.2 (feb. de 2010), págs. 235-244. ISSN: 00295493. DOI: [10.1016/j.nucengdes.2008.12.007](https://doi.org/10.1016/j.nucengdes.2008.12.007). URL: <https://linkinghub.elsevier.com/retrieve/pii/S0029549308006225> (visitado 22-07-2026).
- [34] D. C. Groeneveld, S. C. Cheng y T. Doan. «1986 AECL-UO Critical Heat Flux Lookup Table». En: *Heat Transfer Engineering* 7.1-2 (1986), págs. 46-62. URL: <https://doi.org/10.1080/01457638608939644>.
- [35] Moshe Siman-Tov. «Application of energy balance and direct substitution methods for thermal margins and data evaluation». en. En: *Nuclear Engineering and Design* 163.1-2 (jun. de 1996), págs. 249-258. ISSN: 00295493. DOI: [10.1016/0029-5493\(95\)01174-9](https://doi.org/10.1016/0029-5493(95)01174-9). URL: <https://linkinghub.elsevier.com/retrieve/pii/0029549395011749> (visitado 21-07-2026).
- [36] S.Y. Ahmad. «Fluid to fluid modeling of critical heat flux: A compensated distortion model». en. En: *International Journal of Heat and Mass Transfer* 16.3 (mar. de 1973), págs. 641-662. ISSN: 00179310. DOI: [10.1016/0017-9310\(73\)90229-9](https://doi.org/10.1016/0017-9310(73)90229-9). URL: <https://linkinghub.elsevier.com/retrieve/pii/0017931073902299> (visitado 22-07-2026).