

Desarrollo de una herramienta predictiva de la potencia límite de canal de la Central Nuclear Atucha II entrenada con simulaciones de código de subcanales

Ing. Juan Ignacio Teich

Carrera de Especialización en Inteligencia Artificial

Director: Mg. Ing. Martín Sebastián Silva (Nucleoeléctrica Argentina S.A.)

Jurados:

Jurado 1 (pertenencia)

Jurado 2 (pertenencia)

Jurado 3 (pertenencia)

Ciudad de Buenos Aires, octubre de 2026

Resumen

En el presente trabajo se expone el desarrollo de una metodología para estimar la Potencia Límite de Canal de la Central Nuclear Atucha II, basada en redes neuronales, con tiempos de cómputo órdenes de magnitud inferiores a los de los códigos termohidráulicos empleados en Nucleoeléctrica Argentina S.A. Esto permite disminuir considerablemente los tiempos y costos computacionales de los cálculos termohidráulicos para las estrategias de recambio de combustibles.

Adicionalmente, se propone una metodología para estimar el Flujo Crítico de Calor, que incorpora redes neuronales informadas por física y redes neuronales de multifidelidad. El enfoque integra datos provenientes de ensayos experimentales en geometrías simples y en la geometría del bundle de la Central Nuclear Atucha II, y de ensayos numéricos.

Para el desarrollo del trabajo se aplicaron conocimientos sobre redes neuronales, tanto informadas por física como de multifidelidad, y sobre su entrenamiento y optimización.

Agradecimientos

Quiero agradecer en primer lugar a Martín,

Índice general

Resumen	I
1. Introducción general	1
1.1. Introducción a termohidráulica nuclear	1
1.2. Contexto y motivación	4
1.3. Estado del arte	4
1.4. Objetivos	5
2. Introducción específica	7
2.1. Frameworks y bibliotecas	7
2.2. Datasets y datos de entrenamiento	9
3. Diseño e implementación	13
3.1. Estimación de PLC	13
3.1.1. Pipeline de datos	13
3.1.2. Arquitectura del modelo, entrenamiento y optimización	15
3.1.3. Integración e implementación del sistema	16
3.1.4. Arquitectura de embeddings, entrenamiento y aplicación	18
3.1.5. Evaluación del modelo	19
3.2. Estimación de CHF	20
3.2.1. Pipeline de datos	20
3.2.2. Arquitectura del modelo	24
3.2.3. Evaluación del modelo	30
4. Ensayos y resultados	33
4.1. Estimación de PLC	33
4.1.1. Optimización de hiperparámetros	33
4.1.2. Resultados de DNBR y fracción de vacío	34
4.1.3. Estimación de PLC por DNBR y fracción de vacío	37
4.1.4. Aplicación de embeddings	40
4.2. Estimación de CHF	43
4.2.1. Modelo predictor de CHF en un tubo	43
4.2.2. Análisis de arquitectura de multifidelidad	49
4.2.3. Análisis de arquitectura informada por física	52
4.2.4. Análisis de variables de entrada	57
4.2.5. Modelos finales	59
4.2.6. Estimación de impacto	62
5. Conclusiones	63
5.1. Conclusiones generales	63
5.1.1. Estimación de PLC	63
5.1.2. Estimación de CHF	64
5.2. Próximos pasos	64

A. Predicción de CHF por LUT de Groeneveld	65
A.1. Interpolación en la LUT	65
A.2. Factores de corrección	65
A.3. Factores de corrección propuestos por INVAP	66
Bibliografía	67

Índice de figuras

1.1. Fotografía aérea de la Central Nuclear Atucha II ¹	1
1.2. Esquematación de los canales refrigerantes en el núcleo de la CNA-UII y las 5 zonas hidráulicas ²	2
1.3. Curva de Nukiyama ³	3
2.1. Esquema del loop de cálculo iterativo de la PLC por DNBR con COBRA3-CP.	7
2.2. Comparación de resultados preliminares de estimación de PLC y DNBR por DNN.	8
2.3. Histogramas de las variables de los ensayos de CHF en un tubo recopilados por Groeneveld.	10
2.4. Histogramas de las variables de los ensayos de CHF de la Universidad de Columbia.	11
3.1. Histogramas de fracción de vacío y MDNBR para las simulaciones con COBRA3-CP.	14
3.2. Arquitectura de la DNN para estimación de MDNBR y fracción de vacío, para predicción de PLC.	15
3.3. Lazo de cálculo del flujo de calor que alcanza el MDNBR objetivo.	17
3.4. Esquema del autoencoder: el codificador comprime la entrada en un embedding de baja dimensión y el decodificador reconstruye la entrada a partir de él.	18
3.5. Comparativa de distribuciones de datos de flujo másico, presión, temperatura y título termodinámico entre ensayos de un tubo de Groeneveld y todos los puntos de los ensayos numéricos con COBRA3-CP.	24
3.6. Esquema de la arquitectura de red neuronal de multifidelidad informada por física.	25
3.7. Tendencia del CHF con el flujo másico, para los datos de los ensayos en un tubo recopilados por Groeneveld [1, 2].	28
3.8. Tendencia del CHF con el título termodinámico, para los datos de los ensayos en un tubo recopilados por Groeneveld [1, 2].	29
3.9. Tendencia del CHF con la presión, para los datos de los ensayos en un tubo recopilados por Groeneveld [1, 2].	30
4.1. Resultados de los distintos intentos de la optimización.	34
4.2. Resultados de predicción de DNBR y fracción de vacío, para los conjuntos de test y train.	35
4.3. Resultados de predicción de DNBR y fracción de vacío, para el conjunto excluido.	36
4.4. Distribución del error para cada objetivo, por conjunto de datos.	37
4.5. Resultados de estimación de PLC por DNBR y fracción de vacío con factor de corrección, por zona hidráulica.	39

4.6. Gráficos de perfiles axiales con valores más altos, medianos y bajos de cada componente del espacio latente.	41
4.7. Gráficos de perfiles radiales con valores más altos, medianos y bajos de cada componente del espacio latente.	41
4.8. Relación del CHF predicho con el flujo másico y el título, según el punto predicho por el modelo $LFDNN$ #4. TRAIN y TEST son los conjuntos de entrenamiento y evaluación correspondientes a la $HFDNN$, divididos tal que en evaluación se tienen los ensayos de menor flujo másico.	45
4.9. Evaluación de la generalización de la $LFDNN$ respecto del flujo másico y el título termodinámico.	46
4.10. Relación del CHF predicho con el flujo másico y el título, según el punto predicho por el modelo $LFDNN$ con monotonidad con $\lambda = 0,1$. TRAIN y TEST son los conjuntos de entrenamiento y evaluación correspondientes a la $HFDNN$, divididos tal que en evaluación se tienen los ensayos de menor flujo másico.	47
4.11. Evaluación de la generalización de la $LFPINN$ respecto del flujo másico y el título termodinámico, según λ	48
4.12. Predicción de CHF contra medido y DNBR para cada ensayo, para modelo $LFPINN$ con $\lambda = 0,1$	48
4.13. División de los datos de CHF de la Universidad de Columbia en entrenamiento y evaluación, según flujo másico. Los ejes de flujo másico y título termodinámico corresponden a los valores promedios de la sección de ensayo a la salida.	50
4.14. Distribución de probabilidad de $DNBR_{min}$ para $N = 50$ modelos entrenados de cada tipo.	51
4.15. CHF predicho contra medido y DNBR por ensayo para modelos DNN y $MFDNN$. Se seleccionó para cada variante el modelo con la mediana del $DNBR_{min}$ de entrenamiento.	52
4.16. CHF predicho contra medido y DNBR por ensayo para variante A de $MFPINN$	55
4.17. CHF predicho contra medido y DNBR por ensayo para variante B de $MFPINN$	55
4.18. CHF predicho contra medido y DNBR por ensayo para variante D de $MFPINN$	55
4.19. CHF predicho contra medido y DNBR por ensayo para variante E de $MFPINN$	56
4.20. Relación entre CHF predicho y flujo másico y título termodinámico para variante A de $MFPINN$	56
4.21. Relación entre CHF predicho y flujo másico y título termodinámico para variante B de $MFPINN$	56
4.22. Relación entre CHF predicho y flujo másico y título termodinámico para variante D de $MFPINN$	57
4.23. Relación de CHF con el flujo másico y el título termodinámico para variante D de $MFPINN$, con variables de entrada expandidas.	58
4.24. CHF predicho contra real y DNBR por ensayo, para $MFDNN$ con variables de entrada expandidas.	59
4.25. CHF predicho contra real y DNBR por ensayo, para variante E de $MFPINN$ con variables de entrada expandidas.	59
4.26. Distribución de densidad de probabilidad de $DNBR_{min}$ para 50 modelos $MFDNN$ entrenados.	61

4.27. CHF predicho contra real y DNBR por ensayo para modelo final MFDNN.	61
4.28. CHF predicho contra real y DNBR por ensayo para modelo final MFPINN.	62
A.1. Esquematización de interpolación en tres dimensiones en la LUT de Groeneveld ⁴	65

Índice de tablas

1.1. Principales parámetros de diseño y condiciones de operación de la Central Nuclear Atucha II.	2
4.1. Hiperparámetros de la arquitectura final.	33
4.2. Media y desvío estándar del error con signo para cada objetivo. . .	35
4.3. Media y desvío estándar del error con signo para cada objetivo, segmentado por rangos de cada objetivo.	36
4.4. Media y desvío estándar de cociente predicho-real, y factor de 95 % de probabilidad y confianza. Por zona hidráulica.	38
4.5. Tiempos de cómputo para cálculo de PLC.	38
4.6. Margen perdido medio y máximo por utilizar DNN, según zona hidráulica y total.	40
4.7. Media y desvío estándar del error con signo para cada objetivo, para modelos con embeddings.	42
4.8. Margen perdido medio y máximo por utilizar DNN y embeddings, según zona hidráulica y total.	42
4.9. Arquitecturas de $LFDNN$ propuestas y métricas sobre conjuntos de entrenamiento y evaluación de ensayos en un tubo.	44
4.10. Arquitecturas de $LFDNN$ propuestas y métricas sobre ensayos de bundle de la CNA-UII.	44
4.11. Arquitecturas de $LFDNN$ propuestas y métricas sobre conjuntos de entrenamiento y evaluación de ensayos en un tubo.	46
4.12. Arquitecturas de $LFDNN$ propuestas y métricas sobre ensayos de bundle de la CNA-UII.	47
4.13. Evaluación por métricas estadísticas de la predicción sobre el conjunto de ensayos de la Universidad de Columbia. Para DNN y $MFDNN$ representa la mediana de 50 redes entrenadas.	50
4.14. Evaluación por métricas de predicción de DNBR sobre el conjunto de ensayos de la Universidad de Columbia. Para DNN y $MFDNN$ representa la mediana de 50 redes entrenadas.	51
4.15. Variantes del modelo $MFPINN$ evaluadas.	53
4.16. Resultados de predicción de CHF en conjunto de entrenamiento para las arquitecturas evaluadas de $MFPINN$	53
4.17. Resultados de predicción de CHF en conjunto de evaluación para las arquitecturas evaluadas de $MFPINN$	54
4.18. Resultados de predicción de CHF en conjunto de entrenamiento para las arquitecturas evaluadas de $MFPINN$	57
4.19. Resultados de predicción de CHF en conjunto de evaluación para las arquitecturas evaluadas de $MFPINN$	58
4.20. Evaluación por métricas de predicción de DNBR sobre el conjunto de ensayos de la Universidad de Columbia. Para $MFDNN$ representa la mediana de 50 redes entrenadas. Entrenamiento y evaluación divididos de forma aleatoria.	60

4.21. Potencia límite de canal [MW] por DNB para metodología actual y MFP INN.	62
---	----

Dedicado a Osvaldo, Susana y Alicia.

Capítulo 1

Introducción general

En este capítulo se presentan los lineamientos básicos del funcionamiento de la Central Nuclear Atucha II, su diseño termohidráulico y los métodos de cálculo de Potencia Límite de Canal y estimación de Flujo Crítico de Calor. Se plantea el contexto y la motivación de este trabajo, y el estado del arte de aplicaciones similares. Por último, se establecen los objetivos del trabajo.

1.1. Introducción a termohidráulica nuclear

La Central Nuclear Atucha II (CNA-UII) se ubica en la localidad de Lima, en la provincia de Buenos Aires, Argentina. Es una central nuclear de tipo PHWR (del inglés *Pressurized Heavy Water Reactor*), que utiliza agua pesada (óxido de deuterio, D_2O) como moderador y refrigerante, y uranio natural como combustible. El reactor nuclear genera 2 160 MW térmicos, y provee 745 MW eléctricos al Sistema Argentino de Interconexión (SADI). En la figura 1.1 se aprecia una foto aérea de la central.



FIGURA 1.1. Fotografía aérea de la Central Nuclear Atucha II¹.

En la tabla 1.1, obtenida del Informe Final de Seguridad (IFS) de la CNA-UII [3], se presentan los principales parámetros de diseño y condiciones de operación de la CNA-UII. El núcleo está compuesto por 451 canales refrigerantes que contienen los elementos combustibles (EECC). Los canales se encuentran agrupados en 5 zonas hidráulicas (ZZHH), cada una con un caudal másico característico. El caudal está determinado por un restrictor o drossel distintivo para las 4 zonas periféricas, mientras que la zona central no posee drossel. La diferenciación de

¹Imagen tomada de <https://na-sa.com.ar/>.

caudal fue realizada durante el diseño de la central, con el objetivo de obtener el mismo salto entálpico en todos los canales. En la figura 1.2 se presenta una imagen esquemática de la distribución de los canales en el núcleo de la CNA-UII y sus ZZHH.

TABLA 1.1. Principales parámetros de diseño y condiciones de operación de la Central Nuclear Atucha II.

Condiciones Generales de Operación	CNA-UII
Potencia térmica del reactor	2 160 MW _{th}
Caudal másico total	10 576 kg/s
Presión del Sistema Primario	115 bar
Temperatura de entrada del refrigerante	277,8 °C
Temperatura de salida del refrigerante	314,6 °C
Cantidad de zonas hidráulicas del núcleo	5
Cantidad de elementos combustibles en el núcleo	451
Cantidad de barras combustibles por elemento combustible	37




FIGURA 1.2. Esquematización de los canales refrigerantes en el núcleo de la CNA-UII y las 5 zonas hidráulicas².

Para cumplir con los criterios de diseño y operación segura establecidos en el IFS, se deben satisfacer dos criterios principales en cuanto a la potencia límite de operación de los combustibles dentro del núcleo, o Potencia Límite de Canal (PLC). Los criterios son: límite de fracción de vacío (α) a la salida de los canales refrigerantes, y Apartamiento de la Ebullición Nucleada (DNB, del inglés *Departure from Nucleate Boiling*).

En primer lugar, el límite por fracción de vacío establece la cantidad máxima de vapor admisible a la salida de los canales refrigerantes, con el fin de evitar

²Imagen tomada del IFS de CNA-UII [3].

vibraciones excesivas en los EECC. En particular, para la CNA-UII, el límite está establecido en 25 %.

En segundo lugar, el criterio de seguridad primordial del diseño de una central nuclear es garantizar la contención de los productos de fisión. Dado que las vainas son la segunda barrera de defensa en profundidad para ello, asegurar su integridad es fundamental. Además, el DNB es el mecanismo principal para la degradación de las vainas por efectos térmicos. Por lo tanto, evitar el DNB es el criterio principal del diseño termohidráulico.

El DNB es un cambio en el patrón de flujo que se desarrolla dentro de los canales refrigerantes, en el que se pasa de un régimen de ebullición nucleada (en inglés, *Nucleate Boiling*) a un régimen de ebullición en película (en inglés, *Film Boiling*). Este cambio de régimen se llama crisis de la ebullición y genera un aumento súbito de la temperatura de la pared calefaccionada, como se observa en la curva de Nukiyama [4] en la figura 1.3. Se caracteriza mediante el Flujo Crítico de Calor (CHF, del inglés *Critical Heat Flux*), por lo que la estimación del CHF según las condiciones locales de operación es el paso fundamental en el cálculo del límite por DNB. Adicionalmente, se evalúa el margen al DNB (DNBR, del inglés *DNB Ratio*), que se define como el cociente entre el flujo de calor local y el CHF según las condiciones. El DNBR debe estar por encima de un valor fijo, que considera la incerteza en la estimación del CHF y su sensibilidad respecto de las condiciones de operación, y que garantiza que ante cualquier transitorio esperable (AOO, del inglés *Anticipated Operational Occurrences*) no se produzca DNB.




FIGURA 1.3. Curva de Nukiyama³.

³Imagen tomada y traducida de <https://www.sciencedirect.com/topics/engineering/pool-boiling-curve>.

1.2. Contexto y motivación

Uno de los cálculos más importantes en el diseño termohidráulico de un reactor PHWR es la estimación de las PLC. Este cálculo puede requerir más de un millón de ejecuciones durante cada iteración del diseño de una estrategia de recambio de EECC, lo que implica un alto costo computacional. Por lo tanto, obtener una herramienta que permita computar de manera eficiente las PLC e identificar los casos más críticos a ser evaluados con los códigos termohidráulicos es de elevado interés. Dado que se cuenta con una amplia variedad de cálculos realizados por la División de Termohidráulica con el código COBRA3-CP [5], es factible plantear una herramienta basada en redes neuronales que permita estimar de manera preliminar las PLC con una alta eficiencia computacional. Debido a que los casos de interés para el diseño son los más limitantes, una herramienta que los seleccione de forma rápida y eficiente reduciría los tiempos de cómputo en órdenes de magnitud.

Adicionalmente, en el cálculo con los códigos termohidráulicos, un paso fundamental es la estimación del CHF en función de las condiciones locales del fluido. Hoy en día, esto se realiza con métodos que se dividen en dos: fórmulas semi-empíricas que buscan capturar la alta dimensionalidad del problema, y tablas de CHF obtenidas de ensayos en geometrías simples que luego son modificadas por factores ad hoc para replicar lo mejor posible los ensayos realizados sobre las geometrías reales del canal refrigerante del reactor. Se cuenta con datos de ensayos en geometrías sencillas, ensayos para el bundle de la CNA-UII realizados por la Universidad de Columbia, y la replicación de los ensayos de manera numérica con el código de subcanales COBRA3-CP. Este caso particular de disponibilidad de datos puede ser aprovechado por redes neuronales de tipo multifidelidad (MFDNN, del inglés *Multi-Fidelity Deep Neural Network*), como se plantea en el trabajo de Meng y Karniadakis [6]. Además, ya que se plantea un fenómeno físico, evaluar el impacto de introducir ecuaciones de conservación o relaciones monótonas es de interés, mediante un enfoque informado por física como se plantea en el trabajo fundacional de las redes neuronales informadas por física (PINN, del inglés *Physics Informed Neural Network*) de Raissi, Perdikaris y Karniadakis [7].

1.3. Estado del arte

El cálculo de PLC para la CNA-UII se realiza actualmente por medio del código de subcanales COBRA3-CP y el código de planta AXCNA2 [8]. Este cálculo es específico de cada central y, al ser confidencial, no se dispone de antecedentes bibliográficos de aplicación de aprendizaje automático (ML, del inglés *Machine Learning*).

Para la estimación del CHF, los métodos clásicos se dividen en relaciones semi-empíricas y datos tabulados modificados por factores de ajuste para la geometría de interés. Como ejemplo de relación semiempírica se tiene la correlación Westinghouse-3 (W-3) [9], utilizada en el diseño de la Central Nuclear Atucha I (CNA-UI), obtenida a partir de observación experimental del efecto individual de presión, caudal y título termodinámico sobre el CHF. Por otro lado, la referencia de datos tabulados de CHF son las *Look-up Tables* (LUT) de Groeneveld (1995 [10] y 2006 [2]), obtenidas a partir de más de 25 000 ensayos de CHF en un tubo

calefaccionado. Para obtener CHF en una geometría real de un reactor, se utilizan factores de corrección, como los *Taylor-made Factors* (TMF) para el bundle de la CNA-UII desarrollados por INVAP. Este procedimiento se describe con mayor detalle en el apéndice A.

Métodos más modernos para la estimación de CHF utilizan ML para mejorar la predicción de las herramientas clásicas, especialmente para las LUT. Ejemplos de ello se encuentran en los trabajos de Zhao et al. [11], [12] y Jin et al. [13], donde se utiliza una PIMLAF (*Physics-Informed Machine Learning-Aided Framework*) para estimar la modificación a realizar sobre la predicción por LUT para obtener CHF en una geometría compleja. Por otro lado, Mao y Jin [14] aplican PINN para estimar el CHF, pero con la guía física de los enfoques clásicos de estimación de CHF.

1.4. Objetivos

En función del problema descripto, el trabajo se orientó al desarrollo de modelos basados en redes neuronales para asistir en los cálculos termohidráulicos de la CNA-UII y a la evaluación de su viabilidad. Se establecieron los siguientes objetivos específicos:

- Desarrollar una herramienta basada en DNN para predecir PLC, a partir de los datos de entrada utilizados en los cálculos termohidráulicos.
- Realizar un análisis de reducción de dimensionalidad de los perfiles de potencia axiales y por barra.
- Desarrollar una herramienta basada en redes neuronales de multifidelidad informadas por física (MFPINN, del inglés *Multi-Fidelity Physics-Informed Neural Network*) para predicción de CHF en función de condiciones locales, a partir de datos de multifidelidad.

Capítulo 2

Introducción específica

En este capítulo se explican los frameworks, arquitecturas y bibliotecas utilizados en el trabajo, los conjuntos de datos para el entrenamiento y la validación de los modelos y, por último, la infraestructura de cómputo empleada.

2.1. Frameworks y bibliotecas

En esta sección se establecen los frameworks y bibliotecas utilizados para resolver los dos problemas planteados en este trabajo: la estimación de PLC y la estimación del CHF.

En primer lugar, la estimación de las PLC se realizó con redes neuronales profundas (DNN, del inglés *Deep Neural Networks*). Esta metodología fue elegida principalmente debido a su elevada capacidad de representar funciones no lineales, característica fundamental para el cálculo de las PLC, que presentan un alto grado de no linealidad. Para su implementación se consideraron dos posibilidades: un modelo que calcule directamente PLC y un modelo que reemplace el paso realizado por COBRA3-CP en el procedimiento de cálculo. En la figura 2.1 se esquematiza el procedimiento de cálculo con COBRA3-CP de la PLC por DNBR. El procedimiento para el cálculo de PLC por vacío es similar, pero se aproxima al valor deseado de vacío por el método de la secante [15].




FIGURA 2.1. Esquema del loop de cálculo iterativo de la PLC por DNBR con COBRA3-CP.

Se realizaron pruebas conceptuales de ambas metodologías y se identificó una dificultad relevante para estimar la PLC de manera directa, que se ejemplifica en la figura 2.2a. Por lo tanto, se decidió implementar un modelo que reemplace a COBRA3-CP y, a partir de las condiciones termohidráulicas del canal, estime el DNBR mínimo (MDNBR). Esta implementación demostró una capacidad predictiva superior, que se evidencia en la figura 2.2b. Se estimó que se tendría un comportamiento similar para la estimación de la PLC por vacío, por lo que se aplicó la misma metodología.




FIGURA 2.2. Comparación de resultados preliminares de estimación de PLC y DNBR por DNN.

Esta metodología adicionalmente permite una mayor adquisición de datos, dado que cada canal tiene una única PLC, pero se tienen infinitas posibilidades de MDNBR al variar su potencia. Si se recuerda que las DNN pueden pensarse como “máquinas de aproximación de funciones, diseñadas para obtener generalización estadística” [16], resulta claro que, a mayor disponibilidad de datos, mejor es el comportamiento final del modelo.

También es de interés en este trabajo analizar la aplicación de reducción de dimensionalidad a partir de las features de los perfiles de potencia axiales y por barra. Para ello, se utilizó una arquitectura codificador-decodificador (en inglés *encoder-decoder*), compuesta por dos DNN. La primera, el encoder, reduce la dimensión del vector de entrada, y la segunda, el decoder, amplifica la dimensión reducida, para recuperar el vector original. Este tipo de arquitectura permite encontrar características relevantes, lo que puede reducir la cantidad de features que necesita como entrada la DNN de estimación de DNBR.

Por otro lado, en cuanto a la estimación de CHF, se debe tener en cuenta que esta implica la predicción de un fenómeno físico. Por lo tanto, la aplicación de una arquitectura PINN, presentada por Raissi, Perdikaris y Karniadakis [7], resultó la primera alternativa a considerar. Este tipo de arquitectura permite utilizar una función de pérdida que busque cumplir una ecuación diferencial en derivadas parciales (PDE, del inglés *Partial Differential Equation*), además de la función de pérdida respecto de los datos tabulados para entrenamiento. En principio, esto resulta un problema complejo, ya que definir una ecuación que describa la fenomenología del DNB es una cuestión aún no resuelta. Existen intentos de deducir una ecuación que dependa lo menos posible de factores empíricos, como la de Zhao et al. [12], pero estos no son del todo satisfactorios. Adicionalmente, los ensayos del bundle de la CNA-UII solo proveen información a la salida de la sección ensayada, por lo que computar derivadas espaciales resulta imposible.

Por este motivo, se propuso utilizar una metodología novedosa para la estimación de CHF basada en MFDNN, propuestas por Meng y Karniadakis [6]. Esta arquitectura permite considerar conjuntos de datos de distinta fidelidad, por ejemplo, datos obtenidos a partir de ensayos experimentales (alta fidelidad, disponibilidad acotada o baja), datos obtenidos a partir de ensayos numéricos (baja fidelidad, disponibilidad acotada o alta), datos de ensayos experimentales en geometrías o condiciones diferentes (baja fidelidad, disponibilidad alta), etc. Para realizar esto, se propone la hipótesis de que los datos de alta fidelidad tienen una relación no lineal con los datos de baja fidelidad, que puede ser aproximada por medio de una DNN. Esta metodología se ajusta a los datos disponibles, que combinan información de muy alta fidelidad pero muy acotada, y múltiples fuentes de datos de baja o mediana fidelidad con gran volumen.

Para realizar el desarrollo de las arquitecturas mencionadas, en este trabajo se utilizó la biblioteca PyTorch [17], [18]. Esta biblioteca permite implementar arquitecturas derivadas de un módulo base `torch.nn.Module()`, lo que facilita el desarrollo de modelos complejos. Para evaluar las propiedades termofísicas del agua se utilizó la biblioteca CoolProp [19], de amplia adopción y frecuente actualización. La biblioteca Pandas [20, 21] se utilizó para la manipulación de datos en formato tabulado. Para diversas funciones de transformación de los datos en el pipeline se hizo uso de las bibliotecas scikit-learn [22] y NumPy [23]. Para graficado de resultados se utilizaron las bibliotecas Matplotlib [24] y Seaborn [25]. Para la optimización de los hiperparámetros se utilizó la biblioteca Optuna [26].

2.2. Datasets y datos de entrenamiento

En cuanto a los datos de entrenamiento, se debe dividir esta sección en los datos utilizados para la estimación de las PLC y para la estimación de CHF.

Para la estimación de PLC, se utilizaron datos de simulaciones realizadas por la División de Diseño Termohidráulico de la Gerencia de Análisis de Seguridad y Diseño del Núcleo (GASyDN) de Nucleoeléctrica Argentina S.A. (NA-SA), que son de carácter confidencial. Los datos fueron generados con el código de simulación termohidráulica de subcanales COBRA3-CP [5], a partir de estados del reactor calculados en las simulaciones de estrategias de recambio de combustibles. De las salidas de las simulaciones de COBRA3-CP se extrajeron los datos de entrada al código (perfiles de potencia axiales y por barra combustible, temperatura

de entrada, presión de salida, potencia total, zona hidráulica, caudal, etc.), y los datos de salida del código (mínimo DNBR, fracción de vacío a la salida).

Por otro lado, para la estimación de CHF, se dispone de múltiples fuentes de datos. Se incluyen los datos de ensayos en un tubo usados por Groeneveld en su LUT 2006, obtenidos de [1], los datos de ensayos sobre el bundle de la CNA-UII realizados por la Universidad de Columbia [27], y la réplica de los ensayos de Columbia con COBRA3-CP, que permite ampliar la cantidad de puntos de ensayo y obtener datos en función de la coordenada z . Estas últimas dos fuentes de datos son de carácter confidencial.

Los datos de ensayos en un tubo tienen las siguientes variables disponibles: diámetro, longitud, presión a la salida, flujo másico, título termodinámico a la salida, entalpía a la entrada, flujo de calor y temperatura de entrada. En la figura 2.3 se muestran los histogramas de las variables de estos ensayos.

En los ensayos de Columbia se registraron las siguientes variables: presión a la salida, temperatura de entrada, flujo másico, flujo de calor, título termodinámico a la salida y diferencia de presión a la entrada. En la figura 2.4 se presentan los histogramas de las variables de estos ensayos.

Respecto de la infraestructura de cómputo, debido al carácter confidencial de los datos utilizados, se optó por realizar todo el proceso de entrenamiento en un entorno local. Para ello se dispuso de dos computadoras, una provista por la empresa NA-SA, con una placa gráfica NVIDIA A2000 y 32 GB de RAM, y otra de uso personal del autor, con una placa gráfica NVIDIA RTX 3090 y 64 GB de RAM. Ambas computadoras tienen capacidad apta para el trabajo en cuestión.




FIGURA 2.3. Histogramas de las variables de los ensayos de CHF en un tubo recopilados por Groeneveld.




FIGURA 2.4. Histogramas de las variables de los ensayos de CHF de la Universidad de Columbia.

Capítulo 3

Diseño e implementación

En este capítulo se describe el diseño e implementación de los dos modelos desarrollados en este trabajo. Debido a ello, se divide el capítulo en dos secciones, una para la estimación de PLC y otra para la de CHF.

3.1. Estimación de PLC

En esta sección se describe el modelo desarrollado para estimar PLC. Se presentan el pipeline de datos, la arquitectura de la DNN para estimar DNBR y fracción de vacío, su entrenamiento y optimización, y la implementación del modelo para el cálculo de PLC.

Se construyó un archivo Python llamado `plc.py` con funciones auxiliares, empleadas a lo largo del flujo de procesamiento, entrenamiento y evaluación.

3.1.1. Pipeline de datos

Para la estimación de PLC, los datos provienen de simulaciones con COBRA3-CP de estados del reactor correspondientes al diseño de la estrategia de recambio de combustibles. Se evaluaron 100 estados del reactor. Cada uno de ellos implica una simulación por canal refrigerante, es decir, 451 simulaciones.

De las simulaciones de COBRA3-CP, se extrajeron dos conjuntos de información: por un lado, la información de entrada al código y, por otro, la de salida. La información de entrada de interés está compuesta por la zona hidráulica de ejecución, el perfil axial de potencia, el perfil por barra o radial de potencia, la potencia total del EECC, el caudal de entrada, la temperatura de entrada y la presión a la salida. En cuanto a la información de salida, se proveen la fracción de vacío promedio a la salida del canal y el MDNBR. Estos valores se extrajeron para cada caso y canal.

Debido a que los datos de una estrategia se ubican alrededor de los parámetros de operación del reactor, se agregó una varianza a la potencia total, la temperatura de entrada y la presión a la salida. Esto fue realizado por medio de un script de Python, con las funciones `random()` y `randint()` de la biblioteca `random`, que proveen una distribución uniforme en el rango establecido. La potencia se incrementó entre 5 % y 30 %, con intervalos de 5 %. La temperatura se evaluó dentro de un intervalo uniforme entre 268 °C y 288 °C (± 10 °C respecto de la temperatura nominal de operación), y la presión entre 105 bar y 125 bar (± 10 bar respecto de la presión nominal de operación). Estos rangos son similares a los utilizados para calcular el límite de diseño seguro (SDL, del inglés *Safety Design Limit*) en el diseño termohidráulico de la CNA-UII.

Las simulaciones se realizaron en paralelo y fueron procesadas al finalizar, para luego borrar el directorio de ejecución. De esta manera se evitó un excesivo volumen de datos en disco que no aportaba valor.

La distribución de fracción de vacío y MDNBR obtenida se presenta en la figura 3.1. Se observa que el MDNBR presenta una fuerte dependencia de la ZH. Esto es esperable, ya que cada ZH tiene un rango de caudales y una relación potencia-caudal característicos, y los límites de DNBR aumentan hacia las ZH periféricas. La correcta predicción de la PLC en cada ZH es entonces un criterio de evaluación del modelo final. Por otro lado, la fracción de vacío presenta una distribución uniforme en casi todo el dominio, con un pico en 0, es decir, condiciones sin presencia de vapor a la salida del canal.




FIGURA 3.1. Histogramas de fracción de vacío y MDNBR para las simulaciones con COBRA3-CP.

Al realizar las simulaciones y procesarlas se generó un archivo con extensión `csv`, que tiene las siguientes columnas: `caso`, `canal`, `zh`, `pa1`, ..., `pa22`, `pr1`, ..., `pr37`, `power`, `void`, `caudal`, `temperatura`, `presion`, `MDNBR`. Este archivo fue importado como un objeto `pandas.DataFrame`, de la biblioteca `Pandas`. Las columnas `caso`, `canal` y `zh` se descartaron. Las primeras dos, debido a que no aportan información, y la zona hidráulica, debido a que queda unívocamente representada por el caudal.

Los resultados se filtraron según el valor de MDNBR y de fracción de vacío, para conservar solo aquellos dentro del rango de interés al calcular las PLC. Los datos que exceden estos rangos sirvieron de set adicional de evaluación, para determinar la capacidad de generalización del modelo ante valores no incluidos en el entrenamiento. Se conservaron los casos con MDNBR entre 1,7 y 2,5, o fracción de vacío entre 15 % y 35 %.

Con los resultados filtrados el pipeline es el siguiente:

1. Conversión a tensores (`torch.tensor(, dtype=torch.float32)`) para las features (todas las variables menos MDNBR y void) y target.
2. División entre train y test por medio de `train_test_split` de `scikit-learn`.

3. Normalización de tensores de features y targets por medio de la función `plc.scale_tensors()`, que utiliza por dentro `StandardScaler()` de `scikit-learn`.

3.1.2. Arquitectura del modelo, entrenamiento y optimización

El estimador de PLC utiliza una arquitectura estándar de DNN, a partir del módulo `torch.nn.Sequential` y su método `add_module()`. Los hiperparámetros a configurar son cantidad de capas ocultas, cantidad de neuronas en las capas ocultas, función de activación, aplicación de regularización por dropout, learning rate y tamaño del batch de entrenamiento.

En la figura 3.2 se esquematiza la arquitectura implementada. La entrada reúne las 63 variables mencionadas previamente: las 22 componentes del perfil axial, las 37 componentes del perfil radial y las condiciones termohidráulicas de operación. A estas se aplica en la capa de entrada una función de activación σ . A continuación, estas variables ingresan en una red de L capas ocultas con h neuronas cada una, que aplican σ en cada nodo. Por último, la capa de salida está compuesta por dos variables, el MDNBR y la fracción de vacío.




FIGURA 3.2. Arquitectura de la DNN para estimación de MDNBR y fracción de vacío, para predicción de PLC.

Para el armado de la arquitectura se desarrolló la función `plc.build_model`, que permite obtener en una línea el modelo con los hiperparámetros deseados.

Para entrenar al modelo se utilizó Adam [28] como optimizador, debido a su alta capacidad y adopción en casos clásicos de DNN. Como función de pérdida se utilizó la raíz del error cuadrático medio (RMSE, del inglés *Root Mean Squared Error*), debido a que penaliza fuertemente los errores grandes y tiene magnitud del orden de las variables a optimizar.

Durante el entrenamiento se evaluó, además de la función de pérdida, el coeficiente de determinación R^2 , tanto para el set de entrenamiento como el de evaluación. Al predecir sobre el set de evaluación, se utilizó la condición `torch.no_grad()` para desactivar el cálculo de gradientes y evitar que se aprenda de este set de datos, lo que generaría data leakage. Se desarrolló la función de ayuda `plc.train_model` para realizar el entrenamiento sobre la cantidad de épocas deseadas de forma sencilla.

La definición de los hiperparámetros se realizó por medio de su optimización con Optuna. Para ello se planteó un estudio de hiperparámetros con 50 trials de 200 épocas cada uno. Se consideraron DNN con entre 2 y 15 capas ocultas, de entre 32 y 512 neuronas cada una, con un learning rate de entre 10^{-2} y 10^{-5} y batches de entrenamiento de entre 16 y 256. Las funciones de activación consideradas fueron ReLU [29], GELU [30], SiLU/Swish [31], Tanh, Leaky ReLU [32] y ELU [33].

Es importante señalar que la DNN predice dos valores con distinta escala y criticidad. Por lo tanto, es necesario un criterio para equipararlos o ponderarlos en el cálculo de la función de pérdida durante el entrenamiento.

En el capítulo 4 se presentan los resultados de la optimización realizada.

3.1.3. Integración e implementación del sistema

La integración consiste en realizar el lazo de cálculo de PLC de COBRA3-CP, pero con la DNN entrenada en su lugar. Se tiene un lazo para cada límite de PLC, pero ambos son idénticos en concepto. Únicamente se debe modificar la variable objetivo según si el criterio es de DNB o de fracción de vacío.

El lazo de cálculo se esquematiza en la figura 3.3. Allí se observa que, en primer lugar, se deben definir las condiciones operativas de temperatura y presión, y el límite objetivo, ya sea de MDNBR o de fracción de vacío. Luego se realizan dos cálculos, uno de piso y otro de techo, en los que se evalúan los flujos de calor mínimo y máximo. Estos valores se establecen previamente y deben contener al flujo de calor correspondiente al límite objetivo, por lo que un rango amplio es recomendable. Se obtiene el valor del límite para el flujo de calor mínimo y máximo y, por el método de la secante, se estima el flujo de calor con el que se alcanzaría el límite objetivo. Se recalcula el caudal másico con dicho flujo de calor y se vuelve a estimar el límite. Si se obtiene convergencia tanto en el límite objetivo como en caudal y flujo de calor, se termina el lazo de cálculo. Si no se obtiene convergencia, se realiza una nueva iteración del método de la secante.

Para calcular el flujo másico en función del flujo de calor, se recurrió a la relación caudal-potencia desarrollada por INVAP en [34], donde para cada ZH y condición operativa se tiene una tabla para interpolar caudal másico a partir de potencia de canal.




FIGURA 3.3. Lazo de cálculo del flujo de calor que alcanza el MDNBR objetivo.

3.1.4. Arquitectura de embeddings, entrenamiento y aplicación

Como se definió en la sección de objetivos 1.4, se realizó un análisis de reducción de dimensionalidad de los perfiles de potencia axiales y por barra. Para ello, se planteó una arquitectura de codificador-decodificador (en inglés *encoder-decoder* o *autoencoder*). Esto permite llevar el vector de entrada, en $\mathbb{R}^n$, a un espacio latente, $\mathbb{R}^d$, de menor dimensión, $d < n$. De esta forma se obtiene una representación compacta del vector de origen. Para lograr esto, el autoencoder se compone de dos DNN. La primera, el encoder, codifica al espacio latente, y la segunda, el decoder, decodifica nuevamente al espacio original. En la figura 3.4 se presenta un esquema del autoencoder.




FIGURA 3.4. Esquema del autoencoder: el codificador comprime la entrada en un embedding de baja dimensión y el decodificador reconstruye la entrada a partir de él.

Se entrenó un autoencoder independiente para cada perfil, ya que se trata de magnitudes de distinta naturaleza y dimensión: el perfil axial, con $n = 22$ componentes, y el perfil radial o por barra, con $n = 37$ componentes. Los perfiles se extrajeron del mismo archivo `csv` descrito en el pipeline de datos, se convirtieron a tensores de `torch`, se dividieron en `train` y `test` con `train_test_split`, y se normalizaron con `StandardScaler()`, de la misma manera que las features del estimador de PLC.

Tanto el codificador como el decodificador se implementaron como DNN con el módulo `torch.nn.Sequential`, con el mismo esquema que `plc.build_model`. El codificador toma las n componentes del perfil y las reduce progresivamente hasta la capa latente de dimensión d , mientras que el decodificador replica la estructura de forma espejada y expande de d a n . La capa latente no lleva función de activación, para no restringir el rango del embedding, y la capa de salida tampoco, dado que la reconstrucción se realiza sobre variables normalizadas que pueden tomar valores de ambos signos. Los hiperparámetros a configurar son entonces la dimensión latente d , la cantidad de capas ocultas de cada rama,

la cantidad de neuronas por capa, la función de activación, el learning rate y el tamaño del batch.

El entrenamiento es no supervisado: el propio perfil de entrada oficia de target, y la función de pérdida es el error cuadrático medio entre la entrada y su reconstrucción, $\mathcal{L}(\phi, \theta) = \|\mathbf{x} - \hat{\mathbf{x}}\|^2$, como se indica en la figura 3.4. Se utilizó nuevamente el optimizador Adam, con el mismo lazo de entrenamiento por épocas empleado en `plc.train_model`.

La elección de d se realizó por barrido: se entrenó un autoencoder para cada dimensión latente y se comparó el error de reconstrucción sobre el set de evaluación. De esta manera se identificó la menor dimensión que conserva la información relevante del perfil. Una vez entrenado el autoencoder, se descartó el decodificador y se conservó únicamente el codificador, que se aplicó sobre los perfiles para reemplazar las 22 y 37 componentes originales por sus respectivos embeddings de dimensión d .

Con las nuevas features se reentrenó el estimador de PLC descrito en las subsecciones anteriores, y en el capítulo 4 se comparan sus resultados contra los del modelo que utiliza los perfiles completos.

A partir de la transformación al espacio latente, se pueden evaluar cuáles son las componentes que caracterizan a los perfiles de potencia y cómo impactan en la PLC. Como referencia, se realizó un estudio análogo por medio del análisis de componentes principales (PCA, del inglés *Principal Component Analysis*) [35].

3.1.5. Evaluación del modelo

Para evaluar los modelos predictores de PLC, no basta con presentar medidas estadísticas del error, como el error cuadrático medio (MSE, del inglés *Mean Squared Error*), su raíz RMSE o el error absoluto medio (MAE, del inglés *Mean Absolute Error*). Por la naturaleza de la aplicación de este modelo, debe validarse también el conservadurismo de su predicción, esto es, asegurar con cierto grado de probabilidad y confianza que se predice una PLC por debajo de la referencia. Para ello, se aplicó un criterio similar al utilizado en el diseño termohidráulico de la CNA-UII para calcular el $\text{DNBR}_{\min}$, descrito en la sección 3.2.3.

Se definió el factor de ajuste de PLC, o F_{PLC} , que asegura con 95 % de probabilidad y confianza que se subestima la PLC. Entonces, se buscó el intervalo de tolerancia que, con 95 % de confianza, contiene al 95 % de las predicciones por debajo del valor real. Para ello se requería el factor de tolerancia k . En este caso, dada la elevada cantidad de observaciones, se pudo tomar el límite para infinitas muestras. Para 95 % de confianza, 95 % de probabilidad e infinitas muestras, se obtuvo $k_{95/95} = 1,645$. Entonces, F_{PLC} se obtiene según la ecuación 3.1,

$$\frac{1}{F_{\text{PLC}}} = \bar{R} + k_{95/95} \cdot \sigma(R), \quad (3.1)$$

donde R es el cociente entre el valor predicho y el de referencia de la PLC.

Definido el factor que permite asegurar una predicción conservativa, se evaluó el margen de potencia perdido al realizar la predicción por el método propuesto.

3.2. Estimación de CHF

En esta sección se presenta el modelo de multifidelidad informado por física para estimar CHF. Se explica el pipeline de datos, la arquitectura del modelo y la metodología para su evaluación.

Se desarrollaron múltiples códigos Python destinados a tareas auxiliares del proceso de cálculo, entre ellos `chf.py`, `ahmad_scaling.py`, `softmin.py` e `import_cobra.py`.

3.2.1. Pipeline de datos

Los datos disponibles para estimación de CHF se dividen en tres fuentes:

- Datos de ensayo en tubo, utilizados por Groeneveld para sus LUT (versión 2006). 24 579 observaciones.
- Datos de ensayos de la Universidad de Columbia, sobre el bundle de la CNA-UII. 146 observaciones.
- Datos de simulaciones de COBRA3-CP, que modelan la geometría y condiciones de los ensayos de la Universidad de Columbia. 1 322 760 observaciones, de 146 ensayos $\times$ 151 nodos axiales $\times$ 60 subcanales.

Estas fuentes presentan distintas características. Las dos de origen experimental tienen una disponibilidad similar, aunque los ensayos de bundle conllevan una mayor complejidad geométrica, que podría ser tenida en cuenta por el modelo. Es posible realizar data augmentation de los datos experimentales por medio de modelos y relaciones termodinámicas. Por otro lado, las simulaciones permiten obtener datos muy detallados, tanto espacialmente como en variables termodinámicas informadas. En este trabajo se consideraron los datos de las simulaciones como datos de alta fidelidad. En rigor, las simulaciones de COBRA3-CP están sujetas a error. Se han observado en la práctica diferencias respecto de los ensayos, en particular en cuanto al mezclado entre subcanales y el efecto del separador. Puesto que el trabajo busca proponer y validar una metodología, la hipótesis de COBRA3-CP como fuente de verdad resulta válida. En caso de utilizarse esta metodología para la predicción de CHF en la práctica, los cambios en los modelos termohidráulicos de COBRA3-CP deben acompañarse del reentrenamiento del modelo.

A su vez, se deben definir con cautela las features que ingresan al modelo para predecir CHF. Si se considera que no hay pérdidas de calor, la evolución de la entalpía del fluido en función de la coordenada z se expresa mediante la ecuación 3.2.

$$h(z) = h_{\text{inlet}} + \frac{\pi D}{\dot{m}} \int_0^z q'' dz'. \quad (3.2)$$

Por otro lado, el título termodinámico de equilibrio se relaciona con la entalpía según la ecuación 3.3.

$$x(z) = \frac{h(z) - h_f}{h_{fg}}. \quad (3.3)$$

Si $q'' = \text{cte}$, como ocurre tanto en los ensayos de un tubo como en los del bundle de la CNA-UII, al reemplazar la ecuación 3.2 en la 3.3 se obtiene la ecuación 3.4,

$$x(z) = x_{\text{inlet}} + \frac{\pi D q'' z}{\dot{m} h_{fg}}, \quad (3.4)$$

por lo que el modelo, dado $x(z = 1) = x_{\text{outlet}}$, puede despejar q'' . Esto tiene dos implicancias. En primer lugar, el modelo asume un perfil de flujo de calor constante. En segundo lugar, considera que las variables de entrada corresponden a un estado de CHF. Ninguna de estas dos implicancias es deseable, ya que el modelo no podrá generalizar a los casos de interés, es decir, cuando no se conoce el valor del CHF ni se tiene un perfil de potencia uniforme.

En la bibliografía clásica de CHF existen dos enfoques: el método de sustitución directa (DSM, del inglés *Direct Substitution Method*) y el método de balance de calor (HBM, del inglés *Heat Balance Method*). El DSM tiene como principal hipótesis que el CHF es un fenómeno local, por lo que utiliza directamente variables locales para predecir CHF. Esta hipótesis se ha considerado relativamente válida en el caso del DNB, según sugieren diversos autores [36, 9, 37]. Por otro lado, el HBM, como lo indica su nombre, realiza el balance de calor a partir de las condiciones de entrada al tubo. Groeneveld et al. evaluaron sus tres versiones de las LUT (1986 [38], 1995 [10] y 2006 [2]) mediante ambos métodos y obtuvieron predicciones más precisas con el HBM. Sin embargo, el DSM es el más utilizado en la práctica y el más adecuado para su aplicación en códigos termohidráulicos, como señala Siman-Tov [39]. Esto se debe, por un lado, a su simplicidad y, por otro, a que los ensayos realizados en geometrías reales (de bundle) informan las condiciones promedio, mientras que el CHF ocurre a nivel de subcanal. Las condiciones locales a nivel de subcanal pueden ser estimadas por medio de códigos de subcanales como COBRA3-CP, pero esto agregaría un error de la herramienta de cálculo que sería deseable evitar. Adicionalmente, el DSM es el método utilizado en la estimación de CHF para el bundle de la CNA-UII, por medio de las LUT 1995 y los TMF de INVAP.

Por otra parte, se debe considerar un detalle importante de los ensayos realizados en la Universidad de Columbia. La mayoría de estos ensayos se llevó a cabo en agua liviana (H_2O), pero una serie de ellos se realizó en agua pesada (D_2O), el fluido de trabajo de la CNA-UII. Esto impone la necesidad de traducir los ensayos a un único fluido. Debido a que tradicionalmente los ensayos se han hecho con agua liviana con vistas a reactores PWR (del inglés *Pressurized Water Reactors*), y que los ensayos en un tubo se realizaron con agua liviana, la práctica habitual es escalar el ensayo de agua pesada a agua liviana. Luego, la predicción de CHF para agua liviana se debe escalar a agua pesada, para poder predecir las condiciones dentro del reactor. En este trabajo se adoptó el mismo criterio. El escaleo de propiedades entre fluidos depende del fenómeno estudiado. En particular, para CHF se utiliza la regla de Ahmad [40]. Esta regla propone cuatro números adimensionales a conservar entre el fluido “prototipo” y el fluido “modelo”, como se muestra en la ecuación 3.5.

$$\begin{cases} (\Psi_{\text{CHF}})_{\text{prototipo}} = (\Psi_{\text{CHF}})_{\text{modelo}} , \\ (\Delta H/\lambda)_{\text{prototipo}} = (\Delta H/\lambda)_{\text{modelo}} , \\ (\rho_L/\rho_V)_{\text{prototipo}} = (\rho_L/\rho_V)_{\text{modelo}} , \\ (L/D)_{\text{prototipo}} = (L/D)_{\text{modelo}} . \end{cases} \quad (3.5)$$

En estas expresiones, ΔH es el subenfriamiento a la entrada, λ es el calor latente de vaporización, ρ_L y ρ_V son las densidades de las fases líquida y vapor, respectivamente, L es el largo de la sección de ensayo, D es el diámetro de la sección de ensayo, y Ψ_{CHF} es el número adimensional propuesto específicamente para CHF por Ahmad, expresado en la ecuación 3.6,

$$\Psi_{CHF} = \left[\left(\frac{G D}{\mu_L} \right) \cdot \left(\frac{\mu_L^2}{\sigma D \rho_L} \right)^{2/3} \cdot \left(\frac{\mu_V}{\mu_L} \right)^{1/5} \right], \quad (3.6)$$

donde G es el flujo másico por unidad de área, μ_L y μ_V son las viscosidades dinámicas de las fases líquida y vapor, respectivamente, y σ es la tensión superficial. Esta regla se encuentra implementada en un código de Python, por medio de la función `scaling_ahmad()`. El sistema implícito planteado se resuelve mediante la herramienta `scipy.optimize.fsolve`.

Al aplicar una arquitectura de red neuronal de multifidelidad, el pipeline se divide en dos: uno para entrenar la DNN de baja fidelidad a partir de los datos de ensayos en tubo, y otro para entrenar la PINN de alta fidelidad con los datos de los ensayos de la Universidad de Columbia y sus correspondientes simulaciones en COBRA3-CP.

Como se mencionó en la sección 2.2, los datos de ensayos en tubo proveen las siguientes variables: diámetro, longitud, presión a la salida, flujo másico, título termodinámico a la salida, entalpía a la entrada, flujo de calor y temperatura de entrada. De estos, se utilizaron la presión a la salida p , el flujo másico G , el título termodinámico a la salida x y el cociente entre la longitud y el diámetro LD .

Para el pipeline de alta fidelidad, de las simulaciones de COBRA3-CP se extrajo, en cada nodo axial, para cada subcanal y en promedio en el bundle, diferencia de presión respecto de la salida (en bar), entalpía (en kJ/kg), temperatura (en $^{\circ}\text{C}$), título termodinámico, fracción de vapor, caudal másico (en kg/s) y flujo másico (en $\text{kg/m}^2\text{s}$). Luego se realizó un aumento de datos en cada uno de los nodos. Se agregó la siguiente información:

- Presión en el nodo, ya que se debe evaluar en condiciones locales.
- Distancia axial al último separador adimensionalizada (z_{sep_adim}), para que la red pueda tener en cuenta el efecto del separador.
- Desbalance entre título local y título promedio del bundle ($x_{disbalance}$), para que la red pueda contemplar que un subcanal con alto título rodeado de subcanales fríos retrasa el DNB gracias a la transferencia lateral de masa.
- Factor de pico máximo del subcanal (f_{pico}), ya que no todos los subcanales están expuestos a la misma potencia.
- Relación entre perímetro calefaccionado y mojado del subcanal (p_{heat_wet}), para distinguir entre distintos tipos geométricos de subcanal.
- Derivadas respecto de la posición axial de la presión, la entalpía, la temperatura, el título termodinámico y el flujo másico, que se utilizan para la formulación de pérdida informada por física en la PINN.

A continuación, se describe la metodología para obtener cada una de estas variables. La presión en cada nodo resultó de sumar la diferencia registrada en ese

punto al valor a la salida. La distancia al último separador se obtuvo al adimensionalizar la posición axial del nodo con la longitud total y buscar el separador más próximo aguas arriba, a partir de las ubicaciones relevadas en la sección de ensayo [27]. El desbalance de título surgió de restar, al valor local del nodo, el promedio del bundle a la misma altura. Los factores de pico provienen también de [27]: a cada subcanal se le asignó el máximo al que está expuesto, es decir, el de la corona de barras más exterior con la que limita. Por último, la relación entre perímetro calefaccionado y mojado se extrajo de las entradas de COBRA3-CP, que la definen por tipo de subcanal, y se replicó en todos los nodos correspondientes.

Las derivadas de las variables mencionadas respecto de la coordenada axial se calcularon por medio de la función `numpy.gradient`, que calcula de forma numérica el gradiente de un `numpy.array` dado respecto de otro, evaluado en los valores de este último.

El vector final de features de la `HFPINN` contiene las mismas features que la `LFDNN` y, además, la predicción de la `LFDNN`, `z_sep_adim`, `x_disbalance`, `f_pico` y `p_heat_wet`.

Ya que la red de multifidelidad realiza predicción tanto con la red de baja fidelidad como con la de alta fidelidad a partir de las mismas entradas, las redes deben entrenarse a partir de datos escalados de la misma manera. En la figura 3.5 se comparan los gráficos de densidad de probabilidad correspondientes a los datos de ensayos de un tubo y a los puntos obtenidos mediante simulaciones con COBRA3-CP. La comparación se realiza para las cuatro variables de mayor interés: flujo másico, presión, temperatura y título termodinámico. Se observa que los puntos de las simulaciones de COBRA3-CP presentan un mayor sesgo hacia flujos másicos elevados. Los valores de presión se encuentran concentrados alrededor de las 5 presiones de ensayo distintivas. La temperatura, por su parte, se concentra en valores elevados. Por último, el título termodinámico tiene una distribución más concentrada en valores menores a 0. Esto es esperable al considerar todos los puntos de la sección ensayada, a la que ingresa líquido subenfriado. Los casos de ensayos de un tubo presentan distribuciones casi uniformes en presión y temperatura.

Entonces, se combinaron los tensores de entrenamiento de los ensayos de un tubo y de las simulaciones de COBRA3-CP para conformar el `StandardScaler`. Las features adicionales que utiliza la red de alta fidelidad se escalan independientemente, por medio de un `StandardScaler`. En el valor del CHF también pueden existir diferencias importantes, por lo que se realiza un escaleo independiente de las distribuciones, mediante la aplicación del logaritmo natural.

Para la aplicación final del modelo, se debe agregar un factor de corrección por perfil de potencia no uniforme. Este factor toma distintas formas en la bibliografía, como el propuesto por Groeneveld [38] o por Tong [9]. Para mantener consistencia respecto de la metodología actual, se utilizó el de Groeneveld, que se computa según la ecuación 3.7,

$$K_5 = \begin{cases} \frac{\bar{q}}{q_{\text{local}}} & x > 0 \\ 1 & x < 0 \end{cases}. \quad (3.7)$$

Es evidente que, en el caso de flujo uniforme, $K_5 = 1 \forall x$.




FIGURA 3.5. Comparativa de distribuciones de datos de flujo másico, presión, temperatura y título termodinámico entre ensayos de un tubo de Groeneveld y todos los puntos de los ensayos numéricos con COBRA3-CP.

3.2.2. Arquitectura del modelo

Como se explicó en la sección 2.1, el modelo planteado es una red de multifidelidad informada por física, denotada $MFP\ INN$. La $MFP\ INN$ está compuesta por dos redes, una de baja fidelidad y otra de alta fidelidad. La de baja fidelidad es entrenada para predecir CHF en geometría de tubo, a partir de los datos crudos de las LUT de Groeneveld, y se la denota $LFDNN$. Esta, en principio, no incorporaba información física, ya que se dispone de una gran cantidad de datos y se estimaba que un enfoque puro sobre ellos era suficiente. Al entrenar esta red y probar su generalización sobre el conjunto de datos obtenidos de COBRA3-CP al replicar los ensayos de la Universidad de Columbia, se obtuvo un comportamiento no físico para condiciones subenfriadas. Esto se rastreó a la nula representación de condiciones subenfriadas a las presiones y L/D_h de interés en el conjunto de entrenamiento. Este análisis se aborda en detalle en la sección 4.2.1. Por lo tanto, se decidió aplicar una condición de monotonicidad de la derivada del CHF con el título termodinámico. Luego la pérdida quedó descrita por la ecuación 3.8,

$$\mathcal{L} = \text{MSE}(\log \text{CHF}) + \lambda \cdot \frac{1}{\sum w} \sum_i \left[w_i \text{ReLU} \left(\frac{\partial \log \text{CHF}}{\partial x} \Big|_i \right) \right]^2. \quad (3.8)$$

Cabe notar que se tiene $\log \text{CHF}$, el valor predicho por la red. El término w_i corresponde a la máscara de la condición de monotonicidad sobre los puntos de colocación, para ser aplicada solo en el rango $x < 0$ y en las condiciones de trabajo de interés. Los puntos de colocación aplicados corresponden a presiones y relaciones L/D_h del conjunto de datos de COBRA3-CP.

Por otro lado, la componente de alta fidelidad utiliza información física y se la denota HF PINN . Los datos para su entrenamiento son las simulaciones con COBRA3-CP de los ensayos experimentales de la Universidad de Columbia. En la figura 3.6 se presenta un esquema de la arquitectura descrita de la MF PINN .




FIGURA 3.6. Esquema de la arquitectura de red neuronal de multifidelidad informada por física.

La HF PINN entrena con los datos de las simulaciones con COBRA3-CP. Cada una de ellas provee datos en 151 nodos axiales y 60 subcanales, para un total de 9 060 datos por ensayo. Por otro lado, la información provista por los ensayos de Columbia contiene un dato por ensayo, correspondiente al punto desconocido en el que comienza el DNB. Se tiene entonces un desajuste de dimensionalidad entre el producto de la red al evaluar en los ensayos numéricos y lo medido en los ensayos reales, expuesto en la ecuación 3.9.

$$\underbrace{\mathbf{y} \in \mathbb{R}^{9060}}_{\text{campo predicho}} \longrightarrow \underbrace{\hat{\mathbf{y}} \in \mathbb{R}}_{\text{campo medido}}. \quad (3.9)$$

La flecha en la ecuación 3.9 es la reducción de dimensionalidad que se debe hacer antes de poder comparar contra los datos experimentales. La elección natural es el mínimo, ya que el DNB ocurre en el nodo más limitante del bundle. Pero, en cuanto a la optimización numérica, la utilización del mínimo es poco eficiente, e

incluso puede hacer imposible el entrenamiento de un modelo de red neuronal, ya que el mínimo genera un gradiente one-hot, como se expone en la ecuación 3.10.

$$\frac{\partial}{\partial y_j} \min_i y_i = \begin{cases} 1 & \text{si } j = \arg \min_i y_i \\ 0 & \text{en caso contrario} \end{cases}. \quad (3.10)$$

De esta forma el optimizador solo recibe información del punto mínimo. Adicionalmente, al comenzar el entrenamiento, el punto que resulta mínimo es completamente aleatorio, por lo que es muy fácil condicionar negativamente la red y que esta no pueda salir del mínimo inicial.

Se planteó entonces utilizar un enfoque de mínimo suave o softmin, que permita utilizar una mayor cantidad de nodos para el aprendizaje. Un enfoque similar es el promedio ponderado o *attention pooling*, propuesto por Ilse [41] en el contexto de MIL (del inglés *Multiple Instance Learning*). Se propuso utilizar el softmin expuesto en la ecuación 3.11,

$$\text{softmin}_\tau(\mathbf{y}) = \sum_i w_i y_i, \quad (3.11)$$

donde w_i son los pesos para ponderar las distintas predicciones. En el trabajo de Ilse los pesos se aprenden con una red de atención aparte, pero en este trabajo se utiliza el propio campo predicho, a través de la función softmax de Bridle [42] y el parámetro de temperatura propuesto por Hinton, Vinyals y Dean [43], según la ecuación 3.12.

$$w_i = \text{softmax} \left(-\frac{\mathbf{y}}{\tau} \right)_i. \quad (3.12)$$

De esta forma, los nodos con baja predicción se ponderan con un mayor peso que los nodos con predicciones altas. El sesgo de esta concentración es controlado por el parámetro de temperatura τ , que se obtiene a partir del desvío estándar del vector de predicción, según la ecuación 3.13.

$$\tau = \alpha \cdot \text{std}(\mathbf{y}). \quad (3.13)$$

El parámetro α permite controlar la temperatura con la evolución del entrenamiento y se lo controla por medio de un recocido o annealing, que lo recorre geométricamente desde α_0 hasta α_f .

Para evaluar si la temperatura τ a la que converge el entrenamiento es o no correcta, se debe analizar sobre cuántos nodos se promedia realmente. Para ello, se computa el número efectivo de nodos, que se define como la exponencial de la entropía de los pesos, presentada en la ecuación 3.14.

$$N_{\text{eff}} = \exp \left[- \sum_i w_i \log(w_i) \right]. \quad (3.14)$$

Esta definición es el número de Hill de orden 1 [44], la forma estándar de obtener un conteo efectivo a partir de una entropía. Si el entrenamiento es satisfactorio, N_{eff} debe ser menor a 5 hacia el final del entrenamiento.

Esta metodología, además de solucionar el problema del gradiente one-hot, tiene la ventaja de estar acotada superiormente por la media de la predicción, al ser una combinación convexa de los y_i . Esto asegura que el valor predicho sea un valor físicamente válido y sin sesgo dependiente de la cantidad de nodos utilizados.

En cuanto a la información física que se le brinda a la HFP_{INN} , se debe notar que no es posible hacer un planteo tradicional de PINN que provea una ecuación diferencial de conservación de alguna cantidad como función de pérdida. Esto es así puesto que la variable a predecir, el CHF, no responde a una ecuación de conservación, sino que es una propiedad del estado termodinámico y la geometría. Se podría realizar el ejercicio de proveer a la red de, por ejemplo, la ecuación de conservación de la energía. Esto haría que la red aprendiera que, siempre que reciba un set de datos locales, estos corresponden a una condición de CHF, ya que la red fue entrenada con casos en que se tiene DNB. Pero en el campo de aplicación del modelo, se busca estimar el CHF sin estar en DNB.

Se plantearon entonces distintos tipos de ecuaciones diferenciales a satisfacer por el modelo. Se implementaron las siguientes relaciones:

- Monotónicas, presentadas en la ecuación 3.15,

$$\frac{dCHF}{di} \leq 0. \quad (3.15)$$

- De derivada cruzada, presentadas en la ecuación 3.16,

$$\frac{d^2 CHF}{di dj} \leq 0. \quad (3.16)$$

- De convexidad, presentadas en la ecuación 3.17,

$$\frac{d^2 CHF}{di^2} > 0. \quad (3.17)$$

Se partió de ciertas hipótesis sobre las relaciones a aplicar, basadas en conceptos básicos de transferencia de calor y masa. Como relaciones monotónicas se propuso una dependencia positiva con el flujo másico, y negativa con el título termodinámico y con la presión.

Para verificar el uso correcto de estas relaciones y su cumplimiento en el rango de aplicación, se utilizaron los datos de los ensayos en un tubo como evidencia fundamental o ground truth. En las figuras 3.7, 3.8 y 3.9 se presentan las tendencias del CHF con el flujo másico, el título termodinámico y la presión, respectivamente. Al analizar la relación con el flujo másico, se evidencia en la figura 3.7 que la tendencia no es positiva en todo el rango. Se observa una tendencia negativa para títulos termodinámicos mayores a 0,15 hasta aproximadamente 3 000 kg/m²s. Entonces, se modificó la relación propuesta inicialmente para ser negativa en el rango de $x > 0,15$ y $G < 3\,000$ kg/m²s, y positiva en el resto del dominio.

Luego, en la figura 3.8 se evidencia la clara tendencia negativa del CHF con el título termodinámico. Por último, en la figura 3.9 se observa que, en el rango de operación de los ensayos con presiones mayores a 60 bar, se tiene una tendencia decreciente del CHF con la presión.

Se implementó una relación negativa con la derivada cruzada respecto del flujo másico y el título termodinámico, fundamentada en que a mayor flujo másico, la caída del CHF con el título termodinámico es más pronunciada. Esto es consistente con la bibliografía y lo observado en la figura 3.8.




FIGURA 3.7. Tendencia del CHF con el flujo másico, para los datos de los ensayos en un tubo recopilados por Groeneveld [1, 2].

En cuanto a la relación de convexidad, se planteó una derivada segunda positiva del CHF respecto del título termodinámico para la zona de alto título ($x > 0,2$). Esta relación es consistente con la bibliografía y se puede ver en la figura 3.8. Si bien de la figura 3.5 puede afirmarse que hay pocos datos en esa región, esta restricción es útil en puntos de colocación para asegurar que el modelo no obtenga resultados indeseados al extrapolar fuera de los datos de entrenamiento.

La evaluación de este conjunto de ecuaciones diferenciales se realizó sobre un set de datos independiente, tradicionalmente llamado puntos de colocación. Se formó un espacio de puntos de colocación con los límites inferiores y superiores de cada variable, y se expandió cada uno en un 10 % de la media de la variable. De esta forma el espacio permitió evaluar la extrapolación del modelo por fuera de los datos rotulados. Se estableció el doble de puntos de colocación que de observaciones de simulaciones de COBRA3-CP, lo que resultó en un total de 2 645 520 puntos.




FIGURA 3.8. Tendencia del CHF con el título termodinámico, para los datos de los ensayos en un tubo recopilados por Groeneveld [1, 2].

La pérdida total entonces se compone de las componentes de la ecuación 3.18,

$$\mathcal{L} = \mathcal{L}_{\text{data}} + \lambda_{\text{mon}} \sum_i \mathcal{L}_{\text{mon},i} + \lambda_{\text{cruz}} \mathcal{L}_{\text{cruz}} + \lambda_{\text{convex}} \mathcal{L}_{\text{convex}}, \quad (3.18)$$

donde los λ son los factores de peso de las PDE. Estos se optimizaron para obtener resultados que respeten las relaciones postuladas por fuera del rango de operación de los ensayos experimentales.

Para el entrenamiento del modelo, en primer lugar se entrena la LFDNN con sus datos. Su entrenamiento es estándar y puede realizarse con optimizador Adam y métrica MSE. Luego, con los pesos de la LFDNN congelados, se entrena la HFPINN con la estructura completa de la MFPINN . Se realizaron pruebas para determinar si era necesario, debido a las restricciones tipo PINN, un optimizador de segundo orden como L-BFGS [45]. Sus resultados se exponen en el capítulo 4.




FIGURA 3.9. Tendencia del CHF con la presión, para los datos de los ensayos en un tubo recopilados por Groeneveld [1, 2].

3.2.3. Evaluación del modelo

Para la evaluación del modelo se utilizaron métricas estadísticas tradicionales en conjunto con otras particulares del problema. Las primeras son el MSE, el RMSE y el coeficiente de determinación R^2 .

En cuanto a las métricas específicas del problema, se utilizó el $DNBR_{min}$ del diseño termohidráulico de la CNA-UII, explicado en detalle en [3, 46]. Este es el valor para el que, si la predicción de DNBR está por encima, se asegura con 95 % de probabilidad y confianza que no se tiene DNB. Se define según la ecuación 3.19,

$$DNBR_{min} = \overline{DNBR} + k_{95} \cdot \sigma(DNBR), \quad (3.19)$$

donde DNBR son las predicciones en las condiciones de los ensayos de la Universidad de Columbia y k_{95} es el intervalo de tolerancia de una distribución normal para asegurar 95 % de probabilidad y confianza según la cantidad de observaciones [47, 48]. Es importante destacar que el cómputo de esta métrica tiene dos hipótesis: que la distribución es normal y que está centrada. Esto último se debe

asegurar por medio de un factor de centrado.

Otro criterio utilizado para evaluar el modelo fue la evolución predicha de CHF en función de las distintas variables. Esto no se restringe únicamente a las variables de entrenamiento del modelo, sino que también es importante verificar la evolución predicha de CHF respecto de la longitud axial. Además, la predicción de la ubicación del punto más limitante de la sección de ensayo para una dada condición debe ubicarse sobre el final de esta. Esto permite afirmar que el modelo realiza una predicción con sentido físico.

Capítulo 4

Ensayos y resultados

En este capítulo se presentan los resultados de los estudios realizados sobre los modelos de predicción de PLC y CHF.

4.1. Estimación de PLC

A continuación, se presentan los resultados para el modelo de estimación de PLC: la optimización de hiperparámetros, las predicciones de DNBR y fracción de vacío del mejor modelo y la estimación de PLC por ambos criterios.

4.1.1. Optimización de hiperparámetros

Como se mencionó en la sección 3.1.2, la optimización de hiperparámetros se realizó por medio de la biblioteca Optuna. Las métricas objetivo se establecieron por separado para cada criterio. Para el DNBR se utilizó el error porcentual medio, mientras que para la fracción de vacío se usó el error absoluto medio escalado 100 veces. Esta decisión se tomó al considerar que la fracción de vacío tiene valor exactamente igual a 0 para un porcentaje importante de los datos y con el objetivo de lograr una contribución equitativa de ambos criterios al rendimiento del modelo. De esta forma, se obtiene un único modelo con error similar en ambos criterios y se evita entrenar uno por cada uno de ellos.

La figura 4.1 muestra los resultados durante el proceso de optimización, mientras que la arquitectura final se resume en la tabla 4.1.

TABLA 4.1. Hiperparámetros de la arquitectura final.

Hiperparámetro	Valor
Cantidad de capas ocultas	3
Cantidad de neuronas por capa	478
Learning rate	$1,38 \cdot 10^{-4}$
Batch	64
Función de activación	ReLU




FIGURA 4.1. Resultados de los distintos intentos de la optimización.

4.1.2. Resultados de DNBR y fracción de vacío

En esta sección, se evalúan los resultados del modelo en cuanto a la predicción de DNBR y fracción de vacío. En la figura 4.2 se presentan los gráficos de valores predichos contra reales, para los conjuntos de test y train. Se observa una buena predicción del modelo en ambos objetivos y una distribución equivalente entre conjuntos. No obstante, se aprecia una tendencia a subestimar la fracción de vacío en la región cercana a 25 %.

En la tabla 4.2 se presentan la media y el desvío estándar del error con signo para cada objetivo. El error con signo se define como la diferencia entre el valor real y el predicho, por lo que valores positivos de la media implican una subpredicción del objetivo, y los negativos una sobrepredicción. Para la fracción de vacío, se aplica un factor de 10 para que las magnitudes entre objetivos sean comparables. Se observa una tendencia a subpredecir DNBR y a sobrepredir la fracción de vacío, ambas tendencias en igual magnitud en train y test. Los desvíos estándar son menores en test que en train para DNBR, y a la inversa para la fracción de vacío. En ambos casos, los valores de desvío estándar son bajos.

La tendencia general de la predicción de vacío es a sobrepredir, mientras que el gráfico de predicho contra real indica lo contrario. Para analizar esta discrepancia, se realizó el mismo cálculo del error al dividir en 5 regiones el dominio de cada variable objetivo. Los resultados se presentan en la tabla 4.3. Se obtiene, para DNBR, una media aún más baja en la región de interés (1,7 – 2,5) y una subpredicción general del DNBR, lo que representa una tendencia conservativa. En cuanto a la fracción de vacío, no se tiene el mínimo de error en la zona de interés, sino alrededor de ella. En la zona de interés (0,15 – 0,35) se tiene una sobrepredicción de la fracción de vacío, también una tendencia conservativa. Se puede concluir entonces que el modelo tiene un buen rendimiento en ambos objetivos y tendencias conservativas respecto de las referencias.

Como se explicó en la sección 3.1.1, se filtraron los datos disponibles para entrenar en la región de interés en ambas variables objetivo. El filtro conservó los valores de MDNBR entre 1,7 y 2,5, o de fracción de vacío entre 15 % y 35 %. Por




FIGURA 4.2. Resultados de predicción de DNBR y fracción de vacío, para los conjuntos de test y train.

TABLA 4.2. Media y desvío estándar del error con signo para cada objetivo.

Conjunto	DNBR		Fracción de vacío	
	media	σ	media	σ
Train	-0,006	0,021	0,018	0,040
Test	-0,006	0,017	0,018	0,032

ello, resulta de interés evaluar la precisión del modelo por fuera de la región de entrenamiento. En la figura 4.3 se presentan las predicciones comparadas con los valores reales, para MDNBR y fracción de vacío. En primer lugar, se evidencia la dificultad del modelo para predecir en las regiones excluidas del entrenamiento, algo esperable en una arquitectura DNN. Luego, para DNBR se observa un comportamiento correcto en valores inferiores a los de interés, pero una tendencia a subpredecir al aumentar. Si bien esto podría interpretarse generalmente como un resultado desfavorable, se puede considerar que el modelo entrega predicciones conservativas fuera de su zona de entrenamiento y brinda seguridad en su aplicación. Por último, para la fracción de vacío, por debajo de la zona de interés se observan predicciones menores a 0, lo que constituye un resultado no físico. Se podría realizar un clipping de la predicción para que los valores negativos se conviertan en 0, lo que daría un buen rendimiento por debajo de la zona de entrenamiento. Por encima de la zona de entrenamiento, se puede observar en primer lugar una tendencia a subpredecir hasta 60 % y luego una sobrepredicción.

TABLA 4.3. Media y desvío estándar del error con signo para cada objetivo, segmentado por rangos de cada objetivo.

Objetivo	Rango	Conjunto			
		Train		Test	
		media	σ	media	σ
DNBR	< 1,7	0,003	0,004	0,000	0,008
	1,7 – 2,5	–0,001	0,009	–0,001	0,013
	2,5 – 3,5	–0,013	0,013	–0,015	0,019
	3,5 – 5	–0,044	0,038	–0,042	0,051
	> 5	–0,051	0,039	–0,015	0,076
Fracción de vacío	0	–0,035	0,033	0,061	0,037
	0 – 0,15	0,013	0,021	0,010	0,032
	0,15 – 0,35	0,024	0,036	0,025	0,044
	0,35 – 0,6	0,007	0,021	0,007	0,027
	> 0,6	0,031	0,022	0,024	0,014

Para cuantificar el aumento del error en el conjunto excluido, la figura 4.4 presenta los errores para cada variable objetivo en los conjuntos de train, test y excluidos. Tal como se comentó previamente, los conjuntos de train y test presentan errores muy similares, y el conjunto excluido un error considerablemente mayor. Adicionalmente, se grafican los cuantiles del 5 % y 95 %, que evidencian que el conjunto de excluidos también tiene una dispersión mucho mayor en su error.




FIGURA 4.3. Resultados de predicción de DNBR y fracción de vacío, para el conjunto excluido.




FIGURA 4.4. Distribución del error para cada objetivo, por conjunto de datos.

4.1.3. Estimación de PLC por DNBR y fracción de vacío

La evaluación del modelo realizada hasta aquí responde a su capacidad de estimar el mínimo DNBR y la fracción de vacío a la salida de un canal refrigerante, dadas sus condiciones termohidráulicas y distribuciones de potencia. Sin embargo, este no es el objetivo último del modelo, sino que se debe estimar la PLC por DNBR y fracción de vacío. Esto responde a un lazo de cálculo iterativo, explicado en detalle en la sección 3.1.3. A continuación, se analiza el comportamiento del modelo en dicho escenario, por medio del criterio del factor de ajuste F_{PLC} explicado en la sección 3.1.5.

Para esta evaluación, se utilizaron 100 estados del reactor correspondientes a una estrategia de recambio de elementos combustibles de la CNA-UII, con un total de 43 811 simulaciones. El cálculo de las PLC se realizó con COBRA3-CP según la metodología tradicional, para obtener los valores de referencia y los tiempos requeridos en este tipo de cálculos.

En la figura 4.5 se presentan los resultados, segmentados por ZH, para la versión base de la DNN y con la corrección por F_{PLC} . En la tabla 4.4 se observan los valores de media y desvío estándar para el cociente entre el valor predicho y el real, y el F_{PLC} , factor de ajuste para asegurar con 95 % de probabilidad y confianza que la PLC predicha está por debajo de la real. Los tres valores se encuentran segmentados por ZH y para los criterios de DNBR y fracción de vacío.

Se observa un buen desempeño, especialmente para las ZZHH 4 y 5, donde la nube de puntos azul, correspondiente a la DNN sin corregir, se encuentra muy cerca de la recta identidad. Para las ZZHH 1 a 3, el desempeño es inferior, aunque los resultados se encuentran dentro de parámetros aceptables. Este comportamiento resulta esperable, ya que en el conjunto de datos de entrenamiento la representación de las ZZHH era equivalente a la cantidad de canales de cada una en el reactor, distribución que es muy despareja. Esto también se evidencia en los valores de media y desvío estándar del cociente predicho-real. La media y el desvío estándar son decrecientes de ZH 1 a 5, con un valor casi unitario en la última. Los factores de ajuste muestran una mayor sobreestimación de las PLC en las ZZHH periféricas.

Debe tenerse en cuenta que para las ZZHH 1 a 3 el límite siempre se obtiene por fracción de vacío. Por lo tanto, el error en predicción de DNBR no es un problema, y el buen rendimiento en fracción de vacío hace al modelo apto para predecir en estas ZZHH. La ZH 4, en este caso, también está limitada por vacío, por lo que se le puede aplicar la misma conclusión.

En la tabla 4.5 se presenta un resumen de los tiempos de cómputo para el cálculo de PLC. Los resultados son contundentes: la mejora o speedup del proceso de cálculo alcanza una media de entre 8 409 y 9 519 para DNBR, y de entre 2 197 y 2 486 para fracción de vacío. El tiempo total de cómputo pasó de las 380 h con COBRA3-CP a alrededor de 4 minutos con la DNN. Esto sustenta el valor de este modelo, que no solo logra una predicción de las PLC con un error acotado, sino que además requiere un tiempo de cómputo varios órdenes de magnitud inferior. Por otra parte, no se implementaron lógicas adicionales para lograr un cómputo más eficiente por medio de la DNN, como el procesamiento en batch. Se computaron todos los casos en serie, tanto en CPU como en GPU. Estos aspectos representan oportunidades de mejora, como se explica en el capítulo 5.

TABLA 4.4. Media y desvío estándar de cociente predicho-real, y factor de 95 % de probabilidad y confianza. Por zona hidráulica.

Zona Hidráulica	DNBR			Fracción de vacío		
	media	σ	F	media	σ	F
1	1,047	0,015	0,933	1,008	0,004	0,985
2	1,025	0,010	0,961	1,003	0,002	0,993
3	1,018	0,010	0,967	1,002	0,002	0,995
4	1,003	0,003	0,991	1,001	0,002	0,996
5	1,001	0,002	0,995	1,001	0,001	0,997

TABLA 4.5. Tiempos de cómputo para cálculo de PLC.

		Tiempo		Mejora	
		COBRA3-CP [s]	DNN [ms]		
			CPU	GPU	CPU GPU
DNBR	mínimo	8,53	0,28	0,47	3 562 406
	media	25,16	2,66	3,03	9 519 8 409
	máximo	137,95	5,88	5,51	57 882 48 363
	total	306 h	117 s	130 s	9 445 8 503
Fracción de vacío	mínimo	1,07	0,21	0,33	432 405
	media	6,09	2,46	2,80	2 486 2 197
	máximo	14,70	5,70	6,69	5 955 5 385
	total	74 h	108 s	120 s	2 479 2 224

Por último, en la tabla 4.6 se observan los márgenes de potencia perdidos al aplicar la predicción de DNN. Es decir, la diferencia porcentual de potencia entre el valor de referencia y el predicho, corregido por F_{PLC} . Se presentan los valores de margen medio y de margen máximo. Luego se computa el total como el promedio ponderado por la cantidad de canales que pertenecen a cada ZH. Se obtuvieron valores decrecientes de la ZH 1 a la 5 tanto por DNBR como por fracción de vacío, a excepción de la ZH 3, que presenta el valor máximo de margen perdido por




FIGURA 4.5. Resultados de estimación de PLC por DNBR y fracción de vacío con factor de corrección, por zona hidráulica.

DNBR. Los valores máximos en las zonas periféricas resultan altos, aunque dentro de los porcentajes de margen tomados como criterio de seguridad al calcular una estrategia de recambio de combustibles. Es importante tener en cuenta que las ZZHH 1 a 4 están actualmente limitadas por fracción de vacío, y la ZH 5 por DNBR.

Finalmente, los márgenes perdidos totales medios son del 0,7 % para DNBR y 0,5 % para fracción de vacío. Esto expresa la capacidad del modelo de predecir con precisión y seguridad la PLC, sin un resultado demasiado conservativo. Además, debe tenerse en cuenta que las zonas periféricas operan con un importante margen, muy superior al perdido por la utilización del modelo para fracción de vacío. Por lo tanto, el margen expuesto como perdido en rigor no se pierde.

TABLA 4.6. Margen perdido medio y máximo por utilizar DNN, según zona hidráulica y total.

Zona Hidráulica	Margen perdido [%]			
	DNBR		Fracción de vacío	
	medio	máximo	medio	máximo
1	1,56	4,56	2,58	5,22
2	1,35	4,29	1,05	2,28
3	1,88	5,37	0,74	1,87
4	0,58	2,12	0,41	1,25
5	0,38	1,37	0,24	0,89
total	0,71	2,34	0,54	1,45

4.1.4. Aplicación de embeddings

Como se explicó en la sección 3.1.4, se aplicó una arquitectura de autoencoder para obtener el espacio latente de los perfiles de potencia axial y por barras. La arquitectura empleada fue simple, ya que esta tarea no requiere una red densa. Se optó por un encoder con 2 capas ocultas, la primera de 64 neuronas y la segunda de 32. El decoder, por su parte, es el espejo del encoder.

Se buscó el espacio latente de menor dimensión tal que la reconstrucción del vector de entrada en el conjunto de entrenamiento tuviera un coeficiente de determinación $R^2 > 0,99$. El proceso de cálculo recorrió desde un espacio latente de dimensión 1 hasta la primera dimensión que cumpliera con la condición establecida. Para el entrenamiento se utilizó el mismo conjunto de datos que para el estimador de PLC.

Para ambos perfiles de potencia se obtuvo un espacio latente de 3 dimensiones. En la figura 4.6 se presentan, para cada componente del espacio latente, los 3 perfiles con mayor valor de la componente, los 3 con valores medianos y los 3 con menor valor. La primera componente puede interpretarse como el clásico factor de forma de los perfiles axiales, donde los perfiles de menor valor corresponden a la forma típicamente llamada “panza arriba”. La segunda componente tiene un significado similar; se asocia con perfiles cuya zona inferior o superior está aplanada. Por último, la tercera componente representa potencia disminuida en el centro del perfil.




FIGURA 4.6. Gráficos de perfiles axiales con valores más altos, medianos y bajos de cada componente del espacio latente.

En la figura 4.7 se presenta el gráfico análogo para el perfil por barras. En este caso, resulta más difícil obtener una explicación de cada componente.




FIGURA 4.7. Gráficos de perfiles radiales con valores más altos, medianos y bajos de cada componente del espacio latente.

Una vez entrenado el encoder, se evaluó la arquitectura del predictor de PLC, pero con el espacio latente de los perfiles de potencia como entradas. Se plantearon tres modelos, que utilizan el espacio latente del perfil axial, el del perfil por barras y ambos espacios latentes. En la tabla 4.7 se presentan la media y el desvío estándar del error con signo, para los tres modelos con embeddings y el modelo base. Los tres modelos presentan una reducción de la media del error en ambas variables objetivo. En cuanto al desvío estándar, para DNBR no se obtiene una reducción significativa, pero para fracción de vacío se reduce a aproximadamente la mitad. Es importante señalar que los modelos con embeddings del perfil por barras y de ambos perfiles presentan una media positiva del error de DNBR. Por otro lado, los tres modelos presentan un error medio negativo para la fracción de vacío. Estos dos puntos son un resultado no conservativo, aunque no de forma excesiva.

En la tabla 4.8 se presenta el margen perdido total para el modelo base y los tres modelos con embeddings. En cuanto al DNBR, solo el modelo con embeddings para el perfil por barras presenta una reducción del margen perdido. Para el margen perdido de fracción de vacío se obtiene una reducción en los tres modelos.

TABLA 4.7. Media y desvío estándar del error con signo para cada objetivo, para modelos con embeddings.

Modelo	Conjunto	DNBR		Fracción de vacío	
		media	σ	media	σ
Base	Train	−0,006	0,021	0,018	0,040
	Test	−0,006	0,017	0,018	0,032
Emb. perfil axial	Train	−0,002	0,018	−0,002	0,021
	Test	−0,001	0,020	−0,002	0,022
Emb. perfil por barras	Train	0,001	0,013	−0,006	0,021
	Test	0,001	0,014	−0,006	0,022
Emb. ambos perfiles	Train	0,000	0,017	−0,011	0,016
	Test	0,000	0,020	−0,010	0,017

Se estima que la reducción del margen perdido en la PLC por DNBR al utilizar el espacio latente del perfil por barras proviene de la elevada dimensión de dicho perfil, en relación con la información que representa. Al reducir su dimensión, la DNN tendría mayor capacidad de centrar recursos en otras variables de entrada.

En el caso de la PLC por fracción de vacío, es sabido que depende de la integral de la energía entregada y no de condiciones locales. Por lo tanto, variables de entrada globales como las componentes del espacio latente presentan una ventaja esperable en su predicción.

TABLA 4.8. Margen perdido medio y máximo por utilizar DNN y embeddings, según zona hidráulica y total.

Modelo	Margen perdido [%]			
	DNBR		Fracción de vacío	
	medio	máximo	medio	máximo
Base	0,71	2,34	0,54	1,45
Emb. perfil axial	0,84	3,05	0,13	0,39
Emb. perfil por barras	0,61	1,83	0,15	0,38
Emb. ambos perfiles	0,99	3,96	0,10	0,40

4.2. Estimación de CHF

A continuación, se analizan los resultados para el modelo de estimación de CHF. En primer lugar, se presenta el modelo predictor de CHF para geometría de tubo, a partir de los datos recopilados por Groeneveld [2, 1]. Esto permite establecer una base sólida sobre la que los modelos de multifidelidad corrigen la estimación para un tubo de forma no lineal.

Luego, se presentan dos análisis respecto de la arquitectura del modelo. Ya que el trabajo propone una superposición de arquitecturas, se evalúa la contribución de cada cambio, con la referencia de un modelo simple y de la metodología actual. Se evalúa en primer lugar la arquitectura de multifidelidad, con la referencia de una implementación de una DNN tradicional. En segundo lugar, se evalúa la implementación de PINN a la red de multifidelidad, con la referencia de la arquitectura de multifidelidad base.

En tercer lugar, se analizan las variables de entrada al modelo, ya que su uso sin evaluación equivale a un modelo de caja negra, que no permite comprender su comportamiento ni su relación con la física del fenómeno. Citando a von Neumann: “Con cuatro parámetros puedo ajustar un elefante, y con cinco puedo hacer que mueva su trompa”¹. Tanto este análisis como los de arquitectura se realizaron con una penalización al modelo: se entrenó sobre casos de caudal alto y se evaluó sobre casos de caudal bajo.

Por último, se define el modelo final, entrenado con una división aleatoria de los datos. Se comparan los valores de $DNBR_{min}$ para las arquitecturas $MFDNN$ y $MFPINN$. Luego se realiza una estimación del impacto de los valores obtenidos con un cálculo de PLC con las condiciones del diseño termohidráulico descriptas en el IFS.

4.2.1. Modelo predictor de CHF en un tubo

Como se comentó en la sección 3.2.2, se construyó un modelo de DNN para predecir el CHF en un tubo. Esta red se utiliza luego como entrada de las $MFDNN$ y $MFPINN$ entrenadas. Es importante notar que, para que los modelos de multifidelidad obtengan información relevante de la estimación en un tubo, esta debe ser confiable y tener valor físico. Por ello, la evaluación de la $LFDNN$ entrenada no se restringe únicamente a estadísticos tradicionales. Para su evaluación se consideran tres categorías principales: su predicción de los ensayos en un tubo, su $DNBR_{min}$ derivado de sus predicciones sobre los ensayos de la Universidad de Columbia y la evolución del CHF predicho en función de los parámetros termohidráulicos. Este último criterio se propuso debido a que redes con arquitecturas muy densas y profundas lograban muy buenos resultados en los primeros dos criterios, pero al mirar en detalle la relación del CHF con los parámetros termohidráulicos se observaban tendencias no físicas.

Entonces, para encontrar una arquitectura óptima resultaba difícil recurrir a una estructura automatizada como Optuna. Se propuso, en cambio, analizar una serie limitada de arquitecturas, para evaluar el impacto del ancho y la profundidad

¹Traducido de la frase original en inglés: “With four parameters I can fit an elephant, and with five I can make him wiggle his trunk” [49].

de la red en los resultados. En la tabla 4.9 se presentan las arquitecturas evaluadas y sus métricas estadísticas. Se evaluó utilizar como función de activación la tangente hiperbólica y la función SiLU. Finalmente, la función SiLU fue la que demostró un comportamiento más estable. Se observa que todos los modelos logran tanto en entrenamiento como en evaluación un $R^2 > 0,95$ y un RMSE menor a 400 kW/m^2 . Los modelos con menos parámetros presentan una menor diferencia entre el RMSE del conjunto de entrenamiento y el de evaluación. Los dos modelos con mayor cantidad de parámetros presentan los mejores valores tanto de R^2 como de RMSE. En vista de estos resultados, se podría considerar que el entrenamiento de todas las redes es satisfactorio.

TABLA 4.9. Arquitecturas de LFDNN propuestas y métricas sobre conjuntos de entrenamiento y evaluación de ensayos en un tubo.

#	Dim. capas ocultas	Cant. capas ocultas	Entrenamiento		Evaluación	
			R^2	RMSE	R^2	RMSE
1	64	2	0,9553	337,9	0,9590	322,0 (+0,8 %)
2	64	3	0,9657	296,1	0,9657	294,3 (+4,2 %)
3	64	4	0,9749	253,0	0,9738	257,3 (+14,2 %)
4	32	3	0,9503	356,0	0,9557	334,6 (+0,3 %)
5	128	3	0,9746	254,9	0,9753	249,9 (+9,6 %)

En la tabla 4.10 se presentan los resultados de las distintas arquitecturas al evaluar sobre el conjunto de datos de los ensayos de Columbia replicados con COBRA3-CP. Se presentan la media y el desvío estándar del DNBR predicho y el $\text{DNBR}_{\min}$. Adicionalmente, se calcularon cuántos casos de los 146 presentaron el valor mínimo de CHF de la sección antes de los 250 cm y cuántos en los subcanales interiores, es decir, no periféricos. Esto se realizó debido a que se tiene conocimiento de que el CHF se presenta al final de la sección de ensayos y que, por cómo modela COBRA3-CP los subcanales, los periféricos son los más comprometidos para el CHF. Entonces, se observa que la arquitectura #4 presenta dos ventajas: tiene la media y el desvío estándar más favorables, y además la menor cantidad de predicciones fuera de la región de salida. En cuanto a predicciones en subcanales internos, se encuentra en la mediana de los modelos evaluados.

TABLA 4.10. Arquitecturas de LFDNN propuestas y métricas sobre ensayos de bundle de la CNA-UII.

#	$\overline{\text{DNBR}}$	$\sigma(\text{DNBR})$	$\text{DNBR}_{\min}$	Z entrada	SCH int.
1	0,651	0,329	1,266	89	10
2	0,687	0,403	1,442	72	6
3	0,512	0,393	1,248	97	26
4	0,949	0,266	1,447	31	16
5	0,864	0,315	1,454	31	30

Luego se procedió a analizar en qué condiciones el modelo predice CHF. En la figura 4.8 se presentan, para el modelo #4, los gráficos de CHF frente a flujo másico y título termodinámico. Los valores de flujo másico y título termodinámico corresponden al punto en ese ensayo en el que el modelo obtuvo el menor CHF. El resultado observado es preocupante. El modelo predice valores muy bajos de CHF para condiciones subenfriadas. Esto es algo definitivamente no físico y un

resultado no deseado. El resto de los modelos presenta un comportamiento similar.

Entonces, se propuso evaluar la generalización del modelo con el flujo másico y el título termodinámico. En la figura 4.9 se presenta este análisis. Se filtraron los datos de entrenamiento de Groeneveld para considerar presiones y relaciones L/D similares a las del conjunto de COBRA3-CP, y luego se muestreó por fuera de los límites de flujo másico y título termodinámico. Los resultados explican fehacientemente por qué se tenía en la figura 4.8 una relación no física, específicamente con el título termodinámico. Los modelos no tienen en su conjunto de entrenamiento datos para condiciones subenfriadas, y su extrapolación en esa zona es hacia valores de CHF bajos. Este comportamiento requiere una corrección.




FIGURA 4.8. Relación del CHF predicho con el flujo másico y el título, según el punto predicho por el modelo $LFDNN$ #4. TRAIN y TEST son los conjuntos de entrenamiento y evaluación correspondientes a la $HFDNN$, divididos tal que en evaluación se tienen los ensayos de menor flujo másico.

Para solventar esta dificultad del modelo en la zona subenfriada se propuso una condición de monotonicidad negativa de la derivada del CHF respecto del título termodinámico, es decir, un modelo de PINN para la $LFDNN$, que se denota $LFPINN$. Esta incorporación se realizó al modificar el cálculo de la función de pérdida, según la ecuación 4.1,

$$\mathcal{L} = \text{MSE}(\log \text{CHF}) + \lambda \cdot \frac{1}{\sum w} \sum_i \left[w_i \text{ReLU} \left(\frac{\partial \log \text{CHF}}{\partial x} \Big|_i \right) \right]^2. \quad (4.1)$$

Los términos w y w_i representan la máscara aplicada por la condición de monotonicidad sobre los puntos de colocación, según en qué región del dominio de las variables de entrada se debe aplicar. En particular, en este caso se diseñó el conjunto de puntos de colocación para la región subenfriada, con valores de presión y L/D_h en los rangos de los ensayos de COBRA3-CP. El término λ es el peso atribuido a la condición de monotonicidad.

Se analizó el impacto de esta implementación en una arquitectura de 64×3 , con la misma metodología que las arquitecturas anteriores. Se entrenaron tres redes,

Generalización: media geométrica de cada modelo sobre el train de Groeneveld (P y L/D en rango COBRA)




FIGURA 4.9. Evaluación de la generalización de la LFDNN respecto del flujo másico y el título termodinámico.

variando el valor de λ entre 0,01, 0,1 y 1. Esto permite evaluar el impacto del grado en que se impone esta condición frente a los datos. En la tabla 4.11 se presenta la comparativa de las métricas estadísticas sobre los conjuntos de ensayos en un tubo. Esto permite verificar que la condición agregada no perjudica al modelo dentro del conjunto que busca representar. Se obtiene que los modelos mantienen su precisión respecto de los ensayos de un tubo. La diferencia en RMSE es de menos del 2 % respecto del modelo base, lo que indica que la incorporación de la monotonicidad no corrompe el modelo.

TABLA 4.11. Arquitecturas de LFDNN propuestas y métricas sobre conjuntos de entrenamiento y evaluación de ensayos en un tubo.

Arquitectura	λ	Entrenamiento		Evaluación	
		R^2	RMSE	R^2	RMSE
Base	-	0,9657	296,1	0,9657	294,3 (+4,2 %)
	0,01	0,9624	310,0	0,9642	300,9 (+4,1 %)
	0,1	0,9638	304,1	0,9652	296,8 (+4,7 %)
	1	0,9637	304,6	0,9650	297,6 (+5,1 %)

Luego, en la tabla 4.12, se comparan los valores de media y desvío estándar del DNBR, el $\text{DNBR}_{\min}$ y los puntos predichos en la región de entrada y en subcanales interiores. Se obtiene una mejora considerable en todos los modelos PINN, lo que indica que la condición aplicada beneficia al modelo en condiciones subenfriadas. Los valores de DNBR quedan prácticamente centrados y su desvío estándar se redujo a la mitad. En cuanto al $\text{DNBR}_{\min}$, no se obtuvo una mejora, pero esto se debe a su método de cálculo y a la subpredicción no física del DNBR con el modelo base. La cantidad de predicciones en la región de entrada se reduce de casi el 50 % de los ensayos a menos del 7 %. En cuanto a las predicciones en subcanales internos, se obtiene un aumento, aunque se mantiene en menos de 15 %

de los ensayos. La conclusión es que la aplicación de la monotonicidad mejora la generalización del modelo a la aplicación de interés.

TABLA 4.12. Arquitecturas de LFDNN propuestas y métricas sobre ensayos de bundle de la CNA-UII.

Arq.	λ	$\overline{\text{DNBR}}$	$\sigma(\text{DNBR})$	$\text{DNBR}_{\min}$	Z entrada	SCH int.
Base	-	0,687	0,403	1,442	72	6
	0,01	1,061	0,219	1,470	10	14
PINN	0,1	1,035	0,226	1,457	4	14
	1	1,037	0,224	1,456	3	22

Se mantuvo el criterio empleado para evaluar la predicción de los modelos base y se graficó la relación del CHF predicho con el flujo másico y el título termodinámico para el modelo LFPINN con $\lambda = 0,1$ en la figura 4.10. Se observa que se predicen unos pocos casos de CHF en región subenfriada, lo que indica una mejora considerable del modelo respecto de su versión base. Adicionalmente, no se observan valores de CHF que tiendan a 0, como en la figura 4.8. Luego, en la figura 4.11, se presenta la evaluación de la generalización del modelo respecto del flujo másico y el título termodinámico. Se observa que el modelo ahora presenta un aumento del CHF al reducir el título termodinámico en condiciones subenfriadas. Este es el resultado esperado, reforzado por la monotonicidad aplicada. Se observa una reducción del CHF predicho en la región cercana a $x = 0$, lo que se debe a los ensayos disponibles en un tubo para condiciones subenfriadas. Se halló que se tienen unos pocos ensayos de un tubo en condiciones subenfriadas, pero con longitud calefaccionada muy por debajo de las de aplicación en este trabajo. Su efecto queda compensado por la condición de monotonicidad y los puntos de colocación durante el entrenamiento. Una posible mejora a futuro es realizar un filtrado del conjunto de ensayos de Groeneveld para que las variables estén en el rango de aplicación final.




FIGURA 4.10. Relación del CHF predicho con el flujo másico y el título, según el punto predicho por el modelo LFDNN con monotonicidad con $\lambda = 0,1$. TRAIN y TEST son los conjuntos de entrenamiento y evaluación correspondientes a la HFDNN, divididos tal que en evaluación se tienen los ensayos de menor flujo másico.

Generalización: media geométrica de cada modelo sobre el train de Groeneveld (P y L/D en rango COBRA)




FIGURA 4.11. Evaluación de la generalización de la LFPINN respecto del flujo másico y el título termodinámico, según λ .

Por último, en la figura 4.12 se grafica el CHF predicho contra medido y el DNBR en cada ensayo para el modelo con $\lambda = 0,1$. Se observa una predicción centrada, con algunos outliers en el conjunto de evaluación. Estos casos son los que están por fuera del rango de los ensayos en un tubo, y la red debe extrapolar para estimar CHF. A excepción de estos casos, la predicción del modelo se encuentra contenida en el mismo rango que la metodología actual propuesta por INVAP, que, además de la LUT de Groeneveld, recurre a factores de centrado y corrección desarrollados específicamente para lograr una mejor estimación del CHF en el bundle de la CNA-UII, descritos en la sección A.3. Esto denota que el modelo de baja fidelidad logra ya una precisión incluso comparable a la metodología actual, sin haber utilizado datos de los ensayos en la geometría específica.




FIGURA 4.12. Predicción de CHF contra medido y DNBR para cada ensayo, para modelo LFPINN con $\lambda = 0,1$.

4.2.2. Análisis de arquitectura de multifidelidad

Para realizar el análisis de la arquitectura del modelo, se planteó separar la aplicación de multifidelidad de la de información física. En esta sección se estudió el efecto de la primera. Solo se utilizaron las variables base, tradicionales en la predicción de CHF por las LUT de Groeneveld y adoptadas por la *LFP INN*. Estas son el flujo másico, la presión, el título termodinámico y la relación de largo calefaccionado con diámetro hidráulico. Las primeras tres son las variables necesarias para interpolar dentro de la LUT, mientras que la cuarta permite transformar la predicción a la geometría de bundle. Groeneveld propone factores de corrección que utilizan algunas de las variables adicionales incorporadas en este trabajo. Para más detalles, ver el apéndice A.

Las arquitecturas comparadas son las siguientes:

- DNN tradicional entrenada directamente sobre las simulaciones con COBRA3-CP de los ensayos de la Universidad de Columbia. Constituye un baseline para determinar si las arquitecturas más complejas conllevan una mejora de precisión. También debe evaluarse su comportamiento en regiones no entrenadas y ponerse en tela de juicio si sus predicciones tienen sustento físico.
- *LFP INN* entrenada sobre los ensayos en un tubo utilizados para conformar las LUT 2006 de Groeneveld. Esto permite tener un baseline del aporte de la predicción de CHF en un tubo y de su contribución a la arquitectura de multifidelidad.
- MFDNN, conjunción de la *LFP INN* y la HFDNN. Esta última fue entrenada sobre las simulaciones de COBRA3-CP de los ensayos de la Universidad de Columbia, con la predicción de la *LFP INN* como entrada adicional.

Para lograr una evaluación que no se limitara a la capacidad de los modelos de representar la información con la que fueron entrenados, se planteó entrenarlos con los casos menos exigentes desde el punto de vista del CHF. Entonces, para dividir entre los conjuntos de entrenamiento y prueba, se utilizaron en entrenamiento aquellos ensayos con un flujo másico superior a $4\,000\text{ kg/m}^2\text{s}$. La división se grafica en la figura 4.13. Además del flujo másico, la división se presenta contra el título termodinámico, donde se observa que la división también implica dejar en evaluación a la mayoría de los ensayos que presentaron CHF a título alto. Esto permite evaluar el funcionamiento del modelo al extrapolar hacia condiciones más exigentes de CHF, de forma similar a lo realizado para evaluar y definir la *LFP INN*.




FIGURA 4.13. División de los datos de CHF de la Universidad de Columbia en entrenamiento y evaluación, según flujo másico. Los ejes de flujo másico y título termodinámico corresponden a los valores promedio de la sección de ensayo a la salida.

Para evitar que los resultados de los modelos evaluados dependan del proceso estocástico de entrenamiento, se entrenaron 50 instancias de cada modelo. De esta forma, se comparan las métricas estadísticas y de DNBR medias de cada modelo. Las arquitecturas se evaluaron en su predicción de CHF de forma tradicional, y adicionalmente por medio del $\text{DNBR}_{\min}$, según lo explicado en la sección 3.2.3. En la tabla 4.13 se comparan los valores de R^2 y de RMSE para la DNN, la LFPINN y la MFDNN . Se obtuvo un mejor rendimiento por parte de la MFDNN respecto de la DNN en evaluación y muy similar en entrenamiento. En cuanto a la LFPINN , su comportamiento es pobre, con un $R^2 < 0$ que indica que una predicción constante e igual a la media obtendría un mejor ajuste.

TABLA 4.13. Evaluación por métricas estadísticas de la predicción sobre el conjunto de ensayos de la Universidad de Columbia. Para DNN y MFDNN representa la mediana de 50 redes entrenadas.

Modelo	Conjunto	R^2	RMSE
DNN	Entrenamiento	0,951	51,74
	Evaluación	0,807	121,59
LFPINN $\lambda = 0,1$	Entrenamiento	-1,421	365,39
	Evaluación	-0,221	305,64
MFDNN	Entrenamiento	0,945	54,80
	Evaluación	0,846	108,67

En la tabla 4.14 se comparan, para los mismos modelos, el factor de centrado, la media y el desvío estándar del DNBR y el $\text{DNBR}_{\min}$. Es importante aclarar que el factor de centrado se calculó en función del conjunto de entrenamiento y luego se aplicó al conjunto de evaluación. De esta forma se tiene un cómputo análogo al que se realiza en inferencia. Se obtiene nuevamente un comportamiento similar entre el modelo DNN y MFDNN , con una leve ventaja para este último en evaluación. El desvío estándar en ambos conjuntos es muy similar. En cuanto al modelo

LFP INN, los resultados que obtiene son peores en el conjunto de evaluación, producto de que durante su entrenamiento se expuso a menos condiciones similares. Cabe recordar que este modelo fue entrenado con otros conjuntos, correspondientes a ensayos en un tubo. Aun así, al recordar los resultados de la figura 4.12, su comportamiento resulta similar al de la metodología de INVAP, a excepción de entre 10 y 15 puntos en los que se subpredice el CHF.

TABLA 4.14. Evaluación por métricas de predicción de DNBR sobre el conjunto de ensayos de la Universidad de Columbia. Para DNN y MFDNN representa la mediana de 50 redes entrenadas.

Modelo	Conjunto	f_c	DNBR	$\sigma(\text{DNBR})$	DNBR _{min}
DNN	Entrenamiento	1,035	1,000	0,031	1,060
	Evaluación		1,063	0,109	1,265
LFP INN $\lambda = 0,1$	Entrenamiento	0,916	1,000	0,152	1,300
	Evaluación		0,895	0,240	1,369
MFDNN	Entrenamiento	1,003	1,000	0,032	1,062
	Evaluación		1,041	0,103	1,233

Al analizar el desvío estándar en el DNBR_{min} obtenido en evaluación, el modelo DNN obtiene un valor de 0,088, mientras que el MFDNN 0,008. Esto indica que este último, por su construcción, tiene una mayor robustez y no depende tanto del proceso estocástico de entrenamiento. Esto se evidencia de forma gráfica en la figura 4.14, donde se presenta la distribución de densidad de probabilidad de DNBR_{min} de cada modelo, para los conjuntos de entrenamiento y de evaluación. Ambos modelos presentan buen comportamiento en entrenamiento, algo no sorprendente a esta altura del trabajo. En evaluación, los resultados permiten apreciar el impacto de tomar como entrada la predicción informada de la LFP INN. El modelo de DNN tradicional presenta una distribución casi uniforme entre 1,1 y 1,4, mientras que el modelo MFDNN presenta una distribución con menor desvío estándar y más concentrada. En particular, para esta aplicación, esto es un rasgo positivo, ya que implica que el modelo debe respetar condiciones de fondo que la aleatoriedad no puede mover, es decir, el modelo busca representar la física.






FIGURA 4.14. Distribución de probabilidad de DNBR_{min} para $N = 50$ modelos entrenados de cada tipo.

Por último, en la figura 4.15 se presentan los gráficos de CHF predicho contra medido y de DNBR para cada ensayo, para el modelo con la mediana del $DNBR_{min}$ de entrenamiento de cada variante. El comportamiento de ambos es similar, con una tendencia a subpredecir CHF en algunos casos del conjunto de evaluación. Aun así, se observa que, a excepción de esos puntos extraordinarios, la predicción se encuentra contenida dentro de la de INVAP. Esto indica un mejor comportamiento y destaca el rendimiento de estos modelos aun en condiciones desfavorables de entrenamiento, por no contar con los puntos más limitantes de CHF.



(A) Modelo DNN tradicional.



(B) Modelo MFDNN.

FIGURA 4.15. CHF predicho contra medido y DNBR por ensayo para modelos DNN y MFDNN. Se seleccionó para cada variante el modelo con la mediana del $DNBR_{min}$ de entrenamiento.

4.2.3. Análisis de arquitectura informada por física

Para el análisis de arquitectura informada por física, se adoptó un enfoque de agregación de las condiciones, para poder evaluar el efecto aislado de cada una sobre el modelo. Adicionalmente, se entrenó el modelo con todas las condiciones en conjunto. En la tabla 4.15 se presenta la nomenclatura de las variantes evaluadas. Las variantes A a D fueron planteadas originalmente y, luego, en función

de sus resultados, se agregó la variante E al análisis. El punto de comparación en esta instancia es la red MFDNN evaluada en la sección previa. Para realizar la comparación se dispuso el entrenamiento de la siguiente forma. Se entrenó una red MFDNN con optimizador Adam durante 500 épocas. De esta forma las redes MFPIINN tienen el mismo punto de partida y no dependen fuertemente del proceso estocástico detrás del optimizador para el primer acercamiento a la solución. Luego, se entrenó durante otras 500 épocas cada variante, pero con optimizador L-BFGS, estándar en entrenamiento de redes PINN.

TABLA 4.15. Variantes del modelo MFPIINN evaluadas.

Modelo MFPIINN	Monotonicidad			Derivada cruzada	Derivada segunda
	x	G	p		
A	■	■	■	■	■
B	■	■	■		
B1	■				
B2		■ [†]			
B3			■		
C				■	
D					■
E	■	■	■		■

[†] Solo se aplica la monotonicidad de G positiva en $(x < 0,15) \cup (G < 3\,000 \text{ kg/m}^2\text{s})$.

En la tabla 4.16 se compara el rendimiento de los distintos modelos en cuanto a predicción de DNBR en entrenamiento, y en la tabla 4.17 en evaluación. Nuevamente, el factor de centrado fue calculado sobre el conjunto de entrenamiento y aplicado al de evaluación, de forma análoga a lo que se realiza en inferencia. Se obtiene un rendimiento idéntico entre los modelos en el conjunto de entrenamiento, con una leve mejora respecto del modelo base MFDNN. Esta mejora en todos los modelos es esperable, dado que se dispuso de más épocas de entrenamiento sobre el mismo conjunto.

TABLA 4.16. Resultados de predicción de CHF en conjunto de entrenamiento para las arquitecturas evaluadas de MFPIINN.

Modelo	f_c	$\overline{\text{DNBR}}$	$\sigma(\text{DNBR})$	$\text{DNBR}_{\min}$
MFDNN	1,000	1,000	0,032	1,062
A	1,000	1,000	0,019	1,037
B	1,000	1,000	0,021	1,041
B1	1,000	1,000	0,021	1,042
B2	1,000	1,000	0,020	1,040
B3	1,000	1,000	0,023	1,044
C	1,000	1,000	0,019	1,038
D	1,000	1,000	0,022	1,044
E	1,000	1,000	0,020	1,039

Luego, en evaluación, se obtienen resultados más diversos. Las variantes A, B2 y B3 logran mejorar el rendimiento de la referencia. Se obtuvo un aumento generalizado del desvío estándar y, en los modelos A a B2, una tendencia a subpredecir DNBR, mientras que en los modelos B3 a D se observó una tendencia a sobrepredecir. El modelo E, combinación de los modelos B y D, obtiene una mejora

de rendimiento muy cercana a la del modelo completo A. Esta combinación se realizó no en función de los resultados de $\text{DNBR}_{\min}$, sino a partir de los gráficos de CHF predicho contra medido, presentados en las figuras 4.16, 4.17 y 4.18 para las variantes A, B y D, respectivamente. Allí se observa el rendimiento similar entre el modelo completo A y el B, con algunos outliers adicionales en este último, que producen la reducción de rendimiento. Resulta muy interesante el modelo D en la figura 4.18, que presenta una distribución muy cercana a la recta unitaria, con tres ensayos de sobrepredicción importante del CHF. Estos tres puntos son los que penalizan fuertemente el resultado de $\text{DNBR}_{\min}$ de este modelo. Por este motivo se planteó la combinación de los modelos B y D en el E. Los resultados de CHF predicho contra real se presentan en la figura 4.19, donde se observa un rendimiento sin los casos de sobrepredicción de CHF del modelo D y con una nube más cercana a la recta unitaria que el modelo B. En todos los modelos evaluados se obtuvo subpredicción de CHF para los ensayos con menor caudal. Esto se evidencia en las figuras 4.20, 4.21 y 4.22, donde se presentan los resultados de CHF en función del flujo másico y el título termodinámico para las variantes A, B y D, respectivamente.

En función de los resultados de esta sección, se definió utilizar la variante E como modelo final MFP INN .

El máximo $\text{DNBR}_{\min}$ para MFDNN fue XXX y para MFP INN XXX .

TABLA 4.17. Resultados de predicción de CHF en conjunto de evaluación para las arquitecturas evaluadas de MFP INN .

Modelo	f_c	$\overline{\text{DNBR}}$	$\sigma(\text{DNBR})$	$\text{DNBR}_{\min}$
MFDNN	1,000	1,031	0,094	1,217
A	1,000	0,965	0,117	1,196
B	1,000	0,999	0,146	1,289
B1	1,000	0,939	0,171	1,277
B2	1,000	0,961	0,124	1,207
B3	1,000	1,006	0,103	1,210
C	1,000	1,005	0,217	1,436
D	1,000	1,028	0,188	1,400
E	1,000	0,961	0,122	1,203




FIGURA 4.16. CHF predicho contra medido y DNBR por ensayo para variante A de MFP INN.




FIGURA 4.17. CHF predicho contra medido y DNBR por ensayo para variante B de MFP INN.




FIGURA 4.18. CHF predicho contra medido y DNBR por ensayo para variante D de MFP INN.




FIGURA 4.19. CHF predicho contra medido y DNBR por ensayo para variante E de MFP INN.




FIGURA 4.20. Relación entre CHF predicho y flujo másico y título termodinámico para variante A de MFP INN.




FIGURA 4.21. Relación entre CHF predicho y flujo másico y título termodinámico para variante B de MFP INN.




FIGURA 4.22. Relación entre CHF predicho y flujo másico y título termodinámico para variante D de MFP INN.

4.2.4. Análisis de variables de entrada

Las variables de entrada propuestas en la sección 3.2.1 fueron el flujo másico, la presión, el título termodinámico, la relación de largo calefaccionado con diámetro hidráulico, la distancia adimensional al separador aguas arriba, el desbalance de título termodinámico respecto del valor medio del bundle, el factor de pico de potencia y la relación entre perímetro calefaccionado y mojado del subcanal. Las primeras cuatro variables son las clásicas utilizadas por la LUT de Groeneveld, y se consideran las más importantes para la predicción de CHF. Las cuatro variables restantes fueron propuestas en este trabajo, y se debe evaluar su contribución al modelo.

Se entrenaron el modelo MFDNN y las variantes A, B, C y D del modelo MFP INN. Al igual que en la sección anterior, para el modelo MFDNN se entrenaron 50 instancias y se informan las medianas de las métricas. En cuanto a las variantes MFP INN, no se realizó un estudio de ese tipo, debido a que su costo de entrenamiento es considerablemente elevado.

En la tabla 4.18 se presentan el factor de centrado, la media y el desvío estándar del DNBR predicho y el $\text{DNBR}_{\min}$ para el conjunto de entrenamiento. Se obtuvo un rendimiento similar al del caso con las variables base, levemente mejorado en las variantes MFP INN.

TABLA 4.18. Resultados de predicción de CHF en conjunto de entrenamiento para las arquitecturas evaluadas de MFP INN.

Modelo	f_c	$\overline{\text{DNBR}}$	$\sigma(\text{DNBR})$	$\text{DNBR}_{\min}$
MFDNN	1,007	1,000	0,028	1,055
MFP INN A	1,000	1,000	0,010	1,020
MFP INN B	1,000	1,000	0,014	1,028
MFP INN D	1,000	1,000	0,018	1,035
MFP INN E	1,000	1,000	0,013	1,026

En cuanto al conjunto de evaluación, sí se obtuvieron diferencias en el rendimiento respecto de utilizar las variables base. En la tabla 4.19 se presentan las métricas

para dicho conjunto. La $MFDNN$ presenta un rendimiento casi idéntico al caso anterior. Las variantes A y E de $MFPINN$ presentaron un rendimiento muy pobre, con un $DNBR_{min}$ mayor incluso que el de la $LFDNN$. La variante B presenta una mejora, producto de una reducción del desvío estándar y un aumento en la subpredicción del CHF. La variante D presenta un rendimiento sobresaliente, con el mejor $DNBR_{min}$ obtenido hasta este punto del trabajo. Por ello, se investigó el resultado con mayor detalle, al graficar la relación de los CHF predichos con el flujo másico y el título termodinámico en la figura 4.23. Allí se puede ver que el modelo predice CHF en condiciones subenfriadas en múltiples ensayos. Este resultado pone en tela de juicio el sentido físico de estas predicciones.

TABLA 4.19. Resultados de predicción de CHF en conjunto de evaluación para las arquitecturas evaluadas de $MFPINN$.

Modelo	f_c	$\overline{DNBR}$	$\sigma(DNBR)$	$DNBR_{min}$
$MFDNN$	1,007	1,046	0,097	1,238
$MFPINN$ A	1,000	1,233	0,451	2,125
$MFPINN$ B	1,000	0,953	0,126	1,202
$MFPINN$ D	1,000	0,956	0,089	1,133
$MFPINN$ E	1,000	1,321	0,358	2,030




FIGURA 4.23. Relación de CHF con el flujo másico y el título termodinámico para variante D de $MFPINN$, con variables de entrada expandidas.

Se presentan los resultados de CHF predicho contra real y DNBR por ensayo para el modelo $MFDNN$ en la figura 4.24 y para la variante E del modelo $MFPINN$ en la figura 4.25. Ambos obtienen una tendencia a la sobrepredicción para el conjunto de evaluación. Para la variante E se observa un rendimiento muy pobre, como lo indican las métricas de DNBR, con una sobrepredicción preocupante del CHF.




FIGURA 4.24. CHF predicho contra real y DNBR por ensayo, para MFDNN con variables de entrada expandidas.




FIGURA 4.25. CHF predicho contra real y DNBR por ensayo, para variante E de MFP INN con variables de entrada expandidas.

La conclusión obtenida es que la inclusión de estas variables en el modelo no representa una mejora clara en las predicciones, e incluso puede resultar en predicciones con tendencias no físicas. Por lo tanto, los modelos finales solo utilizan las variables básicas.

4.2.5. Modelos finales

En las secciones 4.2.2 y 4.2.3 se validó la robustez de los modelos MFDNN y MFP INN para la estimación de CHF al restringir su entrenamiento a condiciones de medio a alto caudal y evaluación a bajo caudal. Dichas condiciones implican una penalización importante al modelo, ya que su conjunto de entrenamiento no contiene datos de las condiciones más críticas para el CHF. Si bien este análisis permitió validar el funcionamiento de los modelos, sus versiones finales no deben tener aplicada esta penalización. Por lo tanto, fueron entrenados con una división aleatoria entre conjuntos de entrenamiento y evaluación, con un 20 % de los datos

reservados para evaluación. Se realizó la división con estratificación por conjunto de ensayos de la Universidad de Columbia, de forma de tener datos de los 4 conjuntos de ensayos disponibles.

En la tabla 4.20 se presentan los resultados de las métricas de predicción de DNBR para $MFDNN$ y $MFPINN$. Adicionalmente se tienen los valores de la metodología actual, implementada por INVAP. Aquí se puede comparar directamente con ella, ya que los modelos $MFDNN$ y $MFPINN$ fueron entrenados con todo el rango de los ensayos. La metodología actual fue calibrada sin dejar un conjunto de evaluación, por lo que su capacidad de extrapolar por fuera del rango de calibración no ha sido estudiada.

El modelo $MFDNN$ obtiene un rendimiento similar a los análisis previos en el conjunto de entrenamiento, pero en este caso el $DNBR_{min}$ para evaluación es del mismo orden. La reducción del $DNBR_{min}$ es considerable respecto de la metodología actual. El modelo $MFPINN$ tiene aún mejor comportamiento, con un $DNBR_{min}$ en evaluación incluso menor que el de $MFDNN$ en entrenamiento. Adicionalmente, el desvío estándar también se ve reducido para el modelo $MFPINN$, lo que indica que predice con un error consistentemente bajo.

TABLA 4.20. Evaluación por métricas de predicción de DNBR sobre el conjunto de ensayos de la Universidad de Columbia. Para $MFDNN$ representa la mediana de 50 redes entrenadas. Entrenamiento y evaluación divididos de forma aleatoria.

Modelo	Conjunto	f_c	$\overline{DNBR}$	$\sigma(DNBR)$	$DNBR_{min}$
INVAP	-	1,164	0,999	0,113	1,212
$MFDNN$	Entrenamiento	1,002	1,000	0,050	1,094
	Evaluación		0,998	0,054	1,113
$MFPINN$	Entrenamiento	1,005	1,000	0,029	1,056
	Evaluación		0,987	0,044	1,084

En la figura 4.26 se presenta la distribución de densidad de probabilidad de $DNBR_{min}$ para los 50 modelos $MFDNN$ entrenados. Nuevamente, se evidencia un rendimiento en evaluación consistente y cercano al de entrenamiento. En la figura 4.27 se presentan los gráficos de CHF predicho contra real y DNBR por ensayo para el modelo $MFDNN$ con el valor mediano de $DNBR_{min}$. Comparado con las predicciones por la metodología INVAP, se obtiene una distribución más centrada en la recta de identidad, y todos los valores de DNBR quedan contenidos aproximadamente entre 0,9 y 1,1.

Finalmente, en la figura 4.28 se presentan para el modelo $MFPINN$ los gráficos de CHF predicho contra real y de DNBR por ensayo. La distribución de predicciones es aún más cercana que la de la $MFDNN$, lo que refuerza los valores de $DNBR_{min}$ presentados previamente.




FIGURA 4.26. Distribución de densidad de probabilidad de $\text{DNBR}_{\min}$ para 50 modelos MFDNN entrenados.




FIGURA 4.27. CHF predicho contra real y DNBR por ensayo para modelo final MFDNN.




FIGURA 4.28. CHF predicho contra real y DNBR por ensayo para modelo final MFP INN.

4.2.6. Estimación de impacto

Para estimar el impacto de la reducción del valor del $\text{DNBR}_{\min}$ en las PLC, se utiliza el valor obtenido en evaluación de la MFP INN para calcular el $\text{DNBR}_{\lim}$. Luego se calcula con COBRA3-CP el valor de PLC por DNB, con los perfiles de potencia de diseño termohidráulico del IFS. Es importante notar que esta estimación es de primer orden, puesto que el valor final del $\text{DNBR}_{\lim}$ depende del límite de diseño seguro (SDL). Este límite varía por la metodología de predicción de CHF y su dependencia ante variaciones en las condiciones operativas. A priori, una predicción más robusta de CHF debería permitir reducir el $\Delta\text{DNBR}_{\text{SDL}}$, pero esa evaluación se encuentra por fuera del alcance de este trabajo ya que implica realizar todos los cálculos del diseño termohidráulico de la CNA-UII.

TABLA 4.21. Potencia límite de canal [MW] por DNB para metodología actual y MFP INN.

Metodología	Zona Hidráulica				
	1	2	3	4	5
Actual	3 652	4 074	4 495	5 768	6 920
MFP INN	3 746	4 383	4 932	5 977	7 128
Diferencia	+2,6 %	+7,59 %	+9,72 %	+3,62 %	+3,01 %

Capítulo 5

Conclusiones

A continuación, se presentan las conclusiones del trabajo y las tareas disponibles a futuro para continuarlo.

5.1. Conclusiones generales

Seguidamente, se exponen las conclusiones generales de los modelos desarrollados en el trabajo.

5.1.1. Estimación de PLC

Se propuso un modelo de aprendizaje profundo para la estimación del DNBR y la fracción de vacío en un canal refrigerante de la CNA-UII. El modelo tiene como entradas los parámetros termohidráulicos del canal y los perfiles de potencia axial y por barra. Se optimizaron sus hiperparámetros y se obtuvo el modelo final, con errores relativos menores al 1 %.

Se desarrolló un lazo de cálculo análogo al utilizado con COBRA3-CP para la estimación de PLC con el modelo desarrollado. Se comparó con cálculos de PLC realizados sobre 100 casos de la vigente estrategia de recambio de combustibles de la CNA-UII. Se obtuvieron cocientes entre valor predicho y real con media menor a 1,05.

Para asegurar la estimación conservativa de la PLC, se propuso un factor multiplicativo de ajuste. Al utilizar este factor, se obtuvieron los márgenes perdidos por el uso de la herramienta con inteligencia artificial frente al uso de COBRA3-CP. El margen medio perdido total en el reactor es de 0,71 %, mientras que el máximo es 2,34 %.

El tiempo de cómputo de la metodología propuesta es varios órdenes de magnitud menor que el de la predicción con COBRA3-CP. En términos cuantitativos, la aplicación de esta metodología representa una mejora en el tiempo de cómputo de aproximadamente 2 000 veces por fracción de vacío y 8 500 veces por DNB.

Finalmente, se aplicó una arquitectura autoencoder para obtener el espacio latente de los perfiles de potencia axial y por barra. Los espacios latentes obtenidos permiten identificar las cualidades principales de los perfiles. Adicionalmente, se aplicó la reducción de dimensionalidad de los perfiles para modificar el vector de entrada a la DNN estimadora de DNBR y fracción de vacío. Se obtuvo una reducción del margen perdido en el caso de utilizar el espacio latente del perfil por barra, lo que demuestra que las 37 componentes son altamente redundantes para este cálculo.

5.1.2. Estimación de CHF

5.2. Próximos pasos

- Definir los límites de aplicación de las PDE de forma analítica y no cualitativa.
- Evaluar la optimización del predictor de CHF.
-

MSS: Algo interesante a investigar sería la capacidad de reproducir peores casos. Es decir, si el que te da peor con la red es el que te da peor con COBRA. Sé que es difícil pero habría que mirarlo para ver si te sirve como filtro para saber cuáles casos calcular después con COBRA para afinar el lápiz.

Acá se indica cómo se podría continuar el trabajo más adelante.

Apéndice A

Predicción de CHF por LUT de Groeneveld

A.1. Interpolación en la LUT

La LUT propuesta por Groeneveld es una tabla con tres dimensiones: la presión, el flujo másico y el título termodinámico. Para la versión 2006, se tiene una discretización de 15 puntos para la presión, entre 100 y 21 000 kPa; de 21 puntos para el flujo másico, entre 0 y 8 000 kg/m²s; y de 23 puntos para el título termodinámico, entre -0,5 y 1. Para obtener valores en puntos no tabulados se interpola linealmente. En la figura A.1 se esquematiza la interpolación en tres dimensiones.




FIGURA A.1. Esquematización de interpolación en tres dimensiones en la LUT de Groeneveld¹.

A.2. Factores de corrección

A continuación, se exponen los factores de corrección propuestos por Groeneveld con las LUT 1986 [38].

- Factor de subcanal, expresado en la ecuación A.1.

$$K_1 = \begin{cases} \left(\frac{0,008}{D_h} \right)^{1/3} & 0,002 \text{ m} < D_h < 0,016 \text{ m} \\ 0,79 & 0,016 \text{ m} \leq D_h \end{cases} \quad (\text{A.1})$$

¹Imagen tomada de [38].

- Factor de bundle, expresado en la ecuación A.2.

$$K_2 = \min \left[0,8; 0,8 \cdot \exp \left(-0,5 \cdot x^{1/3} \right) \right] \quad (\text{A.2})$$

- Factor de grilla de separadores, expresado en la ecuación A.3 con las definiciones de la ecuación A.4.

$$K_3 = 1 + A \cdot \exp \left(-B \cdot \frac{L_{sp}}{D_h} \right) \quad (\text{A.3})$$

$$A = 1,5 \cdot k^{0,5} \cdot \left(\frac{G}{1000} \right)^{0,2} \quad B = 0,1 \quad (\text{A.4})$$

- Factor de longitud calefaccionada, expresado en la ecuación A.5.

$$K_4 = \exp \left[\frac{D_h}{L} \exp(2\alpha) \right] \quad \frac{L}{D_h} \geq 5 \quad (\text{A.5})$$

α es la fracción de vacío calculada según el modelo homogéneo.

- Factor de perfil axial de potencia, expresado en la ecuación A.6.

$$K_5 = \begin{cases} \frac{q_{BLA}}{q_{LOCAL}} & x > 0 \\ 1 & x < 0 \end{cases} \quad (\text{A.6})$$

q_{BLA} es el flujo de calor promedio sobre la longitud con ebullición, es decir, desde $x = 0$ hasta $x = x_{CHF}$.

En particular, para la metodología actual de predicción de CHF en el bundle de la CNA-UII, solo se utilizan los factores de subcanal K_1 y de perfil axial de potencia K_5 . Adicionalmente, se utilizan tres factores propuestos por INVAP, explicados en la sección A.3.

A.3. Factores de corrección propuestos por INVAP

INVAP propuso en [50, 51] factores de corrección para mejorar la predicción de CHF por medio de las LUT, específicamente para el bundle de la CNA-UII. Estos factores se plantearon como la exponencial de un polinomio de segundo grado, del cual se optimizaron los coeficientes para reducir la dependencia residual del CHF predicho con el flujo másico y el título termodinámico. Adicionalmente, se aplicó un factor de centrado, que permite luego aplicar el criterio de 95 % de probabilidad y confianza para el cálculo del $DNBR_{min}$, descripto en la sección 3.2.3.

Bibliografía

- [1] D. C. Groeneveld. *Critical Heat Flux Data Used to Generate the 2006 Groeneveld Critical Heat Flux Lookup Tables*. NUREG/KM 0011. Washington, DC: U.S. Nuclear Regulatory Commission, 2019. URL: <https://www.nrc.gov/reading-rm/doc-collections/nuregs/knowledge/km0011/index>.
- [2] D.C. Groeneveld et al. «The 2006 CHF look-up table». En: *Nuclear Engineering and Design* 237.15 (2007). NURETH-11, págs. 1909-1922. ISSN: 0029-5493. DOI: <https://doi.org/10.1016/j.nucengdes.2007.02.014>. URL: <https://www.sciencedirect.com/science/article/pii/S0029549307002002>.
- [3] Nucleoeléctrica Argentina S.A. *Informe Final de Seguridad de la Central Nuclear Atucha II*. Confidencial. 2025.
- [4] S. Nukiyama. «The maximum and minimum values of the heat Q transmitted from metal to boiling water under atmospheric pressure». En: *International Journal of Heat and Mass Transfer* 9.12 (1966), págs. 1419-1433. ISSN: 0017-9310. DOI: [https://doi.org/10.1016/0017-9310\(66\)90138-4](https://doi.org/10.1016/0017-9310(66)90138-4). URL: <https://www.sciencedirect.com/science/article/pii/0017931066901384>.
- [5] N.E. Todreas J.W. Jackson e INVAP. COBRA3-CP. *An improved version of COBRA IIIC/MIT-2: a digital computer program for steady state and transient thermal-hydraulic analysis of rod bundle nuclear fuel elements*. Confidencial. 1981.
- [6] X. Meng y G.E. Karniadakis. «A composite neural network that learns from multi-fidelity data: Application to function approximation and inverse PDE problems». En: *Journal of Computational Physics* 401 (2020), pág. 109020. ISSN: 0021-9991. DOI: <https://doi.org/10.1016/j.jcp.2019.109020>. URL: <https://www.sciencedirect.com/science/article/pii/S0021999119307260>.
- [7] M. Raissi, P. Perdikaris y G.E. Karniadakis. «Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations». En: *Journal of Computational Physics* 378 (2019), págs. 686-707. ISSN: 0021-9991. DOI: <https://doi.org/10.1016/j.jcp.2018.10.045>. URL: <https://www.sciencedirect.com/science/article/pii/S0021999118307125>.
- [8] H. Ballesteros. *Descripción y Teoría del Programa AXENA*. Inf. téc. 22-12. Confidencial. Gerencia de Análisis de Seguridad y Diseño del Núcleo, Nucleoeléctrica Argentina S.A., 2012.
- [9] L. S. Tong e Y. S. Tang. *Boiling Heat Transfer and Two-Phase Flow*. 2nd. New York: Taylor & Francis, 1997. ISBN: 1560324855. URL: <https://www.taylorfrancis.com/books/mono/10.1201/9781315138510/boiling-heat-transfer-two-phase-flow-tong>.
- [10] D.C. Groeneveld et al. «The 1995 look-up table for critical heat flux in tubes». En: *Nuclear Engineering and Design* 163.1 (1996), págs. 1-23. ISSN: 0029-5493. DOI: [https://doi.org/10.1016/0029-5493\(95\)01154-4](https://doi.org/10.1016/0029-5493(95)01154-4). URL: <https://www.sciencedirect.com/science/article/pii/0029549395011544>.

- [11] Xingang Zhao et al. «On the prediction of critical heat flux using a physics-informed machine learning-aided framework». En: *Applied Thermal Engineering* 164 (2020), pág. 114540. ISSN: 1359-4311. DOI: <https://doi.org/10.1016/j.applthermaleng.2019.114540>. URL: <https://www.sciencedirect.com/science/article/pii/S1359431119332065>.
- [12] Xingang Zhao, Robert K. Salko y Koroush Shirvan. «Improved departure from nucleate boiling prediction in rod bundles using a physics-informed machine learning-aided framework». En: *Nuclear Engineering and Design* 374 (2021), pág. 111084. ISSN: 0029-5493. DOI: <https://doi.org/10.1016/j.nucengdes.2021.111084>. URL: <https://www.sciencedirect.com/science/article/pii/S0029549321000364>.
- [13] Yue Jin, Xingang Zhao y Koroush Shirvan. «Constructing A New CHF Look-Up Table Based on the Domain Knowledge Informed Machine Learning Methodology». En: Oak Ridge National Laboratory (ORNL), Oak Ridge, TN (United States). Mar. de 2022. URL: <https://www.osti.gov/biblio/1867773>.
- [14] Congshan Mao y Yue Jin. «Uncertainty quantification study of the physics-informed machine learning models for critical heat flux prediction». En: *Progress in Nuclear Energy* 170 (2024), pág. 105097. ISSN: 0149-1970. DOI: <https://doi.org/10.1016/j.pnucene.2024.105097>. URL: <https://www.sciencedirect.com/science/article/pii/S0149197024000477>.
- [15] Richard L. Burden, J. Douglas Faires y Annette M. Burden. *Numerical Analysis*. 10th. Boston, MA: Cengage Learning, 2015.
- [16] Ian Goodfellow, Yoshua Bengio y Aaron Courville. *Deep Learning*. <http://www.deeplearningbook.org>. MIT Press, 2016.
- [17] Adam Paszke et al. *PyTorch: An Imperative Style, High-Performance Deep Learning Library*. 2019. arXiv: [1912.01703](https://arxiv.org/abs/1912.01703) [cs.LG]. URL: <https://arxiv.org/abs/1912.01703>.
- [18] Adam Paszke et al. *PyTorch*. URL: <https://pytorch.org/>.
- [19] Ian H. Bell et al. «Pure and Pseudo-pure Fluid Thermophysical Property Evaluation and the Open-Source Thermophysical Property Library CoolProp». En: *Industrial & Engineering Chemistry Research* 53.6 (2014). DOI: [10.1021/ie4033999](https://doi.org/10.1021/ie4033999).
- [20] The pandas development team. *pandas-dev/pandas: Pandas*. Ver. latest. Feb. de 2020. DOI: [10.5281/zenodo.3509134](https://doi.org/10.5281/zenodo.3509134). URL: <https://doi.org/10.5281/zenodo.3509134>.
- [21] Wes McKinney. «Data Structures for Statistical Computing in Python». En: *Proceedings of the 9th Python in Science Conference*. Ed. por Stéfan van der Walt y Jarrod Millman. 2010, págs. 56-61. DOI: [10.25080/Majora-92bf1922-00a](https://doi.org/10.25080/Majora-92bf1922-00a).
- [22] Fabian Pedregosa et al. «Scikit-learn: Machine Learning in Python». En: *Journal of Machine Learning Research* 12 (2011), págs. 2825-2830. URL: <http://arxiv.org/abs/1201.0490>.
- [23] Charles R. Harris et al. «Array programming with NumPy». En: *Nature* 585.7825 (sep. de 2020), págs. 357-362. DOI: [10.1038/s41586-020-2649-2](https://doi.org/10.1038/s41586-020-2649-2). URL: <https://doi.org/10.1038/s41586-020-2649-2>.
- [24] J. D. Hunter. «Matplotlib: A 2D graphics environment». En: *Computing in Science & Engineering* 9.3 (2007), págs. 90-95. DOI: [10.1109/MCSE.2007.55](https://doi.org/10.1109/MCSE.2007.55).
- [25] Michael L. Waskom. «seaborn: statistical data visualization». En: *Journal of Open Source Software* 6.60 (2021), pág. 3021. DOI: [10.21105/joss.03021](https://doi.org/10.21105/joss.03021). URL: <https://doi.org/10.21105/joss.03021>.

- [26] Takuya Akiba et al. «Optuna: A Next-generation Hyperparameter Optimization Framework.» En: *KDD*. Ed. por Ankur Teredesai et al. ACM, 2019, págs. 2623-2631. ISBN: 978-1-4503-6201-6. URL: <http://dblp.uni-trier.de/db/conf/kdd/kdd2019.html#AkibaSYOK19>.
- [27] L.Lencina y H. Ballesteros. *Recopilación datos experimentales obtenidos de los ensayos termohidráulicos realizados en el Elemento Combustible Atucha II en los Circuitos Experimentales de la CNEA (CEBP y CEAP) y en la Universidad de Columbia*. Inf. téc. 11-08. Confidencial. Gerencia de Análisis de Seguridad y Diseño del Núcleo, Nucleoeléctrica Argentina S.A., 2008.
- [28] Diederik P. Kingma y Jimmy Ba. «Adam: A Method for Stochastic Optimization». En: *International Conference on Learning Representations (ICLR)*. 2015.
- [29] Vinod Nair y Geoffrey E. Hinton. «Rectified Linear Units Improve Restricted Boltzmann Machines». En: *Proceedings of the 27th International Conference on Machine Learning (ICML-10)*. 2010, págs. 807-814.
- [30] Dan Hendrycks y Kevin Gimpel. «Gaussian Error Linear Units (GELUs)». En: *arXiv preprint arXiv:1606.08415* (2016).
- [31] Stefan Elfving, Eiji Uchibe y Kenji Doya. «Sigmoid-Weighted Linear Units for Neural Network Function Approximation in Reinforcement Learning». En: *Neural Networks* 107 (2018), págs. 3-11.
- [32] Andrew L. Maas, Awni Y. Hannun y Andrew Y. Ng. «Rectifier Nonlinearities Improve Neural Network Acoustic Models». En: *Proceedings of the 30th International Conference on Machine Learning (ICML)*. Vol. 30. 1. 2013.
- [33] Djork-Arné Clevert, Thomas Unterthiner y Sepp Hochreiter. «Fast and Accurate Deep Network Learning by Exponential Linear Units (ELUs)». En: *arXiv preprint arXiv:1511.07289* (2015).
- [34] INVAP. *Flow Rate Versus Power in the Hot Coolant Channel for Each Hydraulic Zone*. Inf. téc. CNA2-1152-3BEIN-010-B. Confidencial. 2008.
- [35] Harold Hotelling. «Analysis of a complex of statistical variables into principal components». En: *Journal of Educational Psychology* 24.6 (1933), 417-441. DOI: [10.1037/h0071325](https://doi.org/10.1037/h0071325).
- [36] J Weisman y B S Pei. «Prediction of critical heat flux in flow boiling at low qualities». en. En: (1983). DOI: [https://doi.org/10.1016/S0017-9310\(83\)80047-7](https://doi.org/10.1016/S0017-9310(83)80047-7). URL: <https://www.sciencedirect.com/science/article/pii/S0017931083800477>.
- [37] Jean-Marie Le Corre, Shi-Chune Yao y Cristina H. Amon. «A mechanistic model of critical heat flux under subcooled flow boiling conditions for application to one- and three-dimensional computer codes». en. En: *Nuclear Engineering and Design* 240.2 (feb. de 2010), págs. 235-244. ISSN: 00295493. DOI: [10.1016/j.nucengdes.2008.12.007](https://doi.org/10.1016/j.nucengdes.2008.12.007). URL: <https://linkinghub.elsevier.com/retrieve/pii/S0029549308006225> (visitado 22-07-2026).
- [38] D. C. Groeneveld, S. C. Cheng y T. Doan. «1986 AECL-UO Critical Heat Flux Lookup Table». En: *Heat Transfer Engineering* 7.1-2 (1986), págs. 46-62. URL: <https://doi.org/10.1080/01457638608939644>.
- [39] Moshe Siman-Tov. «Application of energy balance and direct substitution methods for thermal margins and data evaluation». en. En: *Nuclear Engineering and Design* 163.1-2 (jun. de 1996), págs. 249-258. ISSN: 00295493. DOI: [10.1016/0029-5493\(95\)01174-9](https://doi.org/10.1016/0029-5493(95)01174-9). URL: <https://linkinghub.elsevier.com/retrieve/pii/S0029549395011749> (visitado 21-07-2026).
- [40] S.Y. Ahmad. «Fluid to fluid modeling of critical heat flux: A compensated distortion model». en. En: *International Journal of Heat and Mass Transfer* 16.3 (mar. de 1973), págs. 641-662. ISSN: 00179310. DOI: [10.1016/0017-](https://doi.org/10.1016/0017-)

- 9310(73)90229-9. URL: <https://linkinghub.elsevier.com/retrieve/pii/S0017931073902299> (visitado 22-07-2026).
- [41] Maximilian Ilse, Jakub M. Tomczak y Max Welling. «Attention-based Deep Multiple Instance Learning». En: *Proceedings of the 35th International Conference on Machine Learning*. Vol. 80. PMLR. 2018, págs. 2127-2136.
- [42] John S. Bridle. «Probabilistic Interpretation of Feedforward Classification Network Outputs, with Relationships to Statistical Pattern Recognition». En: *Neurocomputing: Algorithms, Architectures and Applications*. Vol. F68. NATO ASI Series. Berlin, Heidelberg: Springer, 1990, págs. 227-236. DOI: [10.1007/978-3-642-76153-9_28](https://doi.org/10.1007/978-3-642-76153-9_28).
- [43] Geoffrey Hinton, Oriol Vinyals y Jeff Dean. *Distilling the Knowledge in a Neural Network*. NIPS 2014 Deep Learning Workshop. 2015. arXiv: [1503.02531](https://arxiv.org/abs/1503.02531).
- [44] M. O. Hill. «Diversity and Evenness: A Unifying Notation and Its Consequences». En: *Ecology* 54.2 (1973), págs. 427-432. DOI: [10.2307/1934352](https://doi.org/10.2307/1934352).
- [45] Dong C. Liu y Jorge Nocedal. «On the limited memory BFGS method for large scale optimization». En: *Mathematical Programming* 45.1-3 (1989), págs. 503-528. DOI: [10.1007/BF01589116](https://doi.org/10.1007/BF01589116).
- [46] INVAP. *Proposed Thermal Design Procedure*. Inf. téc. CNA2-1152-3BEIN-005-B. Confidencial. 2008.
- [47] NIST/SEMATECH. 7.2.6.3. *Tolerance Intervals for a Normal Distribution*. <https://www.itl.nist.gov/div898/handbook/prc/section2/prc263.htm>. NIST/SEMATECH e-Handbook of Statistical Methods. 2012. (Visitado 17-08-2026).
- [48] Mary Gibbons Natrella. *Experimental Statistics*. Vol. 91. National Bureau of Standards Handbook. Washington, D.C.: U.S. Government Printing Office, 1963.
- [49] Freeman Dyson. «A meeting with Enrico Fermi». En: *Nature* 427.6972 (2004), pág. 297. DOI: [10.1038/427297a](https://doi.org/10.1038/427297a). URL: <https://www.nature.com/articles/427297a>.
- [50] INVAP. *Review of the CHF Prediction Method Applied to the CNA2 Fuel Bundle*. Inf. téc. CNA2-1152-3BEIN-001-A. Confidencial. 2008.
- [51] INVAP. *Incorporation of the 1995 AECL Lookup Table for CHF to the COBRA3-CP code*. Inf. téc. CNA2-1152-3BEIN-004-A. Confidencial. 2008.